单位代码：10220
学　　号：238002070432

中图分类号：TP311.5
密　　级：



东北石油大学

Northeast Petroleum University

硕士研究生学位论文

题　　目　基于大语言模型的需求歧义检测和修复的方法研究

学科专业　软件工程

研究方向　软件工程智能化及应用

硕 士 生　刘芳

指导教师　高俊涛 副教授

二〇二六年六月

中国知网　https://www.cnki.net

Research on the Method of Requirement Ambiguity Detection and Repair Based on Large Language Model

by Liu Fang

Supervisor: Associate Professor Gao Juntao



A Thesis Submitted to the **Northeast Petroleum University**
In partial fulfillment of the requirement
For the Degree of Master of Engineering:Software engineering
June, 2026

中国知网 https://www.cnki.net

基于大语言模型的需求歧义检测和修复的方法研究

摘　要

在现代软件开发中，需求歧义是导致项目失败、成本超支和质量问题的关键因素，因此人们对需求歧义的自动化检测和修复进行了广泛研究。然而现有方法在歧义类型覆盖方面仍存在不足，传统方法缺乏深层次的语义理解、逻辑关系识别以及指代关系识别能力，无法有效检测语用歧义与语言错误歧义，且修复结果与原始需求语义存在不一致问题。为此，本文提出一种基于大语言模型的需求歧义检测与修复方法，构建智能化的需求歧义识别与修复机制，主要研究工作如下：

（1）开展面向需求歧义检测与修复的大语言模型经验研究。探索使用大语言模型高效解决需求歧义检测与修复的问题，通过实证方法系统评估大语言模型在歧义检测任务中的性能表现，设计并验证需求歧义检测与修复的提示词模板和操作流程规范，并与当前最先进方法对比验证其性能优势，明确大语言模型的能力边界与局限性。以经验结论为驱动，为后续结合多智能体混合架构实现多样化需求歧义识别与修复的方法提供实证依据。

（2）提出基于大语言模型的需求歧义检测方法 LMAdetect（LLM-based Multi-Agent Ambiguity Detection）。针对单一模型在多阶段推理中歧义类型覆盖不足的局限，引入多智能体协作机制设计 LMAdetect 框架，首先基于启发式规则对需求进行初步筛选与歧义类型预判，再将不同歧义类型分配给对应的专家智能体进行深度检测。而后对这些检测结果根据置信度进行汇总输出置信度高的分类结果。结果表明，相较传统基于规则的方法，LMAdetect 的 *F*1 分数提升了 0.3440，相较仅使用基于大语言模型的方法，*F*1 分数提升了 0.3160。

（3）提出基于大语言模型的需求歧义修复方法 LMArepair（LLM-based Multi-Agent Ambiguity Repair）。针对现有修复方法在歧义结构提取缺乏规范性、修复建议缺乏针对性的问题，本文设计以歧义类型和歧义需求为输入，针对不同歧义类型采取不同歧义结构提取方法，遵循“歧义触发片段-候选解释集合-模板化解释输出”设计模式，通过领域知识库集成实现歧义修复建议生成。结果表明，LMArepair 在六种歧义类型上的 *F*1 分数均优于对比方法，平均 *F*1 分数为 0.7925。

本文在需求歧义检测与修复方面建立了较为完整的技术体系。通过经验研究明确了大语言模型的能力边界与设计规范，进而提出了融合启发式规则、多智能

中国知网 https://www.cnki.net

体协作与领域知识集成的检测方法 LMAdetect 与修复方法 LMArepair。实验表明，所提出方法在六类歧义类型的检测与修复任务中均优于主流基线方法，$F1$ 分数显著提升，具有实用价值与推广潜力，为软件需求质量的自动化保障提供了有效的技术支持。

关键词：需求歧义；歧义检测；大语言模型；歧义修复；语义理解

中国知网　https://www.cnki.net

Research on the Method of Requirement Ambiguity Detection and Repair Based on Large Language Model

ABSTRACT

In modern software development, requirement ambiguity is a key factor leading to project failure, cost overruns, and quality problems. Therefore, extensive research has been conducted on the automated detection and repair of requirement ambiguity. However, existing methods still have shortcomings in ambiguity type coverage. Traditional methods lack deep semantic understanding, logical relationship recognition, and referential relationship recognition capabilities, failing to effectively detect pragmatic and language error ambiguities, and the repair results are inconsistent with the original requirement semantics. Therefore, this thesis proposes a requirement ambiguity detection and repair method based on a large language model, constructing an intelligent requirement ambiguity identification and repair mechanism. The main research work is as follows:

(1) Conducting empirical research on large language models for requirement ambiguity detection and repair. Exploring the efficient use of large language models to solve the problem of requirement ambiguity detection and repair, systematically evaluating the performance of large language models in ambiguity detection tasks through empirical methods, designing and verifying prompt word templates and operational procedures for requirement ambiguity detection and repair, and comparing their performance advantages with the current state-of-the-art methods to clarify the capability boundaries and limitations of large language models. Driven by empirical conclusions, providing empirical evidence for subsequent methods combining multi-agent hybrid architectures to achieve diversified requirement ambiguity identification and repair.

(2) A requirement ambiguity detection method, LMAdetect (LLM-based Multi-Agent Ambiguity Detection), based on a large language model is proposed. Addressing the limitation of insufficient ambiguity type coverage by a single model in multi-stage reasoning, a multi-agent collaborative mechanism is introduced to design

中国知网 https://www.cnki.net

the LMAdetect framework. First, heuristic rules are used for preliminary screening of requirements and prediction of ambiguity types. Then, different ambiguity types are assigned to corresponding expert agents for deep detection. Finally, these detection results are summarized based on confidence levels to output classification results with high confidence. Results show that compared to traditional rule-based methods, LMAdetect improves the $F1$ score by 0.3440, and compared to methods using only a large language model, the $F1$ score is improved by 0.3160.

(3) A requirement ambiguity repair method, LMArepair (LLM-based Multi-Agent Ambiguity Repair), based on a large language model is proposed. To address the shortcomings of existing ambiguity repair methods, such as a lack of standardization in ambiguity structure extraction and a lack of specificity in repair suggestions, this thesis designs a method that takes ambiguity types and ambiguity requirements as input and adopts different ambiguity structure extraction methods for different ambiguity types. Following the design pattern of "ambiguity trigger fragment - candidate interpretation set - templated interpretation output," ambiguity repair suggestions are generated through domain knowledge base integration. Results show that LMArepair outperforms the comparative methods in $F1$ scores for all six ambiguity types, with an average $F1$ score of 0.7925.

In this thesis, the requirements ambiguity detection and repair has established a relatively complete technical system. Through research, the capability boundaries and design specifications of the large language model are clarified, and then a detection party LMAdetect and a restoration party LMArepair that integrate heuristic rules, multi-agent cooperation and domain knowledge integration are proposed. Experiments show that the proposed method is superior to the mainstream baseline method in the detection and repair tasks of six types of ambiguity, and the score is significantly improved. It has practical value and promotion potential, and provides effective technical support for the automatic guarantee of software requirements.

Key words：Requirement Ambiguity；Ambiguity Detection；Large Language Model；Ambiguity Repair；Semantic Understanding

中国知网 https://www.cnki.net

目　录

第 1 章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....3
1.2.1 需求歧义检测研究现状.....3
1.2.2 需求歧义修复研究现状.....6
1.2.3 大语言模型研究现状.....7
1.3 问题阐述和研究内容.....8
1.4 论文组织结构.....9
第 2 章 相关理论概述.....11
2.1 需求歧义.....11
2.2 需求歧义检测和修复方法.....12
2.2.1 自然语言处理.....12
2.2.2 正则表达式.....13
2.2.3 基于句法结构的规则匹配.....13
2.3 大语言模型和提示工程.....14
2.4 多智能体系统.....15
2.5 本章小结.....16
第 3 章 面向需求歧义检测和修复的大语言模型经验研究.....17
3.1 实验设计.....17
3.1.1 研究问题.....17
3.1.2 数据收集.....18
3.1.3 研究方法.....21
3.2 实验结果与分析.....23
3.2.1 问题 1：歧义检测任务.....23
3.2.2 问题 2：歧义检测模板和流程设计.....26
3.2.3 问题 3：检测方法性能对比.....30
3.2.4 结果启示.....31
3.2.5 有效性影响因素分析.....31
3.3 本章小结.....32
第 4 章 基于大语言模型的需求歧义检测方法.....34
4.1 方法框架.....34
4.2 基于启发式规则的初步筛选.....36
4.2.1 歧义类型的检测规则.....36
4.2.2 预处理算法.....38

中国知网 https://www.cnki.net

4.3 基于大语言模型的歧义分类 39
4.4 基于智能体对大语言模型歧义检测结果合并 41
4.5 实验分析 45
4.5.1 研究问题 45
4.5.2 评价指标及基准方法 45
4.5.3 实验方法 46
4.5.4 实验结果与分析 49
4.5.5 讨论与局限性 61
4.5.6 有效性威胁分析 62
4.6 本章小结 63
第 5 章 基于大语言模型的需求歧义修复方法 64
5.1 方法框架 64
5.2 基于大语言模型的歧义定位 65
5.2.1 预处理 65
5.2.2 模式匹配 66
5.2.3 基于大语言模型的推理与验证 68
5.3 基于领域知识集成的歧义修复建议生成 69
5.3.1 领域语料库构建 69
5.3.2 歧义修复算法 70
5.4 实验分析 72
5.4.1 研究问题 72
5.4.2 评价指标及基准方法 72
5.4.3 实验方法 73
5.4.4 实验结果与分析 73
5.4.5 讨论与局限性 77
5.5 本章小结 77
第 6 章 结论及展望 78
参考文献 80

中国知网 https://www.cnki.net

第 1 章　绪论

1.1　研究背景及意义

本课题来源于黑龙江省自然科学基金资助项目“组织数字孪生中流程性能预测及措施优选方法研究（LH2024F005）”。需求工程（Requirements Engineering，RE）是软件开发过程中一个基础环节，主要包括需求获取、分析、文档化、验证与管理[1]等步骤。其核心目标是明确定义软件系统必须满足的功能和质量约束，以确保最终产品符合用户期望和利益相关者的需求。然而，在实际软件开发中，需求规格说明书（Software Requirements Specification，SRS）通常采用自然语言编写，这种方法简单便捷并且易于理解，但是它容易造成语义上的歧义、不完整和模糊等问题。据资料统计，需求阶段产生的缺陷占比高达 50%以上，远超设计和编码阶段[2]，而需求歧义是需求阶段关键缺陷类型之一，与项目失败高度相关。因此，需求歧义是需求工程中的一个关键问题。需求歧义分为语言歧义和软件工程歧义[3]，本文主要关注的是语言歧义，具体研究其在自然语言需求中的检测和修复方法，目前已确认的语言歧义类型有词汇歧义、句法歧义、语义歧义、语法歧义、语用歧义和语言错误歧义。

需求歧义是 Kamsties 等人在 2000 年首次系统化定义的概念[4]，即由于自然语言本身特点造成的需求描述存在多个可能的理解方式，且在不能有效处理需求歧义时会使需求说明书缺乏明确性、一致性以及可测试性[5,6]。需求歧义源于自然语言的多义性，可能引发开发人员误解[7]、需求冲突或返工。例如，在餐厅优惠纠纷案例中[8]，需求语句“For every Zhongcan consumption reaches RMB 100, receive RMB 30”中“Zhongcan”一词存在歧义（可指午餐或中式餐点），造成消费者与商家对于晚餐是否可享受该优惠产生分歧，进而引发消费纠纷，最终由商家退还 120 元。另一个案例是关于文件柜收据标点问题[8]，收据内容为“27 iron cabinets have been received from the supplier today, the amount of uncollected information cabinet is outstanding”由于逗号位置不明确而产生歧义，既可以理解成全部款项均未结清，也可以理解为仅资料柜款项未结，从而造成买卖双方对支付义务的理解产生分歧，进而引发诉讼，法院最终判决被告支付 12960 元。这些真实案例凸显了需求歧义的严重影响。一方面，多种歧义类型导致需求表达不清楚，难以被利益相关人员一致理解或验证[6]，另一方面，清晰的需求表达可以更好地支持软件的设计和开发。

中国知网　https://www.cnki.net

值得注意的是，需求歧义不仅是需求质量[9]下降的指标，也是需求澄清和改进的机会指标[10]。

传统需求歧义检测和修复方法大多依靠人工检查、基于规则的技术或者需求模板等手段，在词汇和句法上可以发现一部分问题，但是也有诸多不足之处。一是需要遵循人为规定的规则而导致缺乏灵活性，在深层语义理解上存在局限；二是忽略专业知识背景而导致准确性低下；三是在解决问题的过程中需要人工参与，效率低下而且不易扩展及维护。尤其是对于需求变化或者新的歧义出现的情况下，必须要重新制定规则，浪费时间和精力并且容易受到人的主观因素的影响。Gause 等人首次提出了利用多方对需求进行解读来发现其中存在的歧义的方法[11]，但这种方法仍停留在人工层面，不能完成大规模的自动化处理。

随着人工智能的发展，大语言模型（Large Language Model，LLM）如 GPT 和 BERT 的兴起[12]，给需求歧义检测与修复带来了新的可能。由于 LLM 经过大量数据学习，具有较强的语言理解能力和上下文推理能力，可以自主发现需求文档中的语义内容、逻辑关系及潜在问题并进行端到端的智能化处理。本文主要研究基于 LLM 的需求歧义检测与修复的方法，在此基础上提出一种基于多个智能体的应用设计方案，通过多智能体协作与分工[13]，完成不同类型的歧义检测工作，实时共享信息，从而高效检测、分析和定位歧义。基于 LLM 的知识生成能力，参考行业最佳标准，提出合理有效的建议并自动优化重写需求描述，使其更加清晰、完整、准确、一致。

本课题的研究具有重要理论及现实意义。在理论上扩展了自然语言处理（Natural Language Processing，NLP）技术在需求工程中的应用，探索 LLM 在语义歧义消解、领域适应和多智能体协作方面的潜力，促进需求工程领域的智能化发展的同时结合控制自然语言（Controlled Natural Language，CNL）实现软件工程标准化。在实践中，通过提高需求质量降低后续开发风险，有助于减少因需求歧义引发的返工成本，对缩短软件开发周期具有积极意义。本文通过整合多元来源的需求实例进行相关研究，此过程具有良好的泛化能力，有广阔的应用空间。此外还可以减轻人工负担并且提高检查的一致性和准确性。最后，本研究有助于减少因需求问题导致的项目失败，实现软件项目的可持续发展，创造可观的经济效益和社会效益，推动软件行业需求工程实践的革新。因此选题符合当前软件开发中存在的问题同时也促进了技术的进步和发展，有着重要的理论意义和应用前景。

中国知网　https://www.cnki.net

1.2 国内外研究现状

1.2.1 需求歧义检测研究现状

目前有一系列针对需求歧义检测的相关研究工作，根据他们所采用的检测机制，主要可分为三类：基于检查表的方法、基于规则的半自动化方法和基于 NLP 的自动化方法。

基于检查表的方法依靠人类专业知识来识别歧义性，通常使用结构化指南以确保系统分析。Kamsties 等人[4]提出了一种基于检查表的方法用于发现语言中的歧义，针对词汇层面、句法层面以及语义层面，通过预设问题对 SRS 文档进行审查。这种方法适用于小规模项目或初步审查，虽系统化但繁琐耗时，依赖审阅者的专业知识，且难以扩展至大规模文档。Kamsties 等人[14]提出了一种通过检查发现需求文档中歧义的方法，将基于检查表的审查与场景化阅读相结合。检查表方法采用预定义的歧义标识符，供评审人员系统性地扫描文档。场景化阅读则通过构建用例或测试场景，模拟利益相关者的解读来揭示歧义。虽然这种方法能有效调动领域专家参与并实现特定类型歧义的高检出率，但其劳动强度大、需要深厚领域知识且难以扩展至大规模 SRS。此外，由于缺乏自动化处理，该方法容易出现人为错误，并在检测细微语义或语用歧义时存在不一致性。相比之下，LMAdetect 通过使用大语言模型自动检测，不仅减少了人工投入，还能覆盖更广泛的歧义类型，包括语用和语言错误类歧义。

基于规则的方法利用预先定义的语言规则或词汇表进行歧义检测以减轻人工负担并且保留结构性分析，如 QuARS[15]这类需求规范质量分析器，它采用事先规定好的规则识别模糊表述方式，而这些工具只是标记潜在问题供人工审核。可以减轻人工的工作量，适用于初步筛查，QuARS 以专门定义的质量模型为基础，该模型包含多个质量指标，通过这些指标，QuARS 对自然语言需求文档进行分析，自动标记出存在上述潜在缺陷的句子，为需求工程师提供预警信息，帮助他们识别和修正可能导致歧义的问题。Berry 等人[16]对自然语言系统的 SRS 中的歧义问题进行了初步的研究，提出了将非正式需求形式化、寻找歧义模式、比对利益相关方的解读以及与作者建立反馈机制等技术手段。他们注重人工审核并且使用 NASA 的 ARM（Automated Requirements Measurement）等工具来进行模式匹配，但仅限于词汇和句法层面的歧义分析，缺乏语义或语用层面的解析。同样，Nigam 等人[17]也开发了一个简单的基于规则匹配的工具用来查找词汇、句法和语法上的歧义点，

中国知网 https://www.cnki.net

在需求分析过程中帮助需求分析师注意这些歧义。虽然该工具速度快，但是由于准确率不高，因此在处理复杂句子时存在局限性，仍需人工验证。Tjong 等人[18]通过对工业需求语料库进行分析总结出一些规则并开发 SREE 工具，用词素分析加上预先设定的一些规则来识别歧义，这个实验性工具用于辅助需求分析师检测自然语言需求规范中潜在的歧义实例。当 SREE 发现潜在歧义时，会向用户报告该实例，由用户判断是否确实存在歧义，并可根据需要进行消歧处理。SREE 本质上是一个词法分析器，仅针对其数据库中特定词汇进行实例检索。Rosadini 等人[19]在铁路领域应用基于规则的自然语言处理模式，成功识别出被动语态以及模糊表达等问题，达到 80%以上的召回率，但是由于高误报率还需要进一步由人工进行审核。这类规则方法虽能有效处理特定类型的歧义，却难以应对语义与语用层面的复杂情况。Gleich 等人[20]提出一种检测软件需求文档中的歧义的方法，在发现歧义的同时解释产生歧义的原因以帮助需求分析师使其所写文档更加完善。通过统计文中不同术语出现次数从而得到特定领域的术语，主要是在预定义的 38 种模式上用 TreeTagger 和正则表达式来匹配，用词法和句法的方法虽然不能很好地解决复杂的语义或语用歧义，但是因为其简洁性和可靠性所以在实际的需求分析工作中具有显著优势。该方法依赖关键词列表，可以针对词汇歧义、句法歧义、语义歧义进行检测，但其泛化能力有限，没法捕捉到全局的语义依赖关系，对语法、语用以及语言错误歧义无法进行检测。

Sabriye 等人[21]提出了一种基于 NLP 的自动检测 SRS 中句法歧义和语法歧义的方法。该方法的核心是利用 POS 标注技术，它的工作方式是以词性标签匹配以及规则判断为基础，通过量化歧义百分比和可视化输出支持需求分析。其通过三个主要阶段预处理、处理和后处理，将原始文本转换为可处理的结构化数据，使用 POS 标注器为每个句子中的单词分配英语词性标签，提供句子的语法和结构信息，利用 POS 标签检测句法歧义和语法歧义，生成可视化结构直观展示检测结果。该方法只能基于局部的词性信息进行分析，无法捕捉到全局的语义依赖关系。所以，不能检测词汇歧义、语义歧义、语用歧义和语言错误歧义，在面对上下文语义关系引起的歧义时，无法准确检测。Ferrari 和 Esuli[22]旨在识别需求获取过程中不同技术领域利益相关者之间的术语歧义，方法利用领域特定的语言模型和词嵌入技术，量化术语在不同域间的使用差异，并通过歧义评分对潜在歧义进行排序。运用词向量通过跨领域语料库对比术语使用情况，对依赖上下文的术语存在局限，仅检测术语级歧义。Coden 等人[23]提出的 THAT-dictionary 统计方法，利用语境模

中国知网 https://www.cnki.net

式评分判断语义词典中的模糊或者伪术语，用于识别语义资源中相对于特定语料库的歧义或冗余术语，旨在支持信息提取任务中的字典优化。Šenkýř 等人[24]将自然语言处理与领域模型相结合，在 Prolog 推理框架中识别结构歧义以及指代歧义，但是由于过度依赖特定领域的 OCL（Object Constraint Language）规则而使得该系统的扩展性受到限制。Liu 等人[25]使用词嵌入技术识别专业领域的词义模糊问题，但是这种方法只考虑词层面上的词义模糊而忽视句子整体上下文信息，相比之下，LMAdetect 通过将大语言模型与启发式规则相结合，实现了对六种歧义类型的全面检测—包括词汇、句法、语义、语用、语法及语言错误。Veizaga 等人[26]提出基于 Rimay 语言的 Paska 工具，利用 NLP 技术和 Rimay 受控自然语言来检测需求异味（包括与歧义相关的质量问题），通过对需求进行预处理并且将需求划分为多个部分，采用 Tregex 模式[27]、结构模式、规则和词汇表搜索等方式可以检测句法歧义中的协调歧义，无法对词汇歧义、语义歧义、语法歧义、语用歧义、语言错误歧义进行检测。论文中检测协调歧义主要依靠规则来实现。当需求存在两个或更多后续条件，且这些条件由协调连词“or”连接时，Paska 工具会触发协调歧义的检测。通过生成解析树检测协调歧义等，主要依赖预定义的 Rimay 语法，难以全面地考虑句子在整个语境中的复杂语义依赖关系，无法覆盖领域外歧义（如语用歧义）。

Gleich 等人[20]、Sabriye 等人[21]和 Veizaga 等人[26]提出的三种方法，在自动歧义检测领域实现了重大突破，分别运用正则表达式、词性标注和受控自然语言分析等不同技术手段，为该领域发展注入新活力。为更清晰地对比这些方法在不同类型歧义检测中的表现，表 1.1 系统梳理了三者的检测范围，重点分析其在词汇、句法、语义、语法、语用及语言错误等维度的识别能力。

表 1.1 歧义类型检测范围

Table 1.1 Ambiguity type detection scope

工具/方法	词汇歧义	句法歧义	语义歧义	语法歧义	语用歧义	语言错误歧义
正则表达式	√	√	√	×	×	×
POS 标记	×	√	×	√	×	×
Paska 工具	×	√	×	×	×	×

尽管这些研究获得了一定成效，但在歧义检测过程中，仍面临着语义语用分

中国知网 https://www.cnki.net

析缺失、逻辑关系识别不充分、适用性有限等挑战。本研究将会根据现有技术，进一步分析如何提高需求歧义检测的准确性[28,29]以及类型的可扩展性。

1.2.2 需求歧义修复研究现状

需求歧义修复的目的是利用自动或半自动的方式发现并解决 SRS 由于各种原因引起的歧义问题，是 RE 领域的重要研究课题。它可以准确找到并且解决文档中的模糊之处，进而降低由于误解而导致的成本过高以及进度延误的风险。早期工作主要是在句法规则上进行改进和完善，但是随着现有机器学习以及大规模预训练语言模型的发展，目前研究正逐步对多种类型的歧义现象进行系统化处理。

传统方法多依赖于规则和 NLP 技术。Osama 等人[30]构建了基于 Stanford CoreNLP 的句法分析框架 SBADR（Score-Based Automatic Detection and Resolution），借助解析树结构识别并解析句法歧义问题，在 126 个需求数据集上实现 65%精度和 99%召回率。这种方法是给用户提供备选解释来帮助用户进行人工修正，但是由于受到特定模式限制，不能解决语义上的歧义问题。同样 Ashfaq 等人[31]利用语义标注的方法把自然语言的需求转换成一种固定的格式化的表示方式，即通过语义本体规则（Semantic Business Vocabulary and Rules，SBVR）很好地解决了词汇以及句法上的歧义问题。在两个案例中 SBVR 精度达到 96%，说明这个规则具有良好的可解释性，但是该规则缺乏对复杂上下文的适应性。

为提升通用性和准确性，研究者引入领域特定知识和机器学习（Machine Learning，ML）。Ezzini 等人[32]利用 Wikipedia 自动生成领域语料库，结合结构模式和启发式规则处理协调歧义和介词短语附着歧义，在 5156 个工业需求上精度约 80%、召回 89%。该方法通过解释非歧义需求，支持后续信息提取，但仍需人工验证。Ezzini 等人[33]进一步将研究重点聚焦于指代歧义，由 1350 个需求样本的实验分析可知，在低频歧义识别任务中，ML 方法的检测精度高达 60%，同时召回率可达到 100%，解析成功率也接近 98%。这次实验指标展现出比传统 NLP 技术更高的可信度。虽然 ML 在检测低频歧义领域优于传统 NLP 方法，但其依赖前期的高质量数据标注。

近年来，ML 和 LLM 的混合框架成为主流趋势。Izhar 等人[34]提出基于规则与 Random Forest 分类器的混合方法，整合 TF-IDF 向量化、聚类和情感分析，在 1553 个需求数据集上准确率 97%、*F*1 分数 92%，揭示需求易产生歧义。Raj 等人[35]利用 LLaMA-2 细调框架，通过 LoRA 适配器分类歧义并生成无歧义备选，在 1724

中国知网 https://www.cnki.net

个需求上 *F*1 分数 0.80，实现端到端解析，但易受幻觉影响。Talha 等人[36]运用 SpanBERT 与命名实体识别技术，半自动化检测指代、协调和缺失条件歧义，在 425 个需求数据集上 *F*1 分数优于 ChatGPT，强调专用模型相对通用 LLM 的优势。

此外，Scarlini 等人[37]的 ARES（context-AwaRe Embeddings of Senses）框架虽针对词义消歧，但其上下文嵌入技术间接支持需求歧义修复，在多语言 WSD（Word Sense Disambiguation）上 *F*1 为 75.7%，为 RE 提供可迁移的语义工具。

总体而言，当前研究从单纯检测转向检测-解析一体化，强调领域适应和自动化，性能显著提升。然而，仍存在多语句歧义处理不足、标注数据依赖、跨领域泛化弱。未来方向包括集成更多 LLM、动态规则生成和用户交互验证，以实现更精确的歧义修复。

1.2.3 大语言模型研究现状

大语言模型是一种由包含数百亿以上参数的深度神经网络构建的语言模型，通常适用自监督学习方法，可以通过大量无标注文本进行训练。大语言模型在自然语言处理任务中展现出的强大的性能能够支持多种自然语言处理任务[38–40]。在软件需求工程领域，LLM 的优势在于超越传统词向量方法的语义相似性识别，能够捕捉潜在逻辑关联和语义相关性，从而为需求歧义检测和修复提供强大支撑。

LLM 的发展可大致划分为三个阶段：基础模型探索、能力提升和突破性发展。基础模型探索阶段始于 2017 年，Vaswani 等人[41]提出的 Transformer 架构在机器翻译领域实现了重大突破。随后，Google 与 OpenAI 分别在 2018 年提出了 BERT 和 GPT-1[12,42]模型，开启了预训练语言模型的新时代。并推动国内企业如百度和华为推出 ERNIE 及盘古系列[43,44]，采用了类似 BERT 的预训练加微调范式。能力提升阶段（2019-2022 年），研究重点转向零样本或少量样本条件下的高效学习能力，其中 GPT-3 凭借超大规模参数量展现了显著的涌现效应。在此期间，提示工程技术逐渐成熟，通过精心设计的输入指令，例如链式推理结构，提升模型在复杂任务中的推理能力[45]。突破性发展阶段始于 2022 年 11 月，以 ChatGPT 的发布为标志，OpenAI 的 GPT-4 进一步融入多模态能力，接近通用人工智能水平[46]。进入 2025 年，开源模型如 Meta 的 Llama 系列和 DeepSeek 的压缩技术实现了高效部署。目前智能代理技术在实际应用中已经有了显著的进展。比如利用多个智能体协同工作，一起执行复杂任务的微软的 AutoGen 框架以及能够独立开发完整代码项目的 AI 程序员 Devins。

中国知网 https://www.cnki.net

提示工程对 LLM 的能力也起到了一定提升作用。通过给 LLM 提供精心设计的提示词模板和示例，可以帮助模型理解任务需求，增强模型的能力[47]。在需求歧义检测及修复过程中，良好的提示可以使 LLM 理解上下文信息、识别出歧义类型并提出解决方案从而消除语义模糊的情况。近年来，LLM 对于需求文档的理解水平已经有很大提升。目前有关缺陷检测与修复的研究成果也主要集中在语言上的缺陷（如歧义、不一致[48]）和图表上的缺陷（如不完整、冗余[49–51]），这些方法基本都是模块化的设计方式，即先进行数据预处理，再将问题拆解成多个小任务，然后提取每个子任务的相关特征最后进行分析。在需求工程中，LLM 的语义理解和生成能力为歧义检测提供了一条新路径并且极大地提高软件开发效率。

1.3　问题阐述和研究内容

由于需求歧义中的语言具有多样性与复杂性，且语义歧义和语用歧义高度依赖上下文和领域知识，故单一方法难以全面覆盖词汇、句法、语义、语用等不同类型的歧义。传统基于规则或者词性标注的方法因缺乏深层语义理解能力，难以准确捕捉复杂的语义依赖关系或跨句逻辑关联。现有的需求歧义检测及修正方法由于使用固定的规则或者局部特征造成的泛化性能较差，而且缺少对动态语义以及大量背景信息的理解能力因而不能满足多样的语义场景，其修复结果存在与原始需求语义不一致的问题。

本文采用大语言模型建立智能检测机制的方法来发现清晰需求与歧义需求之间的差异，实现基于这些特定语言特征的语言歧义自动检测策略。通过语义解析能力和文本生成能力，可以准确地判断出 SRS 中的歧义并给出相应的改进意见从而降低人工的工作量。本文主要研究内容如下。

（1）系统开展面向需求歧义检测与修复的大语言模型经验研究。大语言模型在自然语言理解与生成方面展现出显著优势，然而其在需求歧义检测与修复这一专项任务上的适用性与能力边界尚缺乏系统性实证支撑。为此，本文在提出具体方法之前，首先从实证角度对大语言模型应用于该任务的可行性展开前导性探索。围绕三个核心问题：LLM 能否有效完成歧义检测任务、如何设计检测模板与流程使其发挥最优效果、以及其性能相较于当前最先进方法是否具有竞争力。实验结果表明，大语言模型在需求歧义检测任务上具备性能优势，同时也暴露出单一模型在多阶段推理与复杂歧义场景下的处理局限。上述经验研究结论为后续引入多智能体混合架构、构建系统性需求歧义检测与修复方法提供了明确的问题导向与

中国知网　https://www.cnki.net

实证依据。问题一确立了方法的可行性前提，问题二驱动了检测方法的多智能体架构设计，问题三驱动了修复方法的领域知识集成设计。三者共同构成本文方法体系的实证基础。

（2）提出基于大语言模型的需求歧义检测方法。针对经验研究所揭示的核心局限：单一 LLM 难以处理多阶段复杂推理，且在同时检测六类歧义类型时容易出现混淆。本文基于多智能体协作机制设计 LMAdetect 框架，覆盖多种类型歧义检测，将不同歧义类型（如词汇、句法、语义、语用等）分配给专属智能体进行层次化处理，建立通信机制确保上下文准确传递，并通过数据集构建和实验评估验证方法的有效性。

（3）提出基于大语言模型的需求歧义修复方法。针对经验研究所揭示的核心问题：单一 LLM 的修复结果存在语义不一致，且由于领域知识缺失，修复容易偏离原意。本文提出 LMArepair 框架。该框架通过模式匹配结合领域知识集成，以领域语料库为外部知识支撑，使用专家智能体对定位出的歧义片段进行针对性修复建议生成，在保障修复准确性的同时维持原始需求的语义完整性。

1.4 论文组织结构

本文共包含六个章节，系统介绍了研究内容及其实现方案，具体内容安排如下。

第 1 章绪论。介绍研究背景及意义，整理国内外相关领域研究现状，分析现有方法的优缺点，总结本文主要研究内容并概述论文结构。

第 2 章相关理论概述。介绍需求歧义方面的相关理论，阐述歧义检测以及修复的主要技术手段，并介绍大语言模型的相关知识。

第 3 章面向需求歧义检测和修复的大语言模型经验研究。本章以探索大语言模型高效解决需求歧义检测与修复问题的可行性为出发点，设计并实施前导性经验研究。围绕模型检测性能评估、提示词模板与流程规范设计、与当前最先进方法的对比验证依次展开，通过实证结果明确大语言模型在该任务上的能力边界与局限所在，为第 4 章和第 5 章系统性检测与修复方法的提出提供问题导向与实证依据。

第 4 章基于大语言模型的需求歧义检测方法。本研究提出一种融合大语言模型与多智能体协作的检测框架 LMAdetect。引入层次化的多智能体协作机制来处理不同类型的歧义，并对多种最新的 LLM 进行了详尽的实验评估，通过实验结果展

中国知网 https://www.cnki.net

示 LMAdetect 方法相较于传统方法的显著优势。

第 5 章基于大语言模型的需求歧义修复方法。本研究提出基于大语言模型与多智能体协作的歧义修复框架 LMArepair。通过基于规则的模式匹配以及领域知识集成，根据定位出的歧义词短语进行针对性的歧义修复建议生成，并通过人机协作进行辅助修复歧义需求。

第 6 章结论与展望。总结本文的研究成果，归纳本文所提方法在需求歧义检测和修复方面的贡献，并对未来的研究方向进行展望。

中国知网　https://www.cnki.net

第 2 章　相关理论概述

本章主要介绍本文研究所涉及的相关理论基础，为后续需求歧义检测与修复方法的设计提供理论支撑。首先介绍自然语言需求中的歧义定义及分类；其次阐述需求歧义检测与修复中常用的自然语言处理方法、规则匹配方法；然后介绍大语言模型与提示工程的基本原理；最后对多智能体系统的概念及协作机制进行说明。

2.1　需求歧义

在软件需求工程中，需求规格说明书通常采用自然语言进行描述。由于自然语言本身具有多义性、上下文依赖性以及表达灵活性，使得需求描述中容易产生歧义问题。需求歧义是指同一段需求描述可能被不同的阅读者理解为不同的含义，从而导致系统分析、设计与实现过程中出现理解偏差。

Berry 等人[3]编写的歧义手册对自然语言需求中的歧义进行了系统梳理和定义，提出歧义主要来源于语言表达本身以及读者对语言的理解差异。自然语言具有多义性，即一个概念可以用多个短语来表达，一个短语也可以用来表达一个概念。歧义可能存在于词汇层面、语法层面、语义层面或上下文解释层面[52]。根据这些层面，自然语言需求中的歧义可分为以下四类：词汇歧义、句法歧义、语义歧义和语用歧义。词汇歧义是指一个词语在不同上下文中可能具有不同的含义。例如，“bank”既可以表示银行，也可以表示河岸。在软件需求中，专业术语、缩略词或领域词汇常常存在类似问题；句法歧义是指一个句子可能存在多种语法结构，从而导致不同的理解方式。例如，一个句子可能对应多个句法树结构，不同结构代表不同的语义解释；语义歧义是指句子在语法结构明确的情况下，仍然可能对应多个逻辑语义表达。例如代词指代不明确、逻辑关系表达不清晰等问题：语用歧义是指句子的真实含义依赖于具体语境、领域知识或读者背景知识。即使语法和语义表达都正确，不同读者仍可能产生不同理解。

此外，Berry 等人[3]也将语言错误视为一类单独的歧义。该类歧义并非源于语言本身的多义性，而是由于拼写错误、标点误用或语法错误，使读者难以判断作者的真实意图，从而产生歧义。同时，文献还指出了与歧义密切相关但应加以区分的两个概念：模糊与笼统。模糊，即如果一个表达式包含边界情况，则该表达式是模糊的，在这种情况下，表达式的真值无法确定，通常是由形容词或副词引

中国知网　https://www.cnki.net

起的；笼统，即如果需要使用更多细节来说明表达式，则表达式是笼统的。严格来说，二者并不属于歧义范畴，但在需求工程实践中往往与歧义问题交织出现。

在软件需求自动分析与检测的研究工作中，Sabriye 等人[21]从工程的角度对歧义进行更细致的划分，将其分为语法歧义与句法歧义。语法歧义主要是由被动语态、缺少主语或者缺少标点符号等原因所造成的歧义；而句法歧义则是指一个句子在结构上可以有很多种不同的理解方式。这种划分并不是传统的语言学上的定义，而是为了便于基于词性标注来进行自动歧义检测提出的。综合歧义手册与自动检测相关研究，自然语言需求歧义主要可分为词汇歧义、句法歧义、语义歧义、语法歧义、语用歧义和语言错误歧义。

2.2　需求歧义检测和修复方法

为了自动识别和修复需求中的歧义问题，研究人员提出了多种基于自然语言处理、规则匹配的方法。本节对相关基础技术进行介绍。

2.2.1　自然语言处理

自然语言处理作为人工智能的一个子领域，可广义定义为将计算技术应用于处理和分析自然语言—即人类书面和口语语言[53]。在需求工程领域，自然语言处理技术常用于需求文本预处理、语言特征提取以及语义分析等任务。NLP 的核心技术包括分词、词性标注和句法分析。

自然语言处理流程一般包括以下几个部分：（1）分词器（Tokenizer）用于把一段文本切分成多个词元，如句子“What time is it?”会被切分成五个词元[What, time, is, it, ?]；（2）句子分割器（Sentence Splitter）用于把一段文本划分成一个个句子；（3）词性标注器（Part-Of-Speech Tagger，POS Tagger）用于给每一个句子里面每一个词元标注词性，比如名词、动词或是代词等；（4）词形还原器（Lemmatizer）用于找出每一个词元的基本形式即原形，比如“playing”的原形是“play”；（5）成分分析器（Constituency Parser）用于找出一个句子里面各个组成部分，比如动词短语和名词短语等；（6）依存分析器（Dependency Parser）用于找出句子里面词元之间的联系，比如主语与宾语的关系等；（7）共指消解器（Coreference Resolver）用于识别文本中指代同一实体的各种表述；（8）语义分析器（Semantic Parser）用于提取单词含义的相关信息。这些处理步骤为需求歧义检测提供了基础语言特征支撑。

中国知网　https://www.cnki.net

2.2.2 正则表达式

正则表达式（Regular Expression，Regex）是一种用来表示字符串集合形式化的方法，在文本处理及模式匹配方面有着广泛应用。而在自然语言处理中，正则表达式一般作为最简单的一种规则形式用于识别文本中有明显特征的语言结构，在基于规则的需求歧义检测中起到基石作用，主要是针对词法层面或者浅层次句法层面的歧义建立模型并进行分析。它是根据形式语言理论中的正则语言，利用有限状态自动机构成的一种有效的方法来进行匹配。在需求歧义检测中，正则表达式通常用于识别具有明显语言模式的歧义表达，例如：模糊副词（usually、normally、often）；不确定词汇（some、many、few）；被动表达结构；条件句模式。Regex 允许程序员可以用简短的语句来表示一个匹配规则，允许通配符（.）、重复量词（*、+、?、{n,m}）、字符类（[a-z]）、分组（()）、选择（|）、锚点（^、$）和否定前瞻/后瞻等字符形式。由于其表达简单、执行效率高，正则表达式常作为基于规则方法中的基础匹配工具。

2.2.3 基于句法结构的规则匹配

相比于基于字符序列的简单匹配方法，基于句法结构的规则匹配是规则驱动方法的高级形式，它超越线性文本和简单序列，操作于结构化的句法表示，从而能够捕捉需求文本中更复杂的语法关系和层次歧义。该方法的核心原理是利用句法解析器将需求句子转换为树状或图状结构，然后定义规则在该结构上进行查询和匹配。这些规则描述节点间的支配关系、路径关系和邻接关系。句法结构表示通常包括：（1）成分句法树，以短语为节点构建树状层次结构；（2）依存关系图，以词语为节点、依存关系为边构建图结构。在此基础上，可以通过预定义规则匹配句法结构中的特定模式，从而检测潜在歧义。

基于句法结构的规则匹配的一个典型实现工具是 Tregex（Tree Regular Expressions）。Tregex 是由 Stanford NLP 提出的基于成分句法树的查询及模式匹配的语言，在树形结构中定义以及匹配一定的句法规则，类似于正则表达式对于字符串的操作，但是应用于层次化的句法结构[27]。Tregex 以句法分析得到的成分句法树作为输入，利用节点类型以及它们之间的层级关系来找到符合要求的句法子结构，该语言支持多种关系操作符，例如“<”表示父子支配关系，“$+”表示相邻兄弟节点，“!”表示否定约束，从而能够表达复杂的句法结构模式，如包含名词短语（NP）和动词短语（VP）的条件从句。

中国知网 https://www.cnki.net

传统基于规则的方法具有较强的可解释性和较低的实现成本，在固定模式识别中表现良好。然而，这类方法高度依赖人工规则设计，泛化能力较弱，当面对复杂语义关系、跨句推理以及领域知识依赖问题时，往往难以获得理想效果。因此，引入具有更强语义理解能力的模型逐渐成为研究趋势。

2.3　大语言模型和提示工程

LLM 是近年来自然语言处理领域的重要研究成果，具备较强的语言理解与生成能力。得益于其在语义建模和上下文理解方面的优势，大语言模型在问答、分类、摘要、翻译、聊天等从理解到生成的各种文本处理任务中展现出良好的应用潜力[54]。在实际应用中，直接依赖大语言模型的默认输出往往难以满足特定任务的需求，因此研究者提出了一系列引导和约束模型行为的方法。其中提示工程也称为上下文提示，是一种通过不更新模型的权重或参数来引导大语言模型行为朝着特定结果的方法。

提示工程的基本理念是在给定的信息中指明任务目的、规定输出格式或是给出一些背景信息，从而使模型利用其已有的经验和推理来更准确地把握用户的意图以及得到预期的结果。由于这种方法不需要增加额外的训练成本，在使用上具有较大的灵活性并且部署成本低，因此也是目前大语言模型应用中的一种有效途径。

在提示工程框架下，大语言模型通常以零样本学习或少样本学习的方式完成任务。零样本学习是指模型在没见过任何示例的情况下直接完成某项任务，这种方式能够在新任务上快速验证模型的泛化能力。少样本学习是在给出任务描述的基础上，为模型提供多个关于任务输入输出的示例样本，让模型更全面地理解任务。该方法泛化能力强，但是对示例的数量和质量要求较高。相较于零样本学习，少样本学习通常具有更高的准确率和稳定性，但其效果在较大程度上依赖于示例的数量和质量。在需求歧义检测等任务中，零样本和少样本学习能够在无需额外标注数据的情况下快速构建模型能力，为基于大语言模型的方法提供了较高的灵活性。

链式提示（Chain-of-Thought Prompting，CoT）[55]是一种通过多次指引模型进行逐步推理或分步解释的提示方法，该方法通过提供中间步骤或逐步推理过程来帮助模型思考和推导最终结果，增强了大语言模型在复杂推理任务中的表现。与标准提示直接要求模型输出答案不同，思维链提示通过引导模型逐步分析问题，

中国知网　https://www.cnki.net

详细推理每一步的逻辑过程，最终得到了正确的答案。思维链除了可以将复杂问题进行多步推理得到正确答案外，还提供了调试能力，用户可以根据推理链条清晰地了解模型是如何一步一步得到答案的。当模型推理出现问题之后，用户还可以分析每一步的逻辑进而发现问题所在并加以修改。因此，提供少量带有思维链的示例可以帮助大语言模型理解任务中的推理逻辑，提升大语言模型的表现。

2.4 多智能体系统

智能体（Agent）是指可以感知周围环境、根据自身状态及目标自主思考并做出判断同时执行相应行为的计算机实体。在智能体系统中，通常以一个 LLM 为智能体的“大脑”，再加上一些决策过程，如任务分解、多路径探索[56,57]、工具使用（调用外部 API、数据库、计算工具[58]）、记忆能力（短期上下文记忆+长期向量数据库记忆[59]）等，显著增强了智能体的自主性以及解决实际问题的能力。

单智能体系统是指在一个环境中只有一个可以做出决策的实体。这个实体可以自己负责观察、决策、执行等任务，在自身内部逻辑基础上与其他周围事物相互作用。而且单智能体已经具备较强认知能力，在结构化推理、工具使用、背景知识获得方面都有所体现[60]。但是其存在缺点在于当遇到比较复杂情况或者是需要从各个角度或者多个方面考虑某个问题就会出现问题，例如认知负载过高、单维思考造成偏见以及无法进行扩展等。

多智能体系统是指在一个环境中存在多个能够自主做决策的实体，这些智能体之间可以相互协作、竞争或者各自独立并行等，在此基础上互相传递信息、分工合作或者竞争，最终达到一个共同的目的。相较于单智能体系统，多智能体系统更加注重个体之间的相互影响、角色划分、涌现行为以及集体智能。每一个智能体都可以有不同的角色、策略、手段和方式，通过持续交流实现动态协作，从而更好地去完成更加复杂、多样和大规模的任务。而多智能体系统的最大优势就是智能体之间能够相互配合进行交互，其常见机制包括：（1）任务分解与分配，把复杂任务划分为小任务，让擅长不同方面的智能体去做相应部分的工作；（2）信息共享与交流，通过发送消息、黑板系统或共享记忆实现知识同步；（3）协商与协调，使用契约网协议、投票机制、博弈论均衡等方式解决冲突；（4）协调范式，可选择集中式、分布式或混合式。

对于各种复杂的文本分析、多种类型的信息提取、需求工程以及战略规划等情景中，使用多智能体系统通过角色分工，例如规划者、执行者、验证者、批评

中国知网 https://www.cnki.net

者等角色之间合作或者从多个角度出发协作可以极大地提高系统的模块化程度、可解释性、精确度以及处理上限。而这种“取长补短、集思广益”的设计思想，正是建立灵活、可扩展、智能化分析及决策系统的重要思路。

2.5　本章小结

本章介绍了本研究相关的基础知识。首先介绍了需求歧义的类型以及相关定义。其次介绍了自然语言处理中涉及到的一些流程组件以及一些正则表达式、规则匹配的相关概念。最后对大语言模型的相关理论做出概述，介绍了智能体的相关知识。

中国知网　https://www.cnki.net

第 3 章　面向需求歧义检测和修复的大语言模型经验研究

LLM 作为近年来自然语言处理领域的重要突破，在文本理解、生成与推理等方面展现出显著能力。然而，LLM 在软件需求工程领域的应用仍处于早期探索阶段，尤其是在需求歧义检测与修复这一具体任务上，现有研究十分有限，缺乏系统性的实证依据。在将 LLM 引入需求歧义处理之前，首先有必要通过经验研究的方式，对其能力边界、适用条件及与现有方法的性能差异进行系统研究，为后续方法设计提供可靠的实证基础。

为此，本章以经验研究为手段，围绕三个核心问题展开调研：LLM 能否有效完成歧义检测任务、如何设计检测模板与流程使其发挥最优效果、以及其性能相较于当前最先进方法是否具有竞争力。通过对上述问题的系统回答，本章旨在梳理 LLM 应用于需求歧义领域的可行性与优势所在，并以此作为后续提出系统性检测与修复方法的实证依据。

3.1　实验设计

3.1.1　研究问题

本文提出以下三个研究问题来验证 LLM 对于检测和修复任务上的有效性，逐步建立 LLM 应用于需求歧义检测与修复的实证认知，主要研究问题如下。

（1）问题 1：大语言模型（如 GPT-4o）在歧义检测任务中的表现如何？研究 LLM 对于需求歧义检测效果及表现。通过对多个主流 LLM 的检测效果进行横向评估，判断其可行性并确定最优模型选择。

（2）问题 2：基于 ChatGPT 的歧义检测模板和流程如何设计？在确认 LLM 具备检测能力的基础上，进一步探讨如何通过结构化的提示词模板与操作流程，使 LLM 的检测效果达到最优。合理的模板与流程设计不仅能够提升检测准确性，也为后续构建系统性方法提供可复用的操作规范。

（3）问题 3：基于 ChatGPT 的歧义检测方法相对于当前最先进检测方法的性能如何？通过与现有最先进方法的对比实验，客观评估 LLM 方法的相对优势与局限。这一比较结果将直接说明引入 LLM 构建新方法的研究价值，并揭示现有单一 LLM 调用方式的不足之处，从而为后续方法的改进方向提供依据。

中国知网　https://www.cnki.net

3.1.2　数据收集

本文在多个学术数据库通过关键词如“需求歧义检测”、“需求歧义修复”、“大语言模型”等进行搜索，以找到关于需求歧义的相关工作。初始检索大约 70 篇文献，然后根据以下标准对这些文献进行筛选。（1）相关性：文章必须是需求歧义相关或者是在需求工程中用到自然语言处理方面的工作；（2）质量：尽量选择高质量期刊、会议或者是被大量引用的文章；（3）多样性：尽量包括不同类型的歧义来增加数据集鲁棒性。依据文章的研究对象以及不同的歧义类别数量等因素判断是否符合标准，剔除与需求歧义检测或者 NLP 无关的文章，仔细阅读每一篇文章以确认其是否符合要求，最后确定 12 篇高质量文章[3,14,16,17,18,20,21,61–65]。为使数据集构建过程清晰可复现，本节详细说明样本抽取、负例定义及多歧义处理规则，具体流程分为以下三个步骤。

（1）样本抽取方式。针对上述 12 篇文献中的需求样本，本文采用分层抽取策略。对每篇文献所提供的需求示例或附录数据集按歧义类型进行分类汇总，提取其中明确标注了歧义类别的单句需求样本。对于仅提供原始需求文档而未标注歧义类型的文献，由两名具有需求分析经验的标注人员依据 3.1 节标注准则对各句逐一判断后再行纳入。负例样本（即不含歧义的需求语句）则从上述文献中明确标注为“无歧义”的样本或 SRS 中经标注人员确认无歧义的原始语句中抽取。

（2）负例样本的定义与确认方式。本文将负例样本定义为：在语义、句法、语用、语法及语言形式等各个层面均不存在歧义的需求语句。负例样本的来源包括两类：其一，来自 12 篇文献中被作者明确标记为“无歧义”的对照样本；其二，来自 SRS 文档中经两名标注人员独立审核均判定为无歧义的原始语句。

（3）六类歧义之间的互斥性说明。本文在标注体系设计上遵循“优先级互斥”原则，即每条需求样本在最终数据集中仅标注一种主导歧义类型，以保证各类别之间的可区分性。然而，需要说明的是，六种歧义类型在语言学层面并非完全互斥，同一句话在理论上可能同时存在多种歧义特征（例如，一个句子可以既含有歧义词汇，又因句法结构不清而产生句法歧义）。针对此类情形，本文采取以下处理原则：若一条需求样本被两名标注人员判定存在两种及以上歧义类型，则由两人协商确定最主要的歧义来源，将该样本归入优先级更高的类别，歧义类型优先级排序为：词汇歧义>句法歧义>语义歧义>语用歧义>语法歧义>语言错误歧义（该优先级参照 Berry 等人[3]的分类体系及标注准则）。对于无法区分歧义类型的样本，在数据集构建阶段予以剔除，不纳入正式实验样本，以保证标注质量。

中国知网　https://www.cnki.net

为了保证数据集标注一致性和可复现性，本文参考 Berry 等人[3]的工作制定标注准则如表 3.1 所示。检查单词是否在上下文中允许多种解释，且这些解释源于词典含义而非句子结构，如果歧义可以通过词典或词源区分，则标注为词汇歧义；如果歧义是由句子中的语法结构造成的而不是由词的意义或逻辑关系造成的，而且可以找到不同的结构化表示方法来解释这个句子，则标注为句法歧义；语义歧义则是由于逻辑关系引起而不是由语法引起的，在没有词汇和结构歧义的情况下，如果句子语法唯一但逻辑解读多，则标注为语义歧义；句子在特定语境中出现多种含义，则标注为语用歧义；语法歧义源于句子语法形式缺陷，而非语境、词汇含义或逻辑关系；语言错误歧义源于写作过程中的语言使用错误，如拼写错误、语法不一致或标点缺失等，若纠正该错误可消除歧义，则标注为语言错误歧义。

本文在已获取的数据集上进行实验，在这些数据集中，有歧义的需求数据集占比 73.15%。表 3.2 给出了数据集所对应的信息。

表 3.1 标注准则

Table 3.1 Labeling criteria

歧义类型	标注准则	示例
词汇歧义	1.识别潜在歧义词，使用词典检查多个含义 2.检查上下文是否允许多种解释 3.标注时注明可能的含义，引用词汇表作为参考	“The bank can be slippery when wet.” 1.识别潜在歧义词“bank”，查词典：含义 1（金融机构）、含义 2（河岸） 2.检查上下文，支持含义 2，但 SRS 中可能误为含义 1 3.标注为词汇歧义，列出含义，建议用词汇表定义“bank”为“河岸”
句法歧义	1.绘制句子的解析树，检查是否有多个合法结构 2.测试不同结构是否产生不同含义 3.标注时，指定子类型并列出可能结构	“The police shot the rioters with guns.” 1.绘制解析树，结构 1（警察用枪射击暴徒）、结构 2（射击持枪暴徒） 2.测试含义差异，暴力程度不同 3.标注为句法歧义，列出结构，（shot（with guns））（rioters（with guns））

中国知网 https://www.cnki.net

表 3.1 标注准则（续）

Table 3.1 Labeling criteria

歧义类型	标注准则	示例
语义歧义	1.转换为谓词逻辑，检查量词/否定范围是否允许多种形式 2.测试上下文是否支持多种逻辑解读 3.标注时，列出逻辑形式和原因	“All linguists prefer a theory.” 1.转换为逻辑 2.测试含义 3.标注为语义歧义，加括号“All linguists prefer（a theory）”指定范围
语用歧义	1.分析上下文（前后句、情境），检查指代/指示是否多义 2.测试替换先行词是否改变含义 3.标注时，指定子类型并列出可能上下文解读	“The trucks shall treat the roads before they freeze.” 1.识别指代词“they”，可能先行词：trucks 或 roads 2.测试上下文：冬季道路维护，含义 1（卡车冻前处理）、含义 2（道路冻前处理） 3.标注为语用歧义，列出先行词
语法歧义	1.句子末尾无句号，导致句子边界模糊，无法确定语义完整范围 2.句子符合被动语态的 POS 标签组合且未明确“执行主体”	“Student records should be documented.” 1.词性标注 2.匹配被动模式 3.标注为语法歧义
语言错误歧义	1.检查语法或标点错误 2.测试意图和字面含义 3.标注时，注明错误类型和可能误解	“Everybody has their lunch.” 1.检查错误，“Everybody”是单数主语，应配单数代词，但“their”是复数 2.测试意图 vs.字面：意图（每个人有自己的午餐）vs.字面（可能误为共享午餐或不确定数量） 3.标注为语言错误歧义，列出误解

需要说明的是，本研究采用基于大语言模型的歧义检测与修复方法，大语言模型本身不进行参数训练或微调，因此不涉及传统机器学习中的训练集、验证集、测试集划分，本研究的数据使用方式如下。（1）提示词示例库（外部来源）：本研究中提示词模板所包含的示例均直接引用自 Berry 等人[3]论文中公开的经典歧义例句，这些示例仅用于引导模型理解歧义检测任务。（2）评估数据集：表 3.2 所

中国知网　https://www.cnki.net

示的 1192 条样本全部用于方法性能的最终评估，即作为评估集使用。

表 3.2 实验数据集

Table 3.2 Experimental dataset

样本	歧义类型	样本数量
正例样本	词汇歧义	135
	句法歧义	127
	语义歧义	353
	语用歧义	92
	语法歧义	80
	语言错误歧义	85
负例样本		320

3.1.3 研究方法

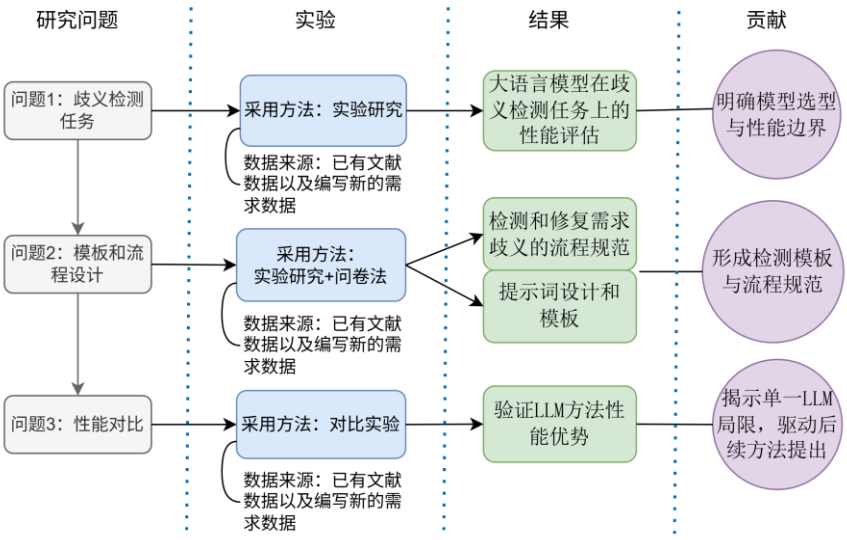


图 3.1 总体实证方案

Fig. 3.1 Overall empirical plan

总体实证方案如图 3.1 所示，图中呈现了三个研究问题在方法、数据与实验设计上的整体布局及相互关系。三个问题依次递进，从验证 LLM 基础能力、优化检

中国知网 https://www.cnki.net

测模板与流程，到与现有最优方法进行性能对比，逐步建立 LLM 应用于需求歧义检测与修复的实证认知。本节在此基础上，分别说明每个研究问题所采用的具体研究方法。

（1）实验研究法

对于问题 1，本文使用实验研究法，通过对比实验考察 LLM（GPT-4o）对于歧义识别的效果。在实验过程中考虑因素包括但不限于输入文本难易程度、歧义种类等，观察模型表现以及应对方式。用模型预测结果与人工标注的歧义标签进行比较，客观评估该模型在该方面的优劣之处。让 LLM 对这些样本进行分类和分析，以此判断 LLM 能否做好歧义检测工作。计算模型相关性能指标，包括准确率、召回率、精确率、$F1$ 分数、困惑度、错误率等。

准确率表示正确分类的样本数占总样本数的比例，其计算公式如式(3.1)所示。

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.1}$$

式中，TP 表示被正确分类为正类的样本数，TN 表示被正确分类为负类的样本数，FP 表示被错误分类为正类的样本数，FN 表示被错误分类为负类的样本数。

召回率用于评估模型正确检测出的歧义数量与实际存在的歧义数量之间的比例，其计算公式如式(3.2)所示。

$$Recall = \frac{TP}{TP + FN} \tag{3.2}$$

精确率用于衡量模型在判断为歧义时的准确性，其计算公式如式(3.3)所示。

$$Precision = \frac{TP}{TP + FP} \tag{3.3}$$

$F1$ 分数综合考虑了精确率和召回率，是一个综合评估指标，其计算公式如式(3.4)所示。

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{3.4}$$

困惑度用于衡量语言模型对给定序列的预测不确定性，反映生成文本的流畅性和可读性，其计算公式如式(3.5)所示。

$$PPL(X) = \exp\left(-\frac{1}{N} \sum_{i=1}^{N} \log p(w_i \mid w_{<i}) \right) \tag{3.5}$$

式中，N 表示测试序列中的 token 总数；$p(w_i \mid w_{<i})$ 表示模型对第 i 个 token 的条件概率（给定前 $i-1$ 个 token）。

错误率用于衡量性能的退化程度，间接反映模型的鲁棒性，其计算公式如式

中国知网　https://www.cnki.net

(3.6)所示。

$$ErrorRate = 1 - Accuracy = \frac{FP + FN}{TP + TN + FP + FN} \tag{3.6}$$

然后评估模型在歧义检测方面的准确性、效率、生成性和鲁棒性进而判断其可行性。再根据实验结果及所得到的各项指标对 LLM 在歧义检测方面所做的工作进行总结，此过程不仅考虑模型正确率，同时也考虑模型对不同类型歧义是否具有鲁棒性和灵活性。对于问题 2，在数据集上进行实验并且用准确率、召回率、*F*1 分数等来评价模型的效果。随后制定实验模板来帮助模型理解用户输入并进行歧义识别。最后根据调研结果收集用户对使用模板的反馈。

（2）问卷法

对于问题 2，本文采用问卷法面向学生和初学者进行调查，通过结合已有的文献回顾，汇总并分类了需求歧义的典型实例，采用问卷调查收集用户对使用模板的反馈。

（3）对比实验法

对于问题 3，本文采用对比实验的方式，将当前最优需求歧义检测方法作为基准，在同一数据集基础上比较基于 LLM 的方法与现有最佳检测方法之间的性能差异。通过不同评价指标对方法进行比较，结合结果分析得出基于 LLM 的需求歧义检测方法相较于传统方法的优势所在，这种实证方法提供了可量化的数据以及客观证据以说明每种方法的相对优势和劣势。同时也可以据此进一步改进基于 LLM 的需求歧义检测方法使其更加完善。

3.2 实验结果与分析

本节依据 3.1 所设定的三个研究问题，分别呈现各问题的实验结果与分析。问题 1 关注 LLM 在歧义检测任务中的基础性能，问题 2 聚焦模板与流程的设计优化，问题 3 则通过与现有最优方法的对比评估 LLM 方法的竞争力。

3.2.1 问题 1：歧义检测任务

本文用收集到的 1192 条需求数据进行歧义检测任务实验，评估大语言模型在歧义检测任务上的效果。使用 LLM（GPT-4o）对它们进行分类并分析其在歧义检测任务上的表现，再计算对应模型的准确率[66,67]、召回率、精确率[39]、*F*1 分数[68]、困惑度等各个指标，并考察模型在歧义检测任务上的准确性[28,29]、生成性和鲁棒性，综合判断 LLM 进行歧义检测任务是否可行。最后根据上述工作所得结论以及

中国知网 https://www.cnki.net

计算出的性能指标总结大语言模型在歧义检测任务上的整体表现。

针对不同提示词输出得到的结果进行指标计算，从而选择最优的提示词。选取 LLM 生成文本质量的指标准确度、生成性、鲁棒性，通过四个模板如表 3.3 计算比较。不同模板所得的结果由表 3.4 所示，模板四准确度最高，其歧义检测和修复效果也最好。生成性是衡量模型生成文本的能力，可以用来衡量模型在产生符合高质量文本方面的表现。该指标的计算方式有很多，一种比较常见的是用困惑度来评价（困惑度越低，生成性越好）。模板四的困惑度最低，因此其生成性最佳。鲁棒性是用来衡量模型对于干扰和异常输入抵抗能力的指标，可用于评估模型在处理需求歧义文本方面的稳定性。其中一种常用方法是使用错误率进行衡量（错误率越低，鲁棒性越好）。模型四的错误率最低，因此其鲁棒性最好。

表 3.3 模板

Table 3.3 Templet

编号	模板
模板一	输入歧义需求---检测这条需求的歧义类型---检测这条需求的歧义类型给个修改的建议
模板二	输入歧义需求---检测这条需求的歧义类型---检测这条需求的歧义类型从几个歧义类型里面挑出一个---检测这条需求的歧义类型给个修改的建议
模板三	输入歧义需求---输入定义---检测这条需求的歧义类型---检测这条需求的歧义类型给个修改的建议
模板四	输入歧义需求---输入定义---检测这条需求的歧义类型---检测这条需求的歧义类型从几个歧义类型里面挑出一个---检测这条需求的歧义类型给个修改的建议

实验结果显示，模板四在生成文本质量上表现最佳，准确度为 0.9200。说明通过模板四所生成的文本与目标文本非常接近，在生成性上，模板四的困惑度为 1.4934，表明其生成文本较为通顺自然，而且模板四的错误率仅为 0.0800，在四种模板中最低，这也说明了在不同场景下模板四有更强的鲁棒性和泛化能力。因此模板四成为进一步评估的理想选择。

中国知网　https://www.cnki.net

表 3.4 不同模板对比结果

Table 3.4 Comparison results of different templates

模板	准确度	困惑度	错误率
模板一	0.5200	1.7507	0.4800
模板二	0.6000	2.0544	0.4000
模板三	0.8400	1.8463	0.1600
模板四	0.9200	1.4934	0.0800

在针对 LLM 的性能检测中，本文选取准确率、召回率、精确率、*F*1 分数来评估 LLM 任务，使用模板四进行检测任务。通过对 LLM 检测任务的指标计算得到的结果可以发现，GPT-4o 在歧义检测任务上有较好效果，在准确率、召回率、精确率以及 *F*1 分数等方面均获得较高分数如表 3.5 所示，表明其对歧义样本识别以及分析有较高准确性。基于上述原因，本文采用 GPT-4o 对需求歧义检测进行进一步研究。

表 3.5 任务指标结果

Table 3.5 Task target results

大语言模型检测任务指标						
指标	GPT-3.5	GPT-4	GPT-4o	文心一言	通义千问	百川
准确率	0.8000	0.8400	0.9200	0.7391	0.8261	0.6522
召回率	0.7857	0.8571	0.9286	0.6875	0.8125	0.8750
精确率	0.8462	0.8571	0.9286	0.9167	0.9286	0.7000
*F*1分数	0.8148	0.8571	0.9286	0.7857	0.8667	0.7778

总结：通过对多个主流大语言模型的横向比较，ChatGPT（GPT-4o）在准确率、召回率、精确率、*F*1 分数等各项指标上均表现最优，整体检测效果显著优于其他模型，具备在需求歧义检测任务中实际应用的能力基础。这一结论解答了 LLM 能否胜任歧义检测这一前提性问题，同时也为后续研究确立了模型选型依据，以 GPT-4o 作为核心模型，进一步探索如何通过模板与流程设计优化其检测能力。

中国知网 https://www.cnki.net

3.2.2　问题 2：歧义检测模板和流程设计

根据对问题 1 的研究可知，在歧义检测中模板四表现出了更高的准确度、生成性和鲁棒性，因此选取模板四作为最优方案。从而得出基于 GPT 检测与修复需求歧义的流程规范，如图 3.2 所示。为进一步验证上述模板与流程在实际使用中的有效性与可行性，仅凭实验性能指标尚不足以全面评估用户在真实操作场景下的使用体验，因此本文引入问卷调查作为补充验证手段。根据需要设计一份问卷如表 3.6 所示，确保问题涵盖模板和流程的易用性、准确性、实用性和用户对于模板与流程的意见或建议等。向相关受众人群发送问卷，共邀请 100 个已经使用过基于 ChatGPT 的歧义检测模板与流程的用户进行填写问卷，通过这种方式从用户视角对流程与模板的有效性进行验证。

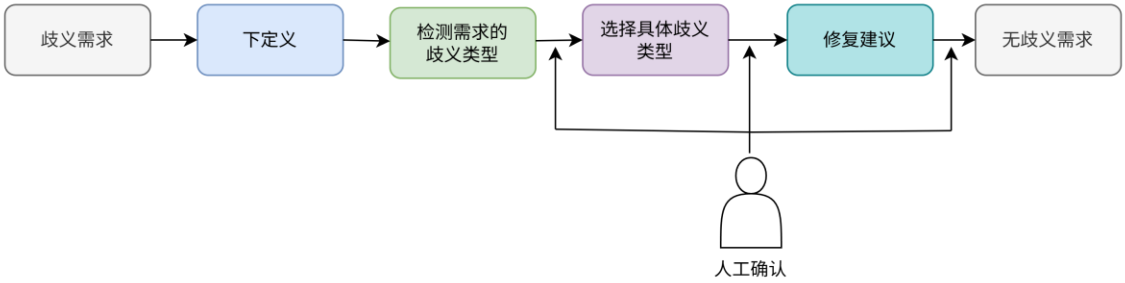


图 3.2 流程规范图

Fig. 3.2 Process flow chart

本次问卷调查的目的是通过对基于 ChatGPT 歧义检测模板及流程进行问卷调研，了解用户对于此模板以及流程的体验和反馈等，进而检验并优化这一方案的可行性及其效果。

根据问卷调查结果，总结了对文本所提出的需求歧义检测与修复流程的用户体验及建议、性能表现等。调研包括用户整体体验和各项具体功能表现两大部分，如图 3.3 所示，根据参与者的整体体验与满意度来看，大部分参与者认为该系统良好，使用体验表示较高满意度。对于易用性与性能感知方面，有 60 份认为系统“非常易用”，即用户界面友好且易操作。在性能上，对于响应速度的满意度最高，共有 80 份认为其“非常快”。而对于准确性和可靠性，大部分用户都认为准确性很好，同时流程是可靠的，但是也有少数用户认为在某些专业术语的理解上存在问题。

中国知网　https://www.cnki.net

表 3.6 问卷调查

Table 3.6 Questionnaire survey

问卷	介绍
问卷对象	使用过基于 ChatGPT 的歧义检测模板和流程的用户
目的	收集用户对基于 ChatGPT 的歧义检测模板和流程的体验和反馈，评估使用情况以及用户体验分析
问卷的角度	从用户体验以及性能评估的角度，了解用户对基于 ChatGPT 歧义检测模板的接受度、满意度、易用性、准确性、响应速度、可靠性和实用性等方面的意见和建议
问卷问题	1.请评价您使用基于 ChatGPT 的歧义检测模板和流程的整体体验如何？（1-非常不满意，5-非常满意） 2.您认为基于 ChatGPT 的歧义检测流程在操作简便性和易理解性上如何？ 3.您认为基于 ChatGPT 的歧义检测模板和流程的检测准确率如何？ 4.您觉得基于 ChatGPT 的歧义检测模板和流程的响应速度如何？ 5.您是否遇到过基于 ChatGPT 的歧义检测模板和流程无法识别或误判的情况？ 6.如果您回答了上一题为是，请问您遇到的无法识别或误判的情况具体是什么？ 7.在使用过程中，您是否感到提供的帮助信息充分解决了您的疑问？ 8.您对基于 ChatGPT 的歧义检测模板和流程的整体性能是否满意？ 9.在日常工作中，您认为该流程的可靠性如何？ 10.您是否愿意继续使用基于 ChatGPT 的歧义检测模板和流程？ 11.如果您回答了上一题为否，请问您不愿意继续使用的原因是什么？[多选题] 12.您对基于 ChatGPT 的歧义检测模板和流程有任何其他建议或意见吗？ 13.感谢您参与本次调查，请问您还有其他想补充的内容吗？

对于流程性能及准确性进行分析如表 3.7 所示，在性能指标评估中，检测准确率为 4.3 分，而响应时间为 4.8 分，说明系统具有良好的响应速度，但是准确率有待提高。虽然总体来看，用户对系统的评价较好，但是准确率偏低也说明有必要进一步改善模型识别效果。对于误判及未识别情况，有 30 人表示曾出现识别问题，虽然多数用户未遇到识别困难，但是对于存在问题的部分人群，在某些情况下提高其识别水平仍是有必要的。而在对误判原因分析中，有 20 份问卷反馈误判主要

中国知网 https://www.cnki.net

集中在特定专业术语的理解上，还有 10 份问卷认为是由于对上下文理解错误造成的。所以未来工作应更加注重该领域相关知识集成以及提升模型对复杂语境下的理解能力。而对于系统的可靠性方面，大多数人都表示满意，有 60 份问卷都给出了“非常可靠”，这反映了大多数人对于系统的稳定性表示肯定的态度。但是也有 40 份问卷选择了“可靠”，这也说明一部分人对于系统的稳定性有一定要求，所以在不断改进性能的基础上还要注重提高系统的稳定性并降低误报率。

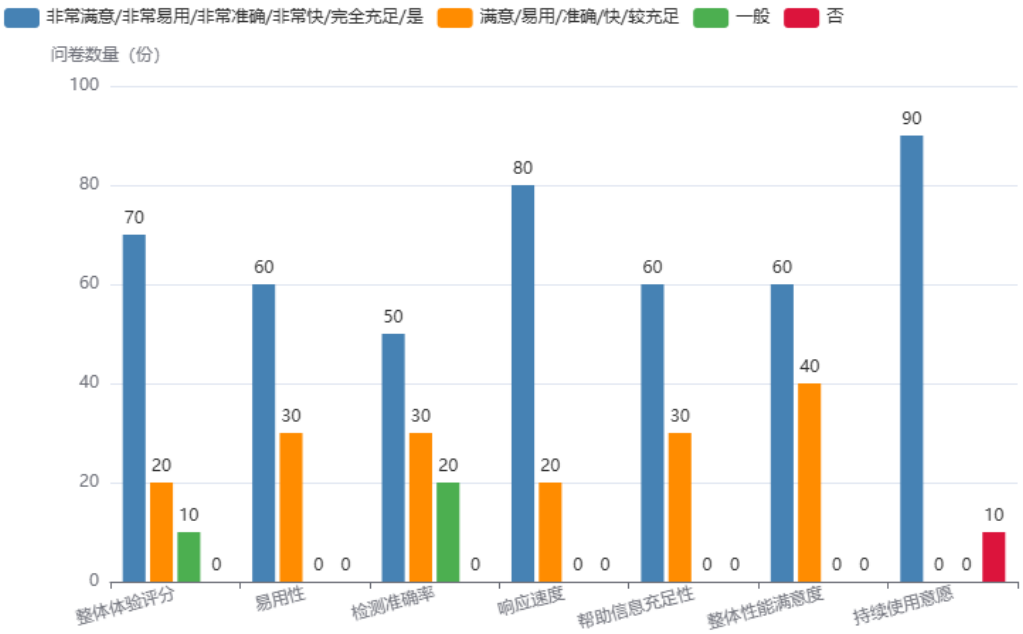


图 3.3 用户体验与满意度

Fig. 3.3 User experience and satisfaction

根据用户的反馈以及提出的建议如表 3.8 所示，少量用户存在不能被正确识别或者误判的问题，主要集中在对某些专业术语的理解错误及对上下文理解有误差，说明系统对于一些特殊场景及复杂的背景情况还需要进一步完善。大部分用户表示愿意继续使用本系统，说明系统具有一定的用户粘性，但也有 10 个用户表示不再使用，说明在部分方面，用户的体验并不满意。相应地提出增加专业知识库来使模型更好地理解专业的环境，从而提高对于各种情况下的准确率，添加更多的个性化选项来满足不同的用户需要，并且用户希望可以得到更加详细的使用说明以及加快系统的更新频率以便及时地跟上新的需求和发展。

调查问卷中问题 1-4、6-8、10 是针对用户对于模板以及流程的使用感受和评

中国知网　https://www.cnki.net

价，调查问卷中问题 3-6、9 是针对模板以及流程的功能性和准确性，调查问卷中问题 11-13 是用户的建议以及反馈。通过对调研结果进行汇总并得出结论，在一定程度上说明基于 ChatGPT 的歧义检测模板及流程的设计具有可行性。

表 3.7 流程性能与准确性

Table 3.7 Process performance and accuracy

问题	用户反馈	问卷数量	原因分析
问题 3 和 4 的平均分	检测准确率平均 4.3 分，响应速度平均 4.8 分	100 份	性能表现良好，但准确率较响应速度略显不足
问题 5（无法识别或误判情况）	遇到过（是）	30 份	少数用户遇到了识别问题
	未遇到（否）	70 份	
问题 6（具体误判情况）	误判集中在特定专业术语理解	20 份	需要针对特定领域和复杂上下文进行优化
	上下文理解偏差	10 份	
问题 9（可靠性评价）	非常可靠（5 分）	60 份	用户普遍认为流程可靠，但小部分用户期待更高稳定性
	可靠（4 分）	40 份	

表 3.8 用户反馈与改进建议

Table 3.8 User feedback and improvement suggestions

问题	用户反馈	问卷数量	原因分析
问题 11（不愿意继续使用的原因）	检测准确率低	10 份	存在上下文理解偏差
问题 12（改进建议）	增加专业领域知识库	30 份	用户期待更多定制化和专业领域支持
	提高特定情境下的准确性	20 份	
	引入用户自定义设置	20 份	
问题 13（额外反馈）	用户反馈中提到希望有更详细的使用教程	10 份	需要针对特定领域和复杂上下文进行优化
	希望能更快地更新迭代，适应新需求	10 份	

中国知网 https://www.cnki.net

总结：歧义检测模板的设计需涵盖歧义定义输入、歧义类型检测、候选类型选择及修复建议生成等关键步骤，以模板四为代表的完整流程在准确度、生成性与鲁棒性上均表现最优。问卷调查结果从用户视角进一步验证了该模板与流程的可行性，但也揭示了模型在专业术语理解和复杂上下文处理方面存在的局限。这表明，仅依靠提示词模板与单一 LLM 的方式，难以应对需求歧义检测中的复杂场景，有必要在此基础上设计更具系统性的方法，以弥补单一模板调用的不足。

3.2.3　问题 3：检测方法性能对比

Veizaga 等人[26]的方法不仅能够自动检测需求，而且首次提出一种基于 Rimay 控制自然语言的模式，在发现错误的同时给出具体的建议而不是仅仅指出存在的问题。相比之下虽然 Zakeri-Nasrabadi 等人[69]提出了数学模型来评估和排名需求的可测试性，Habib 等人[70]利用深度学习提升了检测精度，但二者都没有涉及自动化改进建议的内容，这是 Paska 工具的优势。因此，在调查目前用于需求歧义检测的技术和方法当中，选取 Paska 作为最先进的技术来进行讨论。为了全面评估其性能，用同样的数据集将 Paska 与基于大语言模型的方法进行对比，从准确性、效率等方面进行比较。通过对结果的分析，本文可以评估基于 ChatGPT 的歧义检测方法相对于最先进方法的性能优劣以及这套方法的实际效果，从而进一步完善基于 ChatGPT 的需求歧义检测方法，使其更加高效实用。

GPT-4o 与 Paska 结果比较如表 3.9 所示。从准确率、召回率、精确率及 *F*1 分数进行比较可以看出二者在识别 SRS 质量问题上的性能差异。其中 Paska 具有较高的精确度，在正确识别需求歧义方面表现出色并且能够给出 Rimay 模式帮助改善，说明 Paska 对于降低误报和漏报有很好的效果同时也可以提高检测准确性和效率。

表 3.9 对比实验结果

Table 3.9 Compare experimental results

指标	GPT-4o	Paska
准确率	0.9200	0.8800
召回率	0.9286	0.8571
精确率	0.9286	0.9231
*F*1 分数	0.9286	0.8889

中国知网　https://www.cnki.net

总结：对比实验结果表明，基于 GPT-4o 的歧义检测方法在准确率、召回率及 $F1$ 分数上均优于当前最先进方法 Paska，尤其在歧义类型覆盖面与检测精度方面具有明显优势。这一结果证明了将 LLM 引入需求歧义检测领域具有切实的研究价值与实践潜力。然而，也应注意到，当前基于单一 LLM 调用的方式在多阶段推理、长上下文理解以及修复结果验证等环节仍存在明显局限，这些局限性指向了构建更系统化检测与修复方法的必要性。

3.2.4 结果启示

通过对上述三个问题的系统研究，本章从实证角度完整回答了 LLM 应用于需求歧义检测与修复的核心问题，并从中获得以下关键发现。

（1）LLM 具备需求歧义检测的能力基础，但模型选择与提示词设计对效果影响显著。问题 1 的实验结果表明，GPT-4o 在多项检测指标上均达到较高水平，验证了 LLM 处理需求歧义任务的可行性。与此同时，不同提示词模板之间的性能差异明显，说明 LLM 的检测效果高度依赖于输入结构的合理性，若调用方式缺乏规范性，则难以保障其检测性能的稳定性。

（2）结构化的检测模板与流程是充分发挥 LLM 能力的关键。问题 2 的研究表明，在提示词中引入歧义定义、分类候选项与修复建议等结构化要素，能够显著提升检测的准确性与一致性。这说明，有效利用 LLM 处理需求歧义问题，关键在于构建一套规范化的操作框架，而非仅依赖模型的开放式生成能力。

（3）LLM 方法相较于现有最优方法具有竞争优势，但单一调用模式存在系统性局限。问题 3 的对比结果表明，基于 LLM 的方法在整体性能上优于当前最先进方法，具备替代或超越传统方法的潜力。然而，经验研究同时揭示了单一 LLM 在复杂推理链路中的瓶颈，即在多阶段检测与修复任务中，模型容易出现局部歧义捕捉不全、上下文理解偏差以及修复结果缺乏验证等问题，这些问题依靠提示词优化难以根本解决。

上述发现表明，LLM 在需求歧义检测领域具有显著潜力，但要将这种潜力转化为稳定、可靠、可扩展的工程方法，仅凭单一模型的直接调用是不够的。有必要在经验研究结论的基础上，面向检测与修复两个核心任务，分别构建系统性的方法体系。

3.2.5 有效性影响因素分析

（1）内部有效性

中国知网 https://www.cnki.net

本研究的内部有效性威胁主要体现在以下三个方面。其一，LLM 在多阶段推理中的局部捕捉局限。本文利用 LLM 与人工判断相结合的方式对需求歧义进行分类和分析。尽管 LLM 有良好的自然语言理解能力，但在进行检测、分类、修复等多阶段推理过程中，可能仅捕获到局部歧义而遗漏深层的结构性歧义，进而对模型的实际检测能力产生一定程度的评估偏差。针对这一威胁，本文在每一轮筛查过程中均安排至少两名具有多年需求分析经验的专家对模型输出结果进行人工复核，以弥补模型判断的不足。其二，人工标注的一致性问题。由于参与标注的专家在经验背景与专业知识上存在差异，对同一歧义类别的判断可能出现分歧，导致标注一致性有所波动，进而影响实验结果的可靠性。为此，本文采用多轮迭代的交叉验证方式处理标注结果，通过反复比对与协商统一标注标准，以保证分类的一致性。未来工作可通过引入更多领域专家或采用群体决策机制进一步提升标注质量。其三，LLM 幻觉问题。LLM 在生成输出时可能产生与事实不符的内容，这种幻觉现象在歧义判断中可能表现为对不存在歧义的需求给出错误的分类结论，从而干扰实验结果的准确性。本文通过人工专家复核机制对模型输出进行二次校验，在一定程度上降低了幻觉问题对实验结论的影响。

（2）外部有效性

本研究的外部有效性威胁主要体现在以下两个方面。其一，数据集的代表性局限。尽管本研究所使用数据集已经包含多种歧义类型，但是并不能代表所有软件开发情况面临的复杂且多样的歧义类型，研究结论的适用范围存在一定边界。未来工作可通过扩大数据集规模、纳入更多行业领域的真实需求数据，以提升方法的泛化能力。其二，需求描述标准的不一致性。不同从业者乃至不同项目在需求描述方式与执行标准上存在显著差异，本研究在当前标准下得出的结论，不一定能够直接适用于不同领域或采用不同描述规范的应用场景。针对这一局限，未来工作可对模型进行特定领域的适配训练，使其能够识别和处理不同规范下的需求歧义，从而提升研究结论的外部有效性。

3.3　本章小结

本章以经验研究为手段，针对 LLM 应用于需求歧义检测与修复这一尚待充分探索的问题，围绕三个研究问题展开系统调研。通过具体的案例研究与实证分析成功展示了 LLM 在需求歧义检测与修复中的应用价值。研究结果表明，GPT-4o 在需求歧义检测任务中表现最优，具备可行的应用基础；结构化的检测模板与流

中国知网　https://www.cnki.net

程能够显著提升 LLM 的检测效果，其中模板四在准确度、生成性与鲁棒性上综合表现最佳；基于 LLM 的检测方法在与当前最先进方法的对比中展现出明显的性能优势。然而，经验研究同时揭示了单一 LLM 在需求歧义处理中的系统性局限。在多阶段推理、复杂上下文理解以及修复结果验证等环节，单次模型调用的方式难以保证检测与修复的完整性和可靠性。

基于上述经验研究结论，本文后续章节将分别面向需求歧义检测与修复两项核心任务，提出系统性的方法体系，以解决单一 LLM 调用模式下暴露出的核心问题，实现需求歧义处理能力的全面提升。

中国知网 https://www.cnki.net

第 4 章　基于大语言模型的需求歧义检测方法

前述经验研究（第 3 章）表明，单一 LLM 难以处理多阶段复杂推理任务，且其对于需求之间的语义一致性分析能力有限。因此，本章提出 LMAdetect，通过“规则预筛选+专家智能体验证”的混合架构解决此问题。区别于单纯依赖规则或单一 LLM 的现有方法，本章设计的混合架构兼顾检测效率与语义深度，具体包括引入类型专业化多智能体协作框架，通过门控路由与 D-S 证据理论融合多专家输出，解决了多类型歧义并行检测的决策冲突问题；在已有规则基础上新增语用歧义和语言错误歧义的检测规则，并引入优先级排序机制，扩展了规则方法的覆盖范围。

4.1　方法框架

图 4.1 是需求歧义检测过程图，在需求文本中逐句读取需求，将原始信息转换成结构化的特征，经过预处理之后开始执行初步检测，先通过门控筛选歧义需求，若检测出无歧义则输出无歧义，若检测出有歧义则触发分类执行，各歧义专家结合大语言模型协同检测具体歧义类型，汇总所有专家意见以及综合置信度，在此基础上根据评估指标进行结果评估，输出无歧义结果或者歧义类型、置信度及消歧建议。主要部分是检测模块，在需求歧义检测基础上提出了将大语言模型和多智能体协作以及启发式规则结合的需求歧义检测方法 LMAdetect。如图 4.2 所示为 LMAdetect 多智能体协作框架图，LMAdetect 的工作分为三个步骤：（1）启发式规则初步筛选出可能的歧义需求；（2）用结构化提示让大语言模型进行歧义分类；（3）使用多个智能体之间相互协作并进行证据融合得到可靠的检测结果。

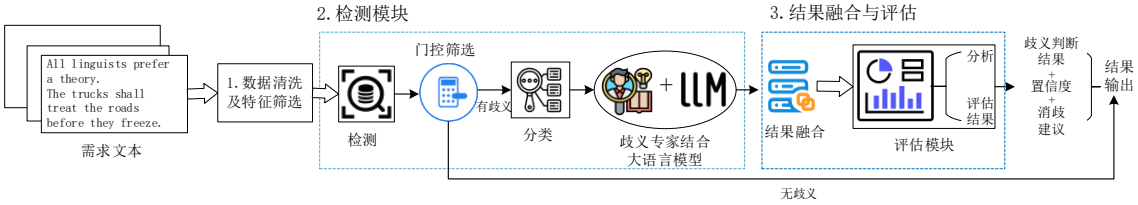


图 4.1 需求歧义检测过程图

Fig. 4.1 Requirements ambiguity detection process diagram

LMAdetect 框架的多智能体协作通过优化后的工作流实现高效检测。与图 4.1 的流程框架相比，图 4.2 侧重于技术层面的支撑机制，展示了基于多智能体协作的

中国知网　https://www.cnki.net

技术架构。具体而言，图 4.1 中“数据清洗及特征筛选”对应图 4.2 的感知层，对输入数据进行一系列解析、意图识别以及关联分析将需求转换成对应特征结构；图 4.1 中“检测模块”对应图 4.2 的元认知层，由任务分配、指引、执行监督以及策略集成等部分组成不同种类的专家智能体进行具体的检测任务；图 4.1 中“结果融合与评估”对应图 4.2 的评估优化，采用证据融合以及评价标准给出最终结果。接下来将分别介绍各个环节的实现。

任务调度模块启动工作流，利用门控智能体进行第一层筛选；指导策略模块根据输入生成相应的优化建议来引导后续专家的选择；执行监控模块关注歧义专家等智能体的行为并保存它们之间的交互以及其中间置信度；策略融合模块利用融合智能体汇总所有结果，然后用 Dempster-Shafer（D-S）证据理论得出最终结果；评估优化模块检查输出是否合理并且给出优化建议从而形成一个闭环。记忆模块分为短期记忆和长期记忆，存储多智能体协作中关键信息，以免重要分析过程中遗漏掉这些过程分析，确保分析的正确性和逻辑严密性。

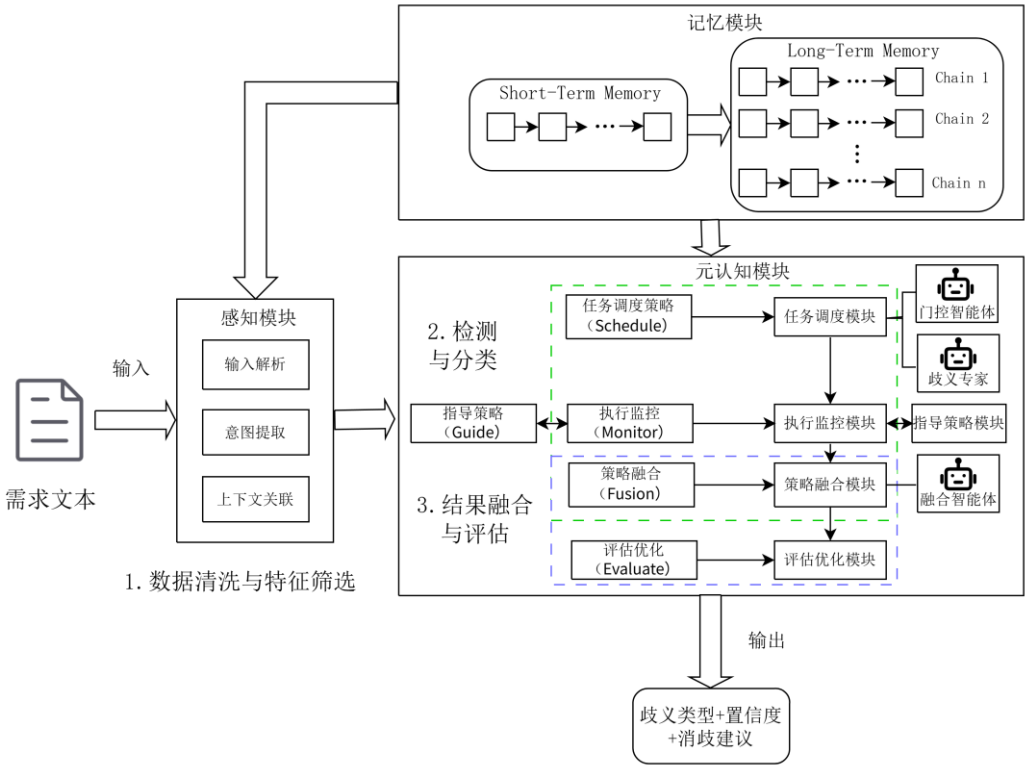


图 4.2 多智能体应用协作技术框架图

Fig. 4.2 Multi-agent application collaboration technology framework diagram

中国知网 https://www.cnki.net

4.2　基于启发式规则的初步筛选

通过对需求歧义检测方法的广泛调研，本文整理出自然语言需求文本中常见的 6 种歧义类型，分别为词汇歧义、句法歧义、语义歧义、语用歧义、语法歧义和语言错误歧义[3,22]。以上歧义类型代表了不同的问题，在自然语言中存在歧义词、多种句法结构、不确定范围、语境理解不当、语法问题或者拼写错误等多种歧义情况。为了解决这些问题，LMAdetect 通过一系列启发式规则对需求文本进行清洗以及获取潜在的歧义需求，然后得到一个结构化的特征集为后续的 LLM 使用。

在歧义检测的调研中，本文发现提取模糊词汇和提取指代不明语句是根据语言语义进行分析的，提取被动语态结构是根据句法信息进行分析的，提取重复表述是根据文本模式进行分析的。本文针对这 4 类情形设计了相应的启发式规则，以实现更加精确的歧义检测。根据四个维度，利用 NLTK、Benepar、FastCoref 以及 WordNet，构造包含六个歧义类型的特征集合，在共指消解及句法分析的基础上，LMAdetect 在词汇层面上以及句子层面都明显优于传统的方法，提高了对语义理解以及指代识别的能力。

4.2.1　歧义类型的检测规则

为了处理更多歧义情况，提升歧义识别率，在此基础上增加一些启发式规则并适当扩充已有工作。Gleich 等人[20]提出一种基于规则的方法主要用于解决词汇和句法歧义问题，如用正则表达式进行关键词和部分词性进行匹配以发现模糊术语及其句法结构等，但该规则只能匹配固定模式，而不能考虑语义相关性和上下文复杂性。Sabriye 等人[21]提出一种基于 POS 标注的方法虽然可以通过词性标签检测语法和句法歧义，但是仅限于局部特征，而忽略全局语义以及语用相关的信息。LMAdetect 在此基础上加入了一些规则和知识，以原有的词典词匹配为基础，增加对量化词的语义范围分析规则并结合句子长度及修饰词的一致性判断，如果出现量化词但又没有具体边界并且句子长度小于 30 个单词，则启动歧义检测规则保证其具有独立性，其中 30 是根据实验数据集统计结果以及经验确定，而在 1192 条需求中，需求描述平均长度约为 25 个词，选择 30 作为阈值可有效避免过长上下文干扰语义独立性，同时覆盖大多数潜在歧义场景，该选取参考需求工程中对简明需求描述的要求，如 Gleich 等人[20]对需求表达形式的研究。针对 Sabriye 等人[21]方法存在的问题，在此基础上加入共指消解以及结合上下文关联的规则，可以发现由于缺乏上下文而导致的歧义。检测条件是代词或者指示词前后没有建立清晰

中国知网　https://www.cnki.net

的关系并且使用部分引用实体出现次数小于 2 次的情况，从而识别上下文的相关性。此外，本文扩展了传统规则的语法检查，增加了自动识别拼写错误以及语法不一致的功能，采用 WordNet 进行词典查询以及语法树解析，若需求语句中的错误词孤立存在，且没有修正上下文的条件时进行检测。而且，本文新引入了基于文本相似度阈值的优先级排序机制，把高频重复的表述暂定为潜在歧义，采用优先级排序机制优化检测的优先级。上述本文对现有方法进行的扩展融入了语义角色标注、共指消解等 NLP 技术，并借助大语言模型理解上下文的能力[71]，填补传统规则所受的限制。针对每种歧义类型的启发式规则设计用于识别特定的语言模式，并在表 4.1 中总结了这些规则及其定义、检测条件和示例。

表 4.1 歧义类型和检测规则

Table 4.1 Ambiguity type and detection rules

歧义类型	检测条件	示例
词汇歧义	1.术语未在词汇表或上下文中定义 2.单个主谓结构，无明确修饰语 3.Word 存在于多义词词典中，具有多种含义	“The system shall respond quickly.” （“quickly”不明确）
句法歧义	1.分析出的句法树数量超过 1 2.名词短语修饰语的数量超过 1 3.修饰语之间缺乏明确的优先级或关系一致性	“The old men and women ate lunch.” （分组不明确）
语义歧义	1.术语范围存在多种可能的解释 2.并列结构中分组不一致大于 1 3.缺乏明确意图或上下文解析	“All files in the system are secure.” （“all”的范围不明确）
语用歧义	1.可能的解释数量超过 1 2.与上下文无明确匹配意图 3.句子长度小于等于 50 词，以避免过于复杂	“The system will notify users.” （通知方式不明确）
语法歧义	1.生成的语法树存在超过一种可能的结构 2.Word 词性标签显示潜在的语法错误 3.句子长度不超过 40 词	“The data process daily.” （“process”中的语法错误）
语言错误歧义	1.Word 未在词典中找到或词性不匹配 2. 连续词语之间缺乏明确的连接成分 3. 句子长度小于等于 30 词	“The sistem is fast.” （“system”拼写错误）

中国知网 https://www.cnki.net

在规则设计中，本文将需求文本的分析维度归纳为四类提取操作，各操作与歧义类型的对应关系如下。模糊词汇提取主要服务于词汇歧义和语义歧义的检测；指代不明语句提取主要服务于语用歧义的检测；被动语态结构提取主要服务于语法歧义的检测；重复表述提取则辅助识别句法歧义及潜在的词汇歧义。四类提取操作的具体检测条件如下。

针对模糊词汇的提取，LMAdetect 将枚举需求语句中的常见模糊词，对于每一个模糊词，满足以下条件则加入候选项：（1）需求语句长度不超过 30 词；（2）模糊词在上下文中未被明确定义；（3）句子最多包含 1 个主谓结构且无歧义修饰语。上述条件从长度限制和语义独立性两个维度确保候选项的有效性，避免因上下文已作澄清而造成误判。

针对指代不明语句的提取，LMAdetect 将枚举需求语句中的代词和指示词，将其划分为指代部分和使用部分，满足以下条件则加入候选项：（1）指代部分与使用部分之间无明确语义连接；（2）该部分的词数不超过需求示例总词数的 70%；（3）指代部分后续语句中未使用相关实体且无歧义解；（4）使用部分引用的实体在后续语句中出现次数不超过 1 次。

针对被动语态结构的提取，LMAdetect 直接根据句法模式识别包含被动语态的句子结构，满足以下条件则加入候选项：（1）句子包含被动语态动词；（2）主语或施动者未被明确指定；（3）句子词数不超过 40 词。

针对重复表述的提取，LMAdetect 通过文本相似度对需求语句进行比较，对相似度超过阈值 0.8 的语句对进行分析，若两个语句仅在具体实体上存在差异且可形成映射关系，则视为重复表述并加入候选项。若多个候选项重复标记同一语句，则在后续优先级排序中累计计入推荐次数。

对于每一个候选项，若标记无冲突，则将其作为候选项。若多个候选项重复标记某一句子，则视为同一条目，并在优先级排序中累计权重。

4.2.2　预处理算法

表 4.2 概述了自然语言需求的预处理流程，目标为生成用于歧义检测的特征集 F。预处理阶段把原始需求文本转换成结构化特征集，以支持启发式规则的应用。此流程涉及分段、分词、词性标注、句法分析、共指消解以及语法检查等步骤。

（1）分词：将文本拆分为单词和短语。

（2）词性标注：使用如 NLTK 这样的工具，为词语分配语法标签。

中国知网　https://www.cnki.net

（3）句法分析：利用如 Benepar 解析器生成句法树，以识别结构上的歧义。

（4）共指消解：通过 FastCoref 等工具识别代词引用，解决指称歧义问题。

（5）词典查询：通过 WordNet 等资源检查单词的有效性和多义性，以解决词汇和语言错误的歧义。

（6）上下文分析：评估句子长度和修饰语的一致性，识别语义和语用歧义。

这种预处理确保了输入需求被转换成结构化的表示，从而能够对候选的歧义需求进行基于规则的有效过滤。

表 4.2 预处理算法

Table 4.2 Preprocessing algorithm

算法 1.自然语言需求预处理
输入:NL requirement(r);
输出:feature set(F).
1. $SEG \leftarrow SEPARATESEGMENTS(r)$;
2. $F \leftarrow \varnothing$;
3.for each $seg \in SEG$ do
4. $W \leftarrow TOKENIZE(seg)$;
5. $T \leftarrow POS_TAGGING(W)$;
6. $P \leftarrow PARSE_TREE(seg)$;
7. $CR \leftarrow COREFERENCE_RESOLUTION(seg)$;
8. $GE \leftarrow GRAMMAR_ERROR_CHECK(seg)$;
9. $F \leftarrow F \cup \{W, T, P, CR, GE, has_period(seg), is_passive(seg)\}$;
10.return F

4.3 基于大语言模型的歧义分类

LLM 擅长阅读和理解自然语言，通过 LLM 理解，捕捉词汇上下文和句子上下文，增强语义理解和逻辑关系识别能力。为此，本文借鉴 Liu 等人[72]的工作进行了提示工程，设计了由以下维度组成的提示模板如表 4.3 所示，其完整提示词示例如表 4.4 所示。规范化提示词模板由智能体角色和方法、歧义类型、检测过程、输出规范、示例输出这 5 个部分组成。

本文在提示中指定了一些约束条件来引导大语言模型进行检测。在提示词中，

中国知网 https://www.cnki.net

本文会明确任务，大语言模型直接进行整体歧义检测（判断需求语句是否存在歧义）、基于词汇进行歧义检测（识别多义词、模糊词）、基于短语进行歧义检测（识别歧义短语结构）。其次，告诉大语言模型具体的检测流程，明确规定输出格式，以减少小片段或无效片段带来的干扰。最后，要求按照示例进行标准输出。

根据表 4.3 所示，提示词引导大语言模型专注于歧义检测，并减少无关的处理过程，确保输出达到标准化。使用算法 1 对检测的需求集 F 进行操作，每一个需求会被划分到某个具体的歧义类型或是被标记无歧义。为了解决因为对语义理解或指代识别不足而导致的问题，模型会通过提示工程去考察句子间的关系。

表 4.3 提示词

Table 4.3 Prompt words

相关要素	提示词
智能体角色与方法	你是 RSDetector，一个负责检测和分类需求语句中歧义的智能体，使用<语言理解或具体方法>
歧义类型列表	基于以下歧义类型、定义和示例分析输入句子： 1.<歧义类型 1>：<定义> - 示例：<示例句子>（<歧义解释>） 2.<歧义类型 2>：<定义> - 示例：<示例句子>（<歧义解释>） ……
检测过程	1.<步骤 1：分析句子> 2.<步骤 2：类型特定检测> 3.<步骤 3：优先级排序或类型区分> 4.<步骤 4：分类歧义> 5.如未检测到歧义，输出“无歧义”
输出格式	- 如果无歧义：“无歧义” - 如果有歧义：“检测到歧义：[类型]”，其中[类型]为预定义类型之一
示例输出	- 输入：“<示例输入 1>” → “<示例输出 1>” - 输入：“<示例输入 2>” → “<示例输出 2>”

中国知网　https://www.cnki.net

表 4.4 完整提示词示例

Table 4.4 Complete prompt example

完整提示词示例
你是 RSDetector，一个负责检测和分类需求语句中歧义的智能体，使用语言理解方法。请基于以下歧义类型、定义和示例分析输入句子： 1.词汇歧义：词语在上下文中允许多种含义 示例：“The bank can be slippery when wet.”（“bank”可指金融机构或河岸） 2.句法歧义：句子结构允许多种解析 示例：“The old men and women ate lunch.”（分组不明：是“old (men and women)”还是“(old men) and women”） …… 检测过程： 1.分析句子结构 2.针对每种歧义类型进行特定检测 3.若同时命中多种类型，按优先级排序。 4.歧义分类 5.如果无歧义则输出“无歧义” 输出格式： - 无歧义：“无歧义” - 有歧义：“检测到歧义：[歧义类型]” 示例输出： 输入：“The trucks shall treat the roads before they freeze.” → “检测到歧义：语用歧义” 输入：“The system shall log all user actions.” → “无歧义”

4.4 基于智能体对大语言模型歧义检测结果合并

智能体可以感知环境、自主做出决定并且采取行动达到某个目的，一般包括感知模块、决策模块、执行模块以及记忆模块等。大语言模型赋予智能体语言交流及思考的能力，智能体利用大语言模型理解用户的命令，把自然语言转化为结构化的意图，给出一个结构化提示词，让大语言模型进行相应推导。

LMAdetect 利用多智能体协作汇总大语言模型结果从而提高歧义检测水平，在

中国知网 https://www.cnki.net

此过程中对不同类型的歧义进行结构优化，如图 4.3 所示，通过启发式规则以及大语言模型相结合的方式对词汇、句法、语义、语用、语法和语言错误等多种类型的歧义检测进行分析和改进，初步的分类结果基于每种类型的语言特征生成。

为了提高检测鲁棒性，LMAdetect 采用了多智能体框架即类型专业化多智能体协同工作方式。该方式将不同类型歧义分给不同智能体负责并利用 D-S 证据理论汇总各个智能体输出。

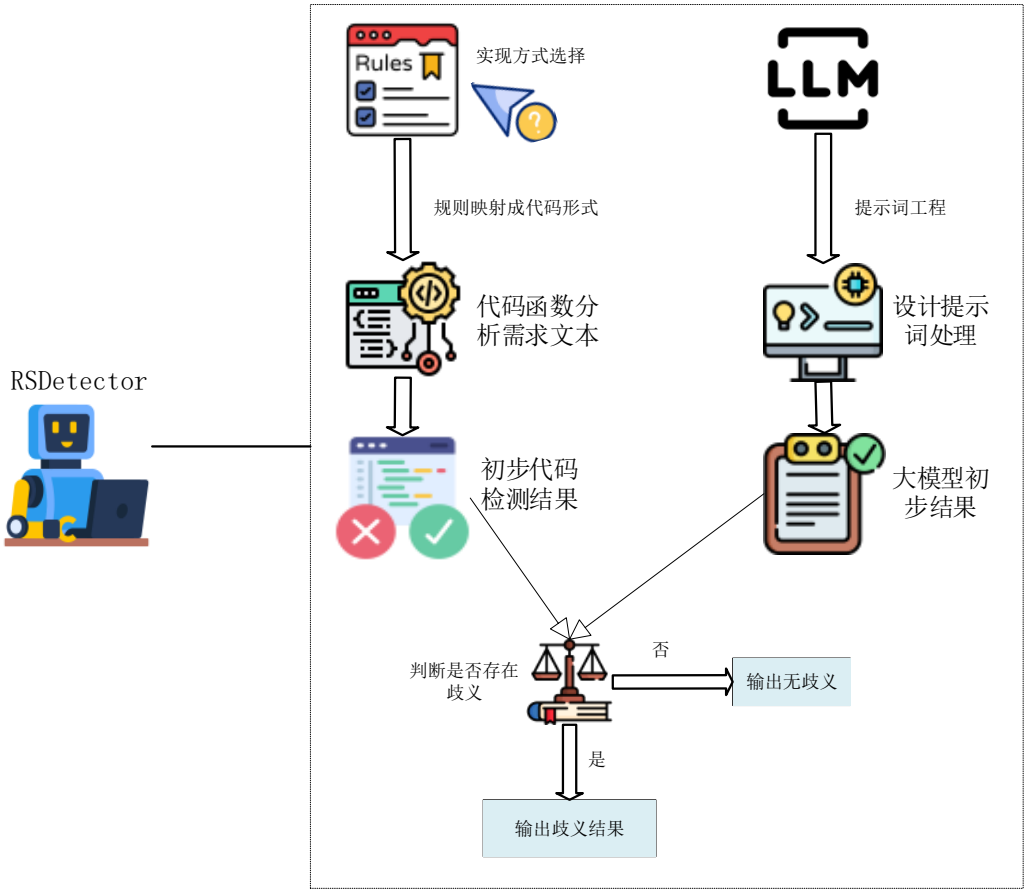


图 4.3 大语言模型与规则结合的方法框架图

Fig. 4.3 Method framework diagram of the combination of large language models and rules

根据如图 4.4 所示，这种基于混合专家带路由的模式，不仅可以实现单一任务的精准检测，还提供了类型协同优化的创新点。在此基础上形成了一个完整的框架。第一层门控智能体进行判断是否存在歧义，第二层门控进行判断具体歧义类型，通过路由进行诊断分配到具体歧义类型专家进行针对性检测，每个任务是一个小专家，整个模式是一个基于混合专家带路由的这种形式。本文采用这种智能

中国知网　https://www.cnki.net

体分步实现歧义类型的检测，每种歧义类型需要不同推理深度，通过任务分解降低单次推理复杂度，确保效率和稳定性。类型专业化多智能体协作框架，核心是按歧义类型给智能体精准分工。让智能体的分工更精准专业，每个智能体当领域专家。通过多智能体分工和内存模块，动态解析句子间的逻辑关系和指代对象，通过专业智能体和大语言模型推理，增强逻辑关系识别和指代识别，通过层次化协作和上下文记忆，提升检测灵活性和覆盖面。

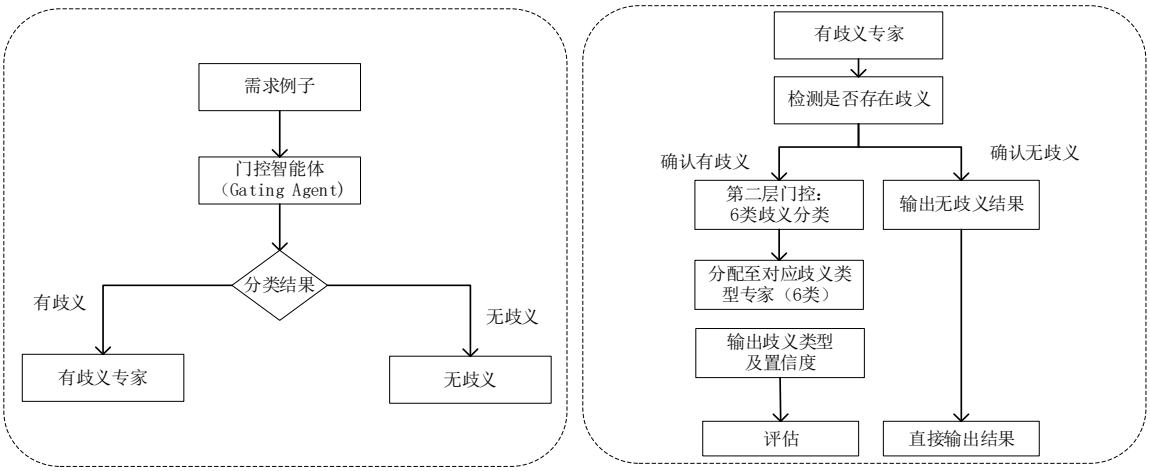


图 4.4 歧义检测引导的混合专家框架图

Fig. 4.4 Mixed expert framework diagram guided by ambiguity detection

该框架依靠 LLM 良好语义理解能力以及记忆模块保存短期、长期上下文信息提高各个智能体之间合作效率。而记忆模块是整个多智能体框架重要组成部分，它可以保存共享上下文促进智能体之间合作，即使在智能体之间不需要频繁进行交互情况下也可以发挥作用，具体使用如下。（1）初始化阶段，在感知模块获取输入需求上下文并存入短期记忆以便进行即时调整；（2）运行期间，智能体可以通过 API 调用查询共享数据；（3）合并阶段，长期记忆为策略融合模块提供历史知识以改进分类效果。而在实际应用中比如处理大规模需求文档的情况下，记忆模块保存跨句引用关系，可以让异步智能体各自开展工作而不是一直保持同步状态，这样可以减少通讯开销。这借鉴多智能体系统中异步内存机制[73–75]，澄清了其在非实时交互环境中的实用性。

中国知网 https://www.cnki.net

表 4.5 歧义检测算法

Table 4.5 Ambiguity detection algorithm

算法 2.检测需求歧义

输入: NL requirement(r), feature set(F),
Agents {GatingAgent, AmbiguousExpert, Experts, FusionAgent};
输出: detected ambiguity result(D).
1. $M \leftarrow \{\text{content}: r, \text{POS_analysis}: F\}$;
2. $D \leftarrow \varnothing$;
3. $O_gating \leftarrow RUN_GATINGAGENT(M)$;// Step 1: GatingAgent Initial Screening
4. $(detected_g, type_g, conf_g, \exp l_g) \leftarrow PARSE_OUTPUT(O_gating)$;
5.if not $detected_g$ and $conf_g \geq 0.9$ then
6. $D \leftarrow$ (False, "None", $conf_g$, $expl_g$);
7. return D ;
8.end if
9. $O_ambiguous \leftarrow RUN_AMBIGUOUSEXPERT(M)$;// Step 2: AmbiguousExpert Verification
10. $(detected_a, types_a, \exp l_a) \leftarrow PARSE_OUTPUT(O_ambiguous)$;
11. $T_top2 \leftarrow SELECT_TOP2_TYPES(types_a)$;
12.if $detected_a$ and $T_top2 \neq \varnothing$ then
13. $E_selected \leftarrow$ {Experts matching T_top2} ;
14.else
15. $E_selected \leftarrow$ all Experts ;
16.end if
17.for each $E_i \in E_selected$ do// Step 3: Expert Analysis
18. $O_i \leftarrow RUN_EXPERT(E_i, M)$;
19. $(detected_i, type_i, conf_i, \exp l_i) \leftarrow PARSE_OUTPUT(O_i)$;
20. $D \leftarrow D \cup \{(detected_i, type_i, conf_i, \exp l_i)\}$;
21.end for
22. $I_fusion \leftarrow$ {GatingAgent: $(detected_g, type_g, conf_g, expl_g)$,
AmbiguousExpert: $(detected_a, types_a, \exp l_a)$, Experts: D} ;// Step 4: FusionAgent Integration
23. $O_fusion \leftarrow RUN_FUSIONAGENT(I_fusion)$;
24. $(detected_f, type_f, conf_f, \exp l_f) \leftarrow PARSE_OUTPUT(O_fusion)$;
25. $D \leftarrow (detected_f, type_f, conf_f, \exp l_f)$;
26.return D

中国知网 https://www.cnki.net

表4.5给出了从初步筛选到最后结果汇总整个歧义检测的过程，在GatingAgent进行初步筛选后，当置信度大于等于 0.9 并且无歧义时就直接返回结果。然后由AmbiguousExpert验证歧义并输出类型列表 *types_a*，对 *types_a* 根据置信度从大到小排序，取其中置信度最高的两个作为后续分配给相应专家智能体的任务，以防止全部激活专家带来大量不必要的计算量以及可能产生的幻觉问题。如果 *types_a* 为空或者置信度较低，则重新激活所有专家，保证覆盖性。最后由FusionAgent汇总结果，得到最终的歧义检测的结果即类型及其置信度。

4.5 实验分析

本节从不同维度对 LMAdetect 进行实验评估。首先针对 LMAdetect 在第 1 章提出的挑战与问题，给出关于该歧义检测方法的 4 个研究问题；随后通过评估歧义检测方法的不同方面来解答这 4 个研究问题。为评估 LMAdetect 的检测效果，本文开展了实验进行评估；最后基于评估结果分析了 LMAdetect 的优势与局限性。

4.5.1 研究问题

为了评估 LMAdetect 是否可以有效解决上述挑战，本节提出下面 4 个问题。

问题 1：数据集的单句需求样本是否在语义、场景和逻辑上完全独立？验证每种歧义类型上数据集是否有独立性，通过对文章中对于数据集介绍梳理以及基于大语言模型对数据集进行相关性分析来说明这些数据集之间的上下文无关性。

问题 2：LMAdetect 在检测单个类型的需求歧义性能方面是否优于现有的需求歧义检测方法？验证LMAdetect在每种歧义类型上的检测性能是否优于基线方法，通过准确率、召回率、精确率、*F*1分数计算证明其在单独类型检测上的有效性。

问题 3：LMAdetect 在检测语用歧义和语言错误歧义上的检测效果如何？验证LMAdetect 如何利用 LLM 以及多个 Agent 进行合作从而在语义理解、逻辑关系识别及指代识别方面提高检测准确率，考察对于上下文理解的效果。

问题 4：在多类歧义检测任务中，不同模型对结果的影响如何？验证不同模型对于不同类别歧义检测的表现，并单独说明通用模型与推理模型在处理相同类型歧义检测任务上的区别。

4.5.2 评价指标及基准方法

本文使用了四个经典指标对 LMAdetect 进行评估，即准确率、召回率、精确率以及 *F*1 分数，在歧义检测研究领域中常用。本文对比每个歧义类型的准确率、

中国知网 https://www.cnki.net

召回率、精确率以及 *F*1 分数。

本文将 LMAdetect 与传统方法如 Gleich 等人[20]的工作、POS 标记[21]及 Paska[26]进行比较。第一种方法是基于 NLP 技术的自动化歧义检测与解释方案，第二种方法是使用词性标注技术检测 SRS 中语法和句法歧义的方案，第三种方法是针对自然语言需求文档的自动化歧义检测与改进推荐方案。

Gleich 等人[20]的工作使用正则表达式以及词性标注来识别歧义，是一种基于词法及轻量级句法的歧义检测工具，可以处理句法以及语义等多种类型的歧义问题。而 LMAdetect 利用 LLM 对语义的理解去发现量词的作用范围以及逻辑连词等，克服了传统的基于词性标注的固定规则的局限性并且反馈与模型重试机制提升了动态上下文感知能力。在检测与评估的过程中多 Agent 协作并通过误分类来进行进一步地对逻辑关系的判断，从而形成一个闭环优化框架，优于以往需要人工定义规则或者仅仅使用词性标注的方法无法理解深层次含义的问题。

POS 标记[21]方法主要用于识别 SRS 文档中存在的语法或句法上的歧义，使用预处理、处理以及后处理三个部分来进行歧义判断。相比于 POS 标记方法，LMAdetect 可以弥补静态标签序列无法表征语义的不足，在此基础上更精准地定位 SRS 中的语法以及句法歧义问题并且加入 LLM 驱动的动态语义理解，以“结构+语义+语境”综合决策，最后形成闭环反馈由多个 Agent 相互合作。这使得对于语义的理解以及对逻辑关系的认识得到加强，弥补了由于 POS 标记受到上下文范围限制、语义信息较少造成的漏检和误判现象的发生，从而使得其检测的效果有较大改善，提高了召回率、准确率以及 *F*1 值。

Paska[26]是一个自动化工具，整合了多种 NLP 技术。根据整个句子的语法关系进行匹配和推荐适当的 Rimay 模式以供分析师重写需求。相比于 Paska，LMAdetect 将静态 Tregex 规则集合大模型驱动的语义理解模块，可以识别介词短语所造成的多义性和其他的句法歧义结构而不仅仅是 Paska 单句结构匹配的方式。

评估实验中，在同一数据集上计算上述指标，比较 LMAdetect 与基线方法的结果从而考察 LMAdetect 对于不同类型歧义的识别能力，衡量方法的有效性以及普适性。

4.5.3　实验方法

本文采用第三章整理的 1192 条需求示例作为实验样本开展需求歧义检测实验。基底 LLM 选择了 deepseek-v3-0324 模型，所有实验都是在配备英特尔酷睿 i9

中国知网　https://www.cnki.net

处理器和 16GB 内存的 Windows11 系统中完成。

采用 agentscope 框架构建智能体，在调用 LLM 的过程中，根据相关工作[76]的经验，温度（temperature）在 LLM 中被用来控制生成文本的随机性。temperature 值越小得到的输出结果越稳定，而值越高 LLM 发散能力越强，在处理复杂任务或需要创造性的情况下表现更佳。综合考虑，选择了一个平衡点 temperature 为 0.5 来调用 deepseek-v3-0324 模型。

为了检验该选择结果的一致性和稳定性，本文在 6 种类型的歧义样本上分别进行了三次独立重复实验。为验证参数引入的随机性，本文额外设置 temperature 为 0（完全确定性模式）进行对比实验，如表 4.6 所示，当 temperature 等于 0.5 时，*F*1 值相比于 temperature 等于 0 时稍有提升。可以看出在一定范围内增加 LLM 的发散性对于需求歧义的识别是有帮助的。对于句法和语法歧义有明显结构的歧义类型，两者结果表现差异不大，因为这两种类型的歧义识别更多依靠规则以及词性标注，受 LLM 本身的影响较小。对于需要考虑上下文的语用和语义歧义，LLM 的发散有利于歧义的准确定位，实验结果显示，0.5 的 temperature 可以保证较高的召回率与 *F*1 分数。总体准确率和精确率在两种温度下变化不大，说明模型本身分类能力强，受随机性影响小。词汇、句法、语法这些结构性歧义主要是基于规则，效果相近；语义、语用、语言错误这些语境型歧义，由于加入了随机性利于语义推断而使得温度取值为 0.5 时的表现较好（ *F*1 提升 0.5 个百分点到 2 个百分点）。总体来看模型对于结构性歧义具有较强的鲁棒性但是对于语境型歧义取值 0.5 的效果更好。但是从稳定性角度出发，参数 0 更适合应用于实际应用中。

对于不同温度参数得到的结果基本一致的情况，在句法歧义的 *F*1 分数方面，两个温度的均值都是 93.57%，因为句法歧义主要是依靠 POS 标注以及一定的规则来进行判断，模型确定性的推理已经达标，随机性不会对语法结构造成影响。而对于不同温度所得到的结果存在差异，在语用歧义的 *F*1 分数方面，参数 0 的平均值为 0.7595 略高于参数 0.5，源于语用歧义依赖上下文指代，temperature 为 0 时的确定性确保一致捕捉逻辑关系，避免随机遗漏；在参数 0.5 的情况下由于其具有一定的随机性，所以在多次的测试过程中可能会忽略边缘上下文，导致轻微召回率下降（temperature 为 0.5 时标准差更高）。而在语言错误歧义中的 *F*1 分数是在参数 0.5 下的较高，因为语言错误需要识别出一些不符合常规的语言现象，在参数 0.5 下由于具有一定的随机性所以有利于发现更多的这些情况；而参数 0 则是更加准确但是覆盖率较低。在词汇歧义的准确率上两者之间差别不大，词汇歧义是基

中国知网 https://www.cnki.net

于词库进行比对的，所以不会受到温度的影响。而总体来看，在语义歧义方面的 $F1$ 分数存在着较大的差距，是因为语义歧义本身涉及多种逻辑解读的可能性，在参数为 0.5 时，模型具有一定的随机性，有助于生成多样化的解释从而减少偏差；而在参数为 0 时，模型输出虽然有一定的确定性但可能会出现漏解的情况。

表 4.6 不同温度参数稳定性与准确性比较

Table 4.6 Comparison of stability and accuracy of different temperature parameters

歧义类型		Temperature 为 0.5				Temperature 为 0			
		准确率	召回率	精确率	$F1$ 分数	准确率	召回率	精确率	$F1$ 分数
词汇歧义	第一次	0.8444	0.8702	0.9661	0.9157	0.8593	0.8788	0.9748	0.9243
	第二次	0.8741	0.8939	0.9752	0.9328	0.8741	0.8939	0.9752	0.9328
	第三次	0.8667	0.8797	0.9832	0.9286	0.8370	0.8561	0.9741	0.9113
	均值	0.8617	0.8813	0.9748	0.9257	0.8568	0.8763	0.9747	0.9228
	标准差	0.0134	0.0118	0.0086	0.0094	0.0152	0.0155	0.0005	0.0088
句法歧义	第一次	0.8661	0.8661	1.0000	0.9283	0.8740	0.8740	1.0000	0.9328
	第二次	0.8898	0.8898	1.0000	0.9417	0.8819	0.8819	1.0000	0.9372
	第三次	0.8819	0.8819	1.0000	0.9372	0.8819	0.8819	1.0000	0.9372
	均值	0.8793	0.8793	1.0000	0.9357	0.8793	0.8793	1.0000	0.9357
	标准差	0.0121	0.0121	0	0.0068	0.0046	0.0046	0	0.0025
语法歧义	第一次	0.8500	0.9577	0.8831	0.9189	0.8375	0.9571	0.8701	0.9116
	第二次	0.8375	0.9571	0.8701	0.9116	0.8375	0.9571	0.8701	0.9116
	第三次	0.8500	0.9714	0.8718	0.9189	0.8375	0.9571	0.8701	0.9116
	均值	0.8458	0.9621	0.8750	0.9165	0.8375	0.9571	0.8701	0.9116
	标准差	0.0072	0.0081	0.0071	0.0042	0	0	0	0
语义歧义	第一次	0.7167	0.8161	0.8547	0.8350	0.7110	0.8097	0.8537	0.8311
	第二次	0.7309	0.8323	0.8571	0.8445	0.7110	0.8045	0.8596	0.8311
	第三次	0.7280	0.8317	0.8538	0.8426	0.6884	0.7814	0.8526	0.8154
	均值	0.7252	0.8267	0.8552	0.8407	0.7035	0.7985	0.8553	0.8259
	标准差	0.0075	0.0092	0.0017	0.0050	0.0130	0.0151	0.0038	0.0091

中国知网　https://www.cnki.net

表 4.6 不同温度参数稳定性与准确性比较（续）

Table 4.6 Comparison of stability and accuracy of different temperature parameters

歧义类型		Temperature 为 0.5				Temperature 为 0			
		准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
语用歧义	第一次	0.6304	1.0000	0.6304	0.7733	0.6196	0.9661	0.6333	0.7651
	第二次	0.6087	0.9825	0.6154	0.7568	0.5978	0.9649	0.6111	0.7483
	第三次	0.5761	0.9636	0.5889	0.7310	0.6196	1.0000	0.6196	0.7651
	均值	0.6051	0.9820	0.6116	0.7537	0.6123	0.9770	0.6213	0.7595
	标准差	0.0273	0.0177	0.0210	0.0213	0.0126	0.0193	0.0112	0.0097
语言错误歧义	第一次	0.8118	0.9718	0.8313	0.8961	0.8118	0.9718	0.8313	0.8961
	第二次	0.8118	0.9718	0.8313	0.8961	0.7882	0.9710	0.8072	0.8816
	第三次	0.8000	0.9577	0.8293	0.8889	0.8000	0.9577	0.8293	0.8889
	均值	0.8079	0.9671	0.8306	0.8937	0.8000	0.9668	0.8226	0.8889
	标准差	0.0068	0.0081	0.0011	0.0042	0.0118	0.0079	0.0134	0.0072

综上所述，两者的相似点来自于以规则为主导的部分，差异则更多体现在以语境为主导的部分，参数 0.5 增加探索性但是也缺少一定稳定性。经过多次实验得出，参数 0 得到的结果更稳定一些，所对应的标准差平均下降大约 1 个百分点；而参数 0.5 稍显不稳定，但是对于词汇、句法层面的影响很小（小于 0.5%），比较适应于探索性工作。最终得出对于温度参数 0.5 带来的随机性影响不大，可以通过多次重复实验来获得一定的结果稳定。

4.5.4 实验结果与分析

问题 1：数据集的单句需求样本是否在语义、场景和逻辑上完全独立?

为了回答该问题，一方面，本文收集 12 篇论文中对数据集的描述进行数据集的独立性判断，判断数据集是否存在关联，分析结果见表 4.7。另一方面，本文将通过余弦相似度计算、隐含狄利克雷分配（LDA）主题建模、正则表达式结构分析来验证数据集的关联性特征，实验结果见图 4.5。

中国知网 https://www.cnki.net

表 4.7 数据集描述分析

Table 4.7 Data set description analysis

序号	代表性文献	数据采集方式	是否为孤立单句	是否提供文档级上下文
1	Berry 等人[3]	经典教学与分析用例句	是	否
2	Berry 等人[16]	从多个项目摘取的“典型歧义句”	是	否
3	Kamsties 等人[14]	零散选取的独立样本，来自系统需求、学术案例、人工设计示例	是	否
4	Nigam 等人[17]	从 scribd.com 下载 4 个开源 SRS 纯文本文档，未做任何修改，用于独立验证歧义检测工具的效果，彼此间无任何关联	是	否
5	Tjong 等人[18]	专为检验而收集的独立例句	是	否
6	Gleich 等人[20]	正则匹配后人工确认的 38 类模式句	是	否
7	Sabriye 等人[21]	POS 实验中逐句标注	是	否
8	Abualhaija 等人[61]	铁路、航天、气象等 6 个完全不同领域的独立抽取句	是	否
9	Fantechi 等人[62]	咖啡机、电商、图书馆、智能家居 4 个独立系统例句	是	否
10	Fazelnia 等人[63]	3 类数据集（分类/缺陷/冲突），来源公开库/真实项目/人工构建；3 类间无关联，无共享样本	是	否
11	Saleem 等人[64]	无人机、医疗、缺陷追踪等 6 个独立领域例句	是	否
12	Wasow 等人[65]	“自然语言歧义案例”，来源英语日常/词典/语料库/真实场景	是	否

通过梳理论文中对数据集的描述，绝大多数论文[3,14,16,17,20,21,61,62,64,65]所使用的数据集本质上是分散的、独立的文本案例或需求语句集合，这些材料来自不同来源、不同领域、不用项目，案例或语句之间没有业务逻辑关联、没有上下文依赖

中国知网　https://www.cnki.net

关系、没有共享术语或系统背景，纯粹是为了佐证歧义现象、覆盖多样场景或验证工具泛化性而被整合到一起。只有部分论文[18,63]的数据来源相对明确且经过筛选验证，但同样强调领域多样性和样本间的非关联性，以确保研究结论的普适性。数据获取方式独立，所有样本收集均遵照完整单句的核心原则，不涉及连续篇章或关联任务的串联收集。每个样本的选取均不依赖其他样本的内容或属性，仅因研究需要被放在一起用作歧义示例或测试样本。

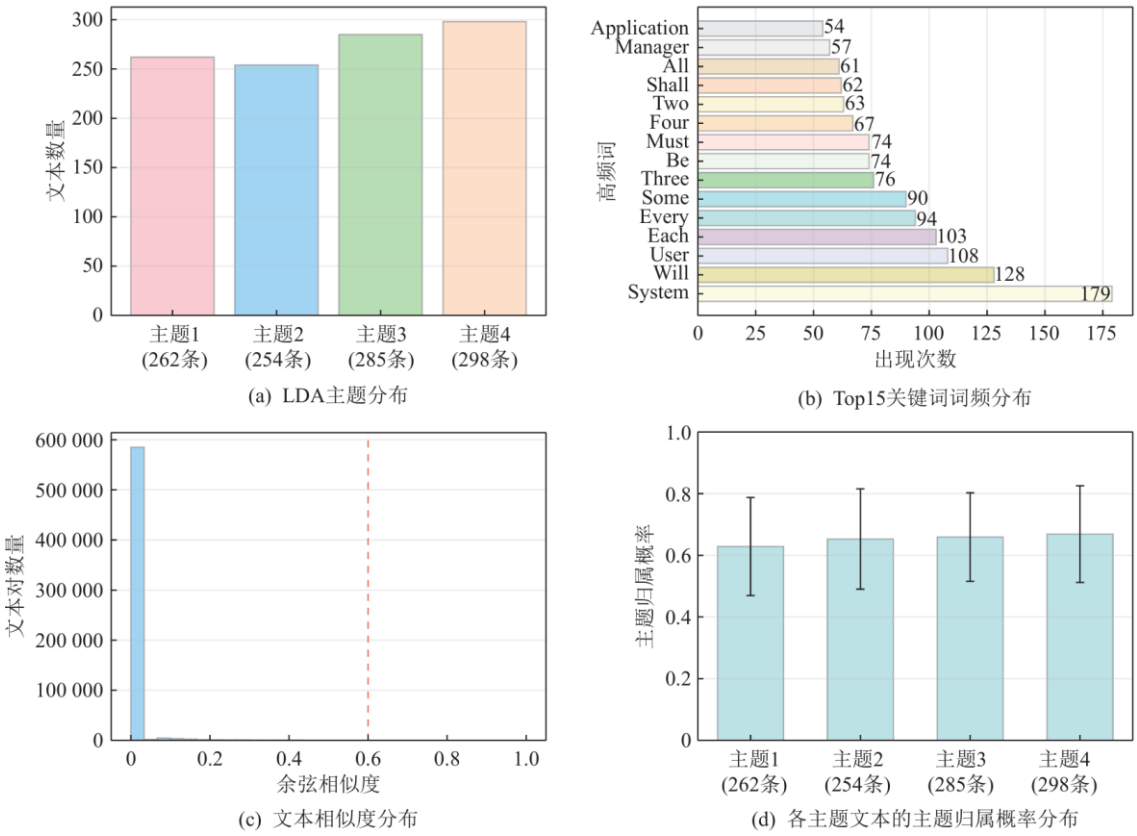


图 4.5 数据关联性分析图

Fig. 4.5 Data correlation analysis chart

通过余弦相似度计算、LDA 主题建模、正则表达式结构分析，基于 LLM 对数据相关性进行分析，在 LDA 主题分布方面，该数据集有四个主题，每个主题下文本数量相近，表明数据集有一定主题多样性，但是由于 LDA 主要是针对文档级别的主题概率进行提取，在有篇章级联系或者跨句依赖的情况下，LDA 可以发现更紧密的主题聚类或者子主题层次结构，而在本例中主题分布相对分散并且彼此之

中国知网 https://www.cnki.net

间无明显关联，说明需求句子多数是独立存在的而非串联形成一个完整的故事，文本语义方向也较分散，不存在同一情境下跨句相关性；而在 Top15 关键词词频中，高频词均为一般性词语而非具体业务场景重要词，因此表示数据集是由许多分散无关联句子组成，并不存在“同一业务或者用户故事相关文档”；在文本相似程度上，大多数文本对余弦相似度小于 0.2，同时强关联阈值 0.6 右侧的文本对数量接近于 0，表明该语料库中文本间重复较少；另外，在主题归属概率上，每个主题归属概率相差不大并且误差棒（黑色竖线）较大，说明文本所涉及的主题范围较广，同一业务场景下语义聚类的情况较少，因此也不存在跨句语义依赖关系。

综上，本研究使用数据集是以单条需求语句作为最小单位，数据来源于公开的需求歧义检测研究及相关论文中的需求实例，在最初创建时一般已进行句子级别的切分及标记，即每条需求语句均可独立表示完整意义，其上下文关系被有意剔除或未被保留。所以该数据集并没有涉及到不同需求语句之间的篇章级关系，也没有考虑同一个业务场景或用户故事中的跨句语义依赖。本文主要关注句内或局部上下文层面的需求歧义检测，并不关注跨句或跨段落的一致性问题。另外，从数据标注的角度看，实验中所需样本均根据单句语义特征被标注为 6 种语言歧义类型之一。因此，本文遵照数据集的特点以单句粒度进行实验设计。

问题 2：LMAdetect 在检测单个类型的需求歧义性能方面是否优于现有的需求歧义检测方法？

为了验证这个问题的结果，本文将 LMAdetect 与 Gleich 等人[20]的工作、基于传统方法实现的原型工具[21]和基于 NLP 技术和规则结合的 Paska 方法[26]进行了对比实验，并将分别仅使用规则和大语言模型对需求进行歧义检测，鉴于现有方法无法对语用歧义和语言错误歧义进行检测，所以此实验针对词汇歧义、语义歧义、语法歧义、句法歧义进行检测对比。对比实验的结果分别见表 4.8 至表 4.11。

如表 4.8 所示，将规则和 LLM 相结合的检测效果明显高于仅使用单一策略的情况。这表明 LMAdetect 中各部分的结合，可以有效提高需求歧义检测的能力。相较于仅采用启发式规则的结果，在针对词汇歧义检测方面，LMAdetect 的准确率提升了 0.2667，召回率提升了 0.2798，$F1$ 分数提升了 0.1770；在检测语义歧义方面，LMAdetect 准确率提升了 0.2691，召回率提升了 0.3700，$F1$ 分数提升了 0.2190；在检测语法歧义方面，LMAdetect 准确率提升了 0.0125，召回率提升了 0.1321，$F1$ 分数提升了 0.0075；在检测句法歧义方面，LMAdetect 准确率提升了 0.4055，精确率提升了 0.5000，$F1$ 分数提升了 0.2837。虽然启发式规则在歧义检测方法中有一

中国知网　https://www.cnki.net

定作用，通过简单的逻辑以及固定的模式进行歧义分类，可以在一定程度上利用结构性的方式发现一部分歧义类型但是对于复杂情况能力存在局限。只使用大语言模型的效果，在基于词汇和语义方面相较于启发式规则有明显的提升。说明大语言模型对于歧义检测可以注意到更多的细节，对于需求的语义理解更深。大语言模型的性能在一些层面上比启发式规则更出色，但在针对结构化的检测上不如启发式规则的检测效果。无论是规则还是大语言模型，和 LMAdetect 的整体效果相比，仍存在差距。与使用正则表达式方法识别的词汇歧义相比，LMAdeetect 的效果有较大改善。召回率以及 *F*1 分数分别为传统方法的 3.74 倍和 2.71 倍，同时精确率也相应提高 0.3558。

表 4.8 LMAdetect 与正则表达式方法性能比较（词汇歧义）

Table 4.8 Performance comparison of LMAdetect and regular expression methods (lexical ambiguity)

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.6074	0.6074	1	0.7558
仅使用大语言模型	0.6809	0.7686	0.8692	0.8158
LMAdetect	0.8741	0.8872	0.9833	0.9328
正则表达式	0.8903	0.2370	0.6275	0.3440

表 4.9 LMAdetect 与正则表达式方法性能比较（语义歧义）

Table 4.9 Performance comparison of LMAdetect and regular expression methods (semantic ambiguity)

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.4391	0.4391	1	0.6102
仅使用大语言模型	0.6006	0.7043	0.8030	0.7504
LMAdetect	0.7082	0.8091	0.8503	0.8292
正则表达式	0.7653	0.6516	0.6250	0.6380

同样，如表 4.9 所示，在识别语义歧义上，LMAdetect 相比于正则表达式方法，在召回率、精确率以及 *F*1 分数上增加约 0.2。由此可见，正则表达式的方法对于歧义检测的效果较差，而 LMAdetect 弥补了这一不足之处，取得良好结果。如表 4.10

中国知网 https://www.cnki.net

所示，与使用 POS 标记方法识别的语法歧义相比，LMAdetect 的召回率、精确率及 *F*1 分数分别提升 0.1389、0.1951 以及 0.1713。如表 4.11 所示，与现有的 3 个方法检测的句法歧义相比，LMAdetect 表现更优，与正则表达式的方法相比，LMAdetect 的准确率、召回率、精确率以及 *F*1 分数分别增长 0.0116、0.7244、0.3784 以及 0.6697；与 POS 标记方法相比，LMAdetect 的准确率、召回率、精确率以及 *F*1 分数分别增高 0.2024、0.3253、0.4016、0.3612；与 Paska 工具相比，LMAdetect 的准确率、召回率、*F*1 分数也都大约增加 0.1。这是由于引入大语言模型进行规则知识以及语义理解相结合，充分发挥出模型优化带来的优势。

表 4.10 LMAdetect 与 POS 标记方法性能比较（语法歧义）

Table 4.10 Performance comparison of LMAdetect and POS tagging methods (syntax ambiguity)

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.8250	0.8250	1	0.9041
仅使用大语言模型	0.1250	0.3125	0.1724	0.2222
LMAdetect	0.8375	0.9571	0.8701	0.9116
POS 标记	0.8936	0.8182	0.6750	0.7403

表 4.11 LMAdetect 与现有方法性能比较（句法歧义）

Table 4.11 Performance comparison of LMAdetect and existing methods (syntactic ambiguity)

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.5000	1	0.5000	0.6667
仅使用大语言模型	0.4016	1	0.4016	0.5730
LMAdetect	0.9055	0.9055	1	0.9504
正则表达式	0.8939	0.1811	0.6216	0.2807
POS 标记	0.7031	0.5802	0.5984	0.5892
Paska	0.7638	0.7638	1	0.8664

综上，结合大语言模型及规则的方法对于不同类型歧义检测都具有良好效果，在实验中相比传统的以及基线模型都有较大提高。LMAdetect 结合启发式规则及大语言模型的优势，即使与单独使用大语言模型相比也能取得较好结果，这说明它

中国知网　https://www.cnki.net

对需求歧义检测的有效性和可靠性。

问题 3：LMAdetect 在检测语用歧义和语言错误歧义上的检测效果如何？

为了回答该问题，本文将分别仅使用规则、仅使用大语言模型和增加语义理解、逻辑关系识别、指代识别的上下文感知能力进行检测，计算语用歧义和语言错误歧义的准确率、召回率、精确率、*F*1 分数，实验结果见表 4.12、表 4.13。

实验结果表明，通过大语言模型与多智能体协作增强上下文感知后得到的结果比只使用规则或者只使用大语言模型所得到的结果要高很多，对歧义检测有明显改善。如表 4.12 所示，在检测语用歧义时，LMAdetect 相比于只使用规则，在准确率、精确率等方面都有较大进步，*F*1 提升 0.5726 效果最好。对于检测语言错误歧义的实验结果如表 4.13 所示，三者均提升了 0.10 以上，而且 *F*1 甚至高达 0.8889。而与只使用大语言模型相比，在检测语用歧义方面，准确率和 *F*1 分数提高了约 0.17，召回率提高 0.5025；而在语言错误歧义方面，准确率、精确率、*F*1 分数也都相应地提高 0.0353、0.0455、0.0222。

表 4.12 检测语用歧义方面性能比较

Table 4.12 Performance comparison of detecting pragmatic ambiguity

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.0652	1	0.0652	0.1224
仅使用大语言模型	0.3587	0.4583	0.6226	0.5280
LMAdetect	0.5326	0.9608	0.5444	0.6950

表 4.13 检测语言错误歧义方面性能比较

Table 4.13 Performance comparison of detecting language error ambiguity

工具/方法	准确率	召回率	精确率	*F*1 分数
仅使用规则	0.6471	0.6471	1	0.7857
仅使用大语言模型	0.7647	0.9848	0.7738	0.8667
LMAdetect	0.8000	0.9714	0.8193	0.8889

综上，实验结果表明，LMAdetect 由于增强了上下文理解，在对语义理解、逻辑关系识别以及指代识别都取得了良好效果的基础上，可以很好地解决语用歧义和语言错误引起的歧义问题而且该方法利用启发式规则简单易操作的特点以及大

中国知网 https://www.cnki.net

语言模型强大的识别能力来提高需求歧义识别的效果，这一发现也说明了LMAdetect 的设计是合理的。

为评估提出的多智能体协作框架和 D-S 证据理论融合的必要性，进行了基于现有基线的消融分析。消融研究通过比较完整 LMAdetect 框架与简化变体评估关键组件的贡献。“仅使用规则”变体消融了大语言模型和多智能体组件，仅依赖启发式规则检测；“仅使用大语言模型”变体消融了基于规则的算法和专家分配，模拟更简单的单大语言模型多分类方法（如通过提示直接处理 6 种歧义类型）。如表 4.8~4.13 所示，消融这些组件能显著降低性能。词汇歧义下，完整 LMAdetect 的 *F*1 分数为 0.9328，较仅使用规则（0.7558）提升 17.7%，较仅使用大语言模型（0.8158）提升 11.7%；其他类型类似，平均 *F*1 分数较仅使用规则提升 34.4%，较仅使用大语言模型提升 31.6%。这证明了每个组件的独特贡献：启发式规则提供结构化检测但缺乏深层语义，导致语用和语言错误歧义召回率低；纯大语言模型提供语义理解但无智能体路由和融合，导致分类不一致，精确率下降。多智能体设计为每类型分配专家，而 D-S 融合汇总置信度解决冲突，实现 6 种歧义全面覆盖。虽然本文的框架通过多智能体协作和 D-S 融合引入复杂性，消融比较证明了其相对于简单替代方案的必要性。本文的设计优势增强语义/逻辑识别和指代解析，实现语用和语言错误歧义的优越处理。

问题 4：在多类歧义检测任务中，不同模型对结果的影响如何？

为考察各种模型对于不同类型的歧义识别的效果的优劣，本文对通用模型与推理模型进行了比较研究，详见表 4.14 至表 4.19，并且通过对这些不同的模型进行比较来发现各自的特点及其对于歧义识别的影响。

（1）通用模型的效果

为了评估通用模型检测能力，本文对 qwen2.5-72b-instruct、deepseek-v3-0324 gpt-4o 等多个通用模型进行了对比。为便于排版，表格中部分模型名称采用简称：qwen2.5-72b-instruct 简称为 qwen2.5-72b，deepseek-v3-0324 简称为 deepseek-v3，claude-3-5-sonnet-20241022 简称为 claude-3-5，其余模型名称与原名保持一致。如表 4.14 所示，在检测词汇歧义上，deepseek-v3-0324 模型的 *F*1 最高，该模型对于词汇歧义识别较好。但是 qwen2.5-72b-instruct 模型 *F*1 为 0.7783，gpt-4o 模型为 0.7892，两者与表现最优的模型 0.9328 相差近 0.15 表现一般，这表明两类模型在细微词汇歧义处理上有所欠缺。对于句法歧义而言，大部分模型均能达到预期效果，其中表现最突出的模型为 claude-3-5-sonnet-20241022，由于其准确率达到

中国知网　https://www.cnki.net

0.9543 同时召回率保持在 0.9843，这间接导致了较高的 *F*1 值。如表 4.15 所示，在语法歧义检测上，deepseek-v3-0324 模型 *F*1 值为 0.9116 最高，相比之下，claude-3-5-sonnet-20241022 和 grok-4 模型准确率却仅在 50%上下，显著拉低了 *F*1 值，在全部对比模型中处于劣势。对于语义歧义类型的检测，所有对比模型均未达到预期，尽管 deepseek-v3-0324 模型取得了 0.8292 的 *F*1 值，但表现最差的模型 gpt-4o 其 *F*1 值仅达 0.6729，准确率只有 0.5071，显示出其在复杂语义场景下处理歧义的困难。如表 4.16 所示，对于语用歧义类型的检测，deepseek-v3-0324 与 gpt-4o 表现较好，qwen2.5-72b-instruct 却表现一般。在语言错误歧义识别上，grok-4 模型 *F*1 最高是 0.9941，其次是 gemini-2.5-pro，说明该模型具有较强的语言错误识别能力。

表 4.14 通用模型检测词汇歧义和句法歧义性能比较

Table 4.14 Performance comparison of general model detecting lexical ambiguity and syntactic ambiguity

通用模型	词汇歧义				句法歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwen2.5-72b	0.6370	0.7478	0.8113	0.7783	0.9291	0.9291	1	0.9633
deepseek-v3	0.8741	0.8872	0.9833	0.9328	0.8741	0.9055	1	0.9504
gpt-4o	0.6519	0.7040	0.8980	0.7892	0.9213	0.9360	0.9832	0.9590
claude-3-5	0.6815	0.9485	0.7077	0.8106	0.9543	0.9843	1	0.9921
grok-4	0.7037	0.9314	0.7422	0.8261	0.9134	0.9134	1	0.9547
gemini-2.5-pro	0.6963	0.9691	0.7121	0.8210	0.8976	0.9268	0.9661	0.9461

注 1）表中模型简称对应关系为：qwen2.5-72b-instruct→qwen2.5-72b，deepseek-v3-0324→deepseek-v3，claude-3-5-sonnet-20241022→claude-3-5，其余模型名称与原名一致。

实验结果表明，通用模型在检测句法歧义和语言错误歧义方面表现良好，但由于可能需要语义以及上下文的推理，通用模型对于语用和语义歧义检测方面相对较差。

（2）推理模型的效果

为了评估不同推理模型针对不用歧义类型的检测情况，本文对 qwq-max-search、deepseek-reasoner、o1-preview 等多个推理模型进行了对比。为便

中国知网 https://www.cnki.net

于排版，deepseek-reasoner 表格中部分模型名称采用简称，qwq-max-search 简称为 qwq-max，deepseek-reasoner 简称为 ds-reasoner，claude-3-7-sonnet-thinking 简称为 claude-3-7，gemini-2.5-pro-thinking 简称为 gemini-2.5，其余模型名称与原名保持一致。如表 4.17 所示，对于词汇歧义的检测，qwq-max-search 模型的 *F*1 最高达到 0.9655。claude-3-7-sonnet-thinking 模型的 0.9664 表现优于其通用模型 claude-3-5-sonnet-20241022 的 0.8106。对于句法歧义检测，多数推理模型均能达到 0.90 以上的 *F*1 值。其中 gemini-2.5-pro-thinking 模型表现最好，准确率达到 0.9291 同时 *F*1 值也达到了 0.9633。如表 4.18 所示，对于语法歧义的检测，在推理模型上的实验中，o1-preview 模型表现最优，准确率达到 0.7875。grok-3-reasoner 模型表现最差，准确率只有 0.3750。对于语义歧义的检测，表现最优的 qwq-max-search 模型的 *F*1 只有 0.6974，grok-3-reasoner 模型甚至只有 0.4619。如表 4.19 所示，对于语用歧义识别，gemini-2.5-pro-thinking 的推理模型 0.9486 的 *F*1 值远高于对应通用模型 gemini-2.5-pro 的 0.7568。本文选取的多种类推理模型在语言错误歧义的判断结果上都表现较好，*F*1 分数大多都在 0.91 以上。

表 4.15 通用模型检测语法歧义和语义歧义性能比较

Table 4.15 Performance comparison of general model detecting syntactic ambiguity and semantic ambiguity

通用模型	语法歧义				语义歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwen2.5-72b	0.7875	0.9000	0.8630	0.8811	0.5241	0.7255	0.6537	0.6877
deepseek-v3	0.8375	0.9571	0.8701	0.9116	0.8375	0.8091	0.8503	0.8292
gpt-4o	0.7125	0.8769	0.7917	0.8321	0.5071	0.5359	0.9040	0.6729
claude-3-5	0.5125	1	0.5125	0.6777	0.6714	0.9186	0.7139	0.8034
grok-4	0.5000	1	0.5000	0.6667	0.6204	0.6801	1	0.8096
gemini-2.5-pro	0.6250	1	0.6250	0.7692	0.6657	0.9553	0.6871	0.7993

注 1）模型简称含义见表 4.14。

实验结果表明，推理模型通常在特定任务中优于其通用模型，尤其是在语用和语言错误歧义方面，能够有效支持上下文理解和逻辑分析。

中国知网　https://www.cnki.net

表 4.16 通用模型检测语用歧义和语言错误歧义性能比较

Table 4.16 Performance comparison of general model detecting pragmatic ambiguity and language error ambiguity

通用模型	语用歧义				语言错误歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwen2.5-72b	0.3587	0.6000	0.4714	0.5280	0.7059	0.9677	0.7229	0.8276
deepseek-v3	0.5326	0.9608	0.5444	0.6950	0.8000	0.9714	0.8193	0.8889
gpt-4o	0.5978	0.5978	1	0.7483	0.8471	0.9474	0.8889	0.9172
claude-3-5	0.4891	1	0.4891	0.6569	0.8353	1	0.8353	0.9103
grok-4	0.4348	0.4396	1	0.6107	0.9882	1	0.9882	0.9941
gemini-2.5-pro	0.6087	0.8116	0.7089	0.7568	0.9412	1	0.9412	0.9697

注 1）模型简称含义见表 4.14。

表 4.17 推理模型检测词汇歧义和句法歧义性能比较

Table 4.17 Performance comparison of inference model detecting lexical ambiguity and syntactic ambiguity

推理模型	词汇歧义				句法歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwq-max	0.9333	0.9618	0.9692	0.9655	0.9055	0.9200	0.9829	0.9504
ds-reasoner	0.6222	0.7059	0.8400	0.7671	0.8268	0.8268	1	0.9052
o1-preview	0.6963	0.7705	0.8785	0.8210	0.8346	0.8346	1	0.9099
claude-3-7	0.8519	0.9350	1	0.9664	0.8819	0.8819	1	0.9371
grok-3-reasoner	0.6370	0.6615	0.9451	0.7783	0.8819	0.8819	1	0.9371
gemini-2.5	0.6667	0.8036	0.7965	0.8000	0.9291	0.9291	1	0.9633

注 1）表中模型简称对应关系为：qwq-max-search→qwq-max，deepseek-reasoner→ds-reasoner，claude-3-7-sonnet-thinking→claude-3-7，gemini-2.5-pro-thinking→gemini-2.5，其余模型名称与原名一致。

对比通用模型与推理模型，推理模型 qwq-max-search 在词汇、语言错误类型的歧义检测上比通用模型 qwen2.5-72b-instruct 有较大提高。gemini-2.5-pro-thinking 模型在语用类型的歧义上也有很高分数，在句法类型的歧义上甚至达到 92.91%的

中国知网 https://www.cnki.net

准确率。可以说明推理模型对语境相关的任务是有一定帮助的。但是 grok-3-reasoner 模型在语义、语法类型的歧义上不如 grok-4 模型。除去模型自身问题，这一案例可以说明推理模型并不适应于所有的类型歧义检测。deepseek-v3-0324 模型在通用任务中表现稳定，尤其擅长处理词汇歧义以及句法歧义。而 deepseek-reasoner 在语言错误歧义检测方面表现优异，但在检测语用歧义上稍显不佳。OpenAI 的 gpt-4o 模型和 o1-preview 模型则展现出均衡性能，其中 o1-preview 模型在检测语法错误和语义歧义方面有所提升。Claude 模型在句法和语言错误歧义检测方面表现良好，通过推理模型的推理增强在语用任务中显著提升了性能。Grok 模型在检测语言错误歧义方面表现优异，但在语义和语法歧义处理上面存在不足，特别是在推理模型检测中。Google 模型通过推理在语用歧义检测上取得显著进步，使其在上下文任务中具备竞争力。

表 4.18 推理模型检测语法歧义和语义歧义性能比较

Table 4.18 Performance comparison of inference model detecting syntactic ambiguity and semantic ambiguity

推理模型	语法歧义				语义歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwq-max	0.5875	0.7705	0.7121	0.7402	0.5354	0.7941	0.6217	0.6974
ds-reasoner	0.4375	0.8333	0.4795	0.6087	0.5921	0.7385	0.7491	0.7438
o1-preview	0.7875	0.9000	0.8630	0.8811	0.5722	0.6537	0.8211	0.7279
claude-3-7	0.6500	0.7123	1	0.8320	0.6289	0.8605	0.7003	0.7722
grok-3-reasoner	0.3750	0.4225	0.7692	0.5455	0.3003	0.3202	0.8281	0.4619
gemini-2.5	0.6500	0.8667	0.7222	0.7879	0.5014	0.6887	0.6484	0.6679

注 1）模型简称含义见表 4.17。

综上，LMAdetect 在检测多种类型的歧义性问题上是可行的。通用模型对于句法歧义和语言错误歧义有较好的效果，在语用以及语义类别的歧义检测上较差。而推理型模型一般可以在涉及逻辑推理或者语境推理的语用与语言错误类别的歧义检测上有较好的效果。但是不同的模型在不同的任务中增加推理的效果并不一致，有些模型在某些种类的歧义检测上表现不佳。

中国知网　https://www.cnki.net

表 4.19 推理模型检测语用歧义和语言错误歧义性能比较

Table 4.19 The inference model detects pragmatic ambiguity and language error ambiguity performance comparison

推理模型	语用歧义				语言错误歧义			
	准确率	召回率	精确率	*F*1 分数	准确率	召回率	精确率	*F*1 分数
qwq-max	0.3587	0.9706	0.3626	0.5208	0.8353	0.9861	0.8452	0.9103
ds-reasoner	0.3370	0.8158	0.3647	0.5041	0.9529	0.9759	0.9759	0.9759
o1-preview	0.4239	0.7222	0.5065	0.5954	0.6824	0.9063	1	0.9508
claude-3-7	0.5109	1	0.5109	0.6763	0.6353	0.8710	1	0.9310
grok-3-reasoner	0.5217	0.7059	0.6667	0.6857	0.6941	0.8551	1	0.9219
gemini-2.5	0.9022	1	0.9022	0.9486	0.8353	0.8765	0.9467	0.9103

注 1）模型简称含义见表 4.17。

4.5.5 讨论与局限性

上节中所有实验均是为了回答前文 4.5.1 提出的四个研究问题，现在由实验结果给出具体回答。问题 1，数据集以单句形式呈现，在语义、场景和逻辑上是完全独立的。问题 2，LMAdetect 虽然能够有效检测单类型的需求歧义，但在若干方面仍然存在不足，需要持续改进完善。问题 3，LMAdetect 能够有效检测语用歧义和语言错误歧义，但针对具体的语用歧义类型当前检测方法还有待加强。问题 4，对于通用模型和推理模型的检测效果来说，通用模型在句法以及语言错误上表现良好，推理模型在语用以及语言错误上有所提升，但是不同的模型与不同的歧义类型效果不同。

上述实验结果与分析表明 LMAdetect 对于需求歧义检测具有良好效果，在一定程度上可以应对第 1 章中提到的问题。这一成果通过精准检测与定位开发周期中的歧义指代，降低项目开发人员之间因为执行标准不一致带来的沟通成本。虽然本研究开发的 LMAdetect 对识别歧义有明显改善，但对于歧义类型的细粒度分类仍然需要进一步改进。特别地，本方法在区分复杂的、上下文相关的歧义类型上还有待提高。因此，未来本研究可将研究重点转移至提升语义与语用歧义情境下上下文的理解能力上，进一步增强全类别歧义检测性能。

本文基于 deepseek-v3-0324 在 1192 个样本的数据集上对 LMAdetect 进行了一

中国知网 https://www.cnki.net

系列实验。虽然在多种歧义类型上表现良好，但仍有一些可以改进之处。其一，基底模型的选择相对单一。目前所使用的该模型已具有一定的语义理解能力，但由于本文在实验中并未使用更大规模的最新版本的模型，也未针对具体的检测任务进行专门的训练以及调优工作，因此该模型所具有的潜力未能充分发挥出来，从而使得 LMAdetect 的整体效果受到影响。其二，实验设计不够全面。本文仅对不同类型 LLM 进行实验来验证不同种类模型在歧义检测上的效果，而对于单一种类的 LLM 本文并未考察其在不同的硬件环境下或者不同的超参数设置下所能达到的结果。其三，数据集中数据来源单一。本文使用的数据集主要是来源于学术论文及 GitHub 代码库等公开资源而未包括实际项目中遇到的各种各样的歧义情况，可能会导致数据集泛化能力不足。大模型幻觉是一个难以根除的问题，这会影响歧义检测的结果导致一些本不应该出现的歧义被误判。其四，LMAdetect 基于多智能体协作虽然提高检测的鲁棒性但其计算复杂性较高。对于实际工程中需要大批处理的需求文档，过长的等待时间不利于该框架投入生产应用。

4.5.6　有效性威胁分析

LMAdetect 方法的有效性可能面临以下威胁。首先，内部有效性威胁，在数据预处理时可能会出现人为选择偏差进而影响实验结果的代表性。此外，模型选择以及具体参数设置也可能影响检测结果，若未充分研究其他模型与参数的组合形式，可能低估了方法性能的上限。其次，外部有效性威胁源于数据集的局限性。现有的实验仅依据特定学术文献和公开数据集，未能涵盖到各个行业或领域的需求文档类型，限制了方法在不同上下文中的普适性。此外，实验环境可能与实际工业环境存在差异，如资源限制或硬件差异，这可能影响方法的可扩展性。最后，构造有效性威胁可能源于对歧义类型的定义和检测条件简化的结果，实际需求中的歧义可能涉及更复杂的交互或未定义的模式，目前的分类体系未必能够完全覆盖所有的可能性，使得检测指标可能高估了方法的实际能力。然而，该方法需要通过提示词提供用户数据进行 LLM 分析，数据可能在操作途径中存在潜在泄露。针对工具本身，本文的框架采用无存储策略，用户输入仅在内存中临时处理，没有任何的日志或者数据库来保存，这就保证工具本身不会发生数据泄露的问题。针对中间服务商 Chatfire，在实验过程中进行调用，因为其不具有透明性所以 Chatfire 对于数据的操作是不确定的，这增加了泄露的风险。针对大语言模型提供商 DeepSeek，在调用 Chatfire 后向 DeepSeek 发送请求，DeepSeek 在公开文档中

中国知网　https://www.cnki.net

明确声明，不会利用客户提供的内容对模型进行训练，且遵循行业标准的隐私保护策略，这在原则上降低了数据泄露的可能性。但需要注意，具体实现上的透明度有限，用户仍需依赖提供商的承诺。然而，由于实际情况缺乏足够的透明度，即便 DeepSeek 已出具书面保证，其能否切实做到信息不泄露，仍有待进一步验证。

4.6 本章小结

本章针对单一大语言模型在多阶段推理中歧义类型覆盖不足的局限，提出了一种基于大语言模型协调多智能体的需求歧义检测方法 LMAdetect。该方法将启发式规则与大语言模型相结合，首先通过基于 NLP 技术的启发式规则对需求文本进行预处理，提取候选歧义区域；随后利用结构化提示工程引导大语言模型完成歧义分类；最后通过类型专业化多智能体协作框架，将不同歧义类型分配给对应专家智能体进行深度检测，并采用 D-S 证据理论对各智能体输出结果进行置信度融合，生成稳健的最终检测结果。下一章将在本章检测方法的基础上，进一步提出面向需求歧义修复的系统性方法。

中国知网 https://www.cnki.net

第 5 章　基于大语言模型的需求歧义修复方法

本章针对第 4 章的检测结果，根据歧义需求以及对应的歧义类型进行针对性的歧义片段定位，进一步为需求分析师提供具体的修复建议。第 3 章中经验研究表明，歧义修复过程中常因缺失领域知识导致歧义修复结果存在语义不一致问题。为此，本章提出 LMArepair，通过模式匹配结合领域知识集成，使用专家智能体进行具体修复操作来解决修复不一致问题。与现有需求歧义修复方法相比，本章构建了“歧义触发片段→候选解释集合→模板化修复结果”的三阶段修复流程，实现了从定位到修复的完整闭环—区别于仅停留在检测或泛化建议的现有工作。针对单一 LLM 在专业术语理解上的偏差，引入基于维基百科的领域语料库自动构建与知识校准机制，减少幻觉与语义偏离；同时，设计了类型驱动的专家路由机制，不同歧义类型由对应专家智能体独立处理，各专家内部集成模式匹配、LLM 推理与知识校正三个子模块，形成差异化的修复策略。

5.1　方法框架

本文提出一种基于多智能体协同优化的需求歧义修复框架 LMArepair，如图 5.1 所示。该框架由专家路由指派任务，根据不同类型的歧义采用不同的歧义结构提取方式，将大语言模型和规则相结合，在各个专家智能体间进行配合，实现歧义片段提取、原因分析以及修复的过程。该框架采用“歧义触发片段-候选解释集合-模板化的解释结果”方式进行工作，从而得到正确规范的输出结果。

这个框架主要包括三大部分，预处理模块、歧义片段提取模块以及修复建议标准化输出模块。预处理模块主要对输入的需求进行一些预处理工作，只有把需求规范化并且切分成小块，才能保证格式一致从而进行后续的操作。歧义片段提取模块是用零样本或者少样本预先定义好的结构化提示模板指示大语言模型去识别出具体的歧义片段。修复建议标准输出模块则是结合专业知识对找到的歧义片段进行分析并给出相应的解决方案，最终输出歧义修复的结果。为了方便统一的管理，在获取到歧义片段后为其匹配相应的歧义原因分析模板，再利用大语言模型语义理解能力输出合理化的修复建议，这样有利于需求人员的理解和使用。整个方法过程遵循模块化的设计思路，每个模块独立完成一部分任务，一方面提高整体流程的易维护性，另一方面也保障了歧义修复的完整性。

中国知网　https://www.cnki.net

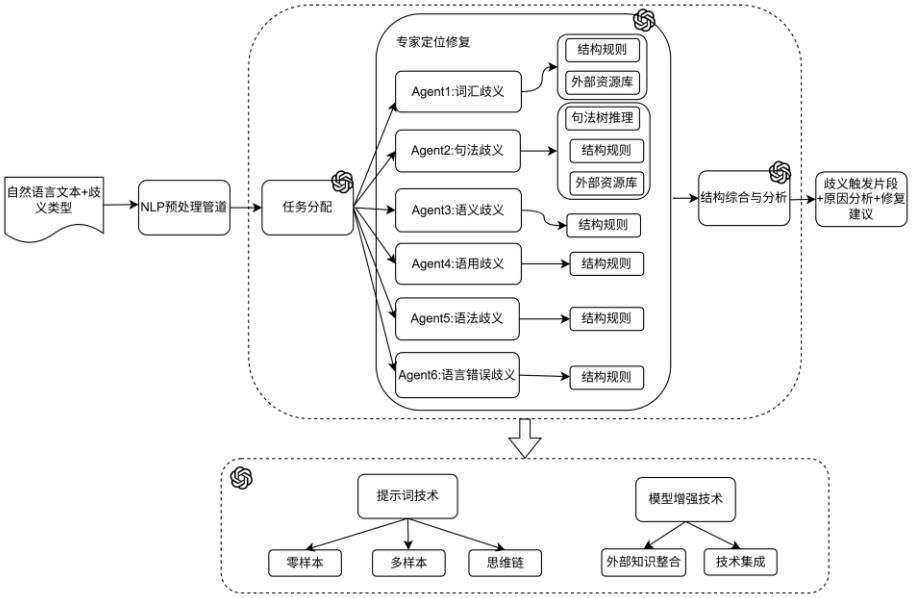


图 5.1 需求歧义修复过程图

Fig. 5.1 Requirements ambiguity repair process diagram

5.2 基于大语言模型的歧义定位

5.2.1 预处理

本文遵照轻量级 NLP 预处理流程对原始输入文本进行预处理得到 LLM 易于理解的结构化语言表示。在此过程中不对歧义进行消解或者作出解释选择，只给出句法以及词汇信息作为后续歧义定位以及选择的基础。

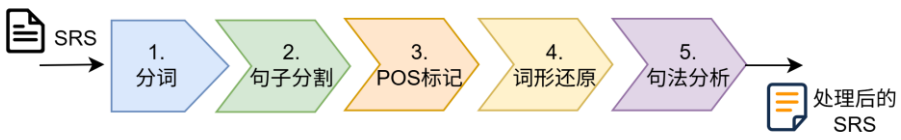


图 5.2 预处理流程图

Fig. 5.2 Preprocessing workflow

如图 5.2 所示，预处理包括五个过程：分词、句子分割、词性标注、词形还原以及成分句法分析。对输入的 SRS 依次进行这些处理，得到带有语言标注的形式，然后由不同歧义处理专家对其进行相应的分析。分词与句子分割将输入文本划分为可以被处理的基本单位并且从句子层面确定歧义分析范围。词性标注和词形还

中国知网 https://www.cnki.net

原给出统一的词性和词形表示，以便于基于规则的方法可以匹配到更一般的模式而不止局限于表面上的形式。成分句法分析所得到的层次化的句法结构可以直接用来定位句法歧义，其句法树也是进行句法歧义定位以及进行多种结构推理的重要输入内容。最后得到的标注形式是供歧义类型路由器和各专家进行定位使用的共同输入。即句法歧义专家根据句法分析树来进行规则驱动和结构上的推理工作，而词性标注以及词元信息则是供词汇歧义专家和语用歧义专家来完成单元定位以及候选解释生成的工作。当前流程将语言预处理和歧义推理分开执行，故本文所提框架允许不同歧义定位专家对同一表示进行处理。

5.2.2　模式匹配

本研究通过分析 6 种歧义类型的结构，参考 Ezzini[77]的工作，针对进行相对应的模式扩展，列出用于不同歧义类型的模式如表 5.1 所示。其中新扩展部分用蓝色阴影表示，已存在的模式用灰色阴影表示，其余模式基于现有模式形式进行撰写，这些模式是根据对应歧义类型结构进行总结得出。

表 5.1 歧义模式

Table 5.1 Ambiguous pattern

歧义类型	序号	模式	序号	模式
句法歧义	1	X+c+Y+c+Z	9	n_1+n_2+n_3
	2	n_1+c+n_2+c+n_3	10	adj+n_1+n_2
	3	adj+n_1+c+n_2	11	dt+n_1+n_2+n_3
	4	adj_1+c+adj_2+n	12	n_1+p(of)+n_2+p(of)+n_3
	5	dt+n_1+v+dt+n_2+p+n_3	13	adj+n_1+p(of)+n_2
	6	n_1+p(of)+n_2+p(with/in)+n_3	14	v+dt/adj+n_1+comp+n_2
	7	dt+n_1+p(of)+dt+n_2+rc	15	as+adj+as+n
	8	n_1+n_2+rc	16	comparative…than…
语用歧义	1	n_1…n_2…pro…adv(time/place)	5	n_1…n_2…pro
	2	…adv_loc/adv_time…	6	np(pl)…they
	3	If+cl_1,…if not,…	7	n(pl)…it
	4	X+shall+Y,If so,Z	8	dt(all/every/each)+n…pro

中国知网　https://www.cnki.net

表 5.1 歧义模式（续）

Table 5.1 Ambiguous pattern

歧义类型	序号	模式	序号	模式
词汇歧义	1	$w+n_1/w+n_2$	6	w+adv
	2	w+p(of)+n	7	dt(this/that)+w
	3	v+w(obj)	8	v+w
	4	adj+w	9	dt+w+be+adj
	5	w+cop+adj	10	be+adj
语义歧义	1	$quant_1+n_1+v+quant_2+n_2$	7	$adj_1+and+adj_2+n$
	2	neg+v+quant+n	8	$if/when/unless+cl_1,cl_2$
	3	quant+adj+n	9	more/less+adj+than+NP
	4	modal+v+quant+n	10	at least/exactly+num+n
	5	X+and+Y+or+Z	11	plural-n+v
	6	X+or+Y+and+Z		
语法歧义	1	be+v-ed	7	be+v-ing
	2	modal+be+v-ed	8	if/when/unless+clause
	3	modal	9	if-clause(fronted)
	4	must+VP/NP	10	modal+not+VP
	5	will/shall+base-VP	11	plural-NP+modal
	6	has+v-ed		
语言错误歧义	1	every/each+singular-n…	6	v_1/v_2
	2	plural-n+singular-verb	7	$modal_1/modal_2$
	3	having…/-ing	8	only/just+position
	4	punctuation-mix	9	adv(time/freq)+position
	5	p(by)/p(until)	10	non-conforming-fragment

注 1）$n/n_1,n_2,n_3$：名词；$adj/adj_1,adj_2$：形容词；v：动词；dt：限定词；p：介词；c：并列连词；rc：关系从句引导词；comp：比较标记；/：或；pro：代词；adv_time/adv_loc：时间/地点副词；cl：从句；cond：条件触发；…：可变上下文；w：歧义词中心；span：实际标注输出片段；quant：量词；modal：情态动词。

中国知网 https://www.cnki.net

在模式匹配中，分析单位是文本片段，即要求中与表 5.1 中给定结构模式相匹配的部分，当对应识别出与表 5.1 中任一模式匹配的段落，本框架会将匹配的段落传递到 LLM，根据 LLM 的思维链模式以及模型增强进行针对性验证，根据置信度评分得出最终歧义片段结果并进行原因分析。

5.2.3　基于大语言模型的推理与验证

在模式匹配筛选出初步候选片段后，利用大语言模型对这些候选片段进行语义层面判断以及验证工作，在模式匹配基础上结合 LLM 推理提高歧义定位准确性。本研究设计了 COT 结构化提示模板，模板结构包括任务指令、结构化输入、推理过程以及输出规范，并通过实例引导模型逐层解析，通过多次指引模型进行逐步推理以及分步进行解释，提供中间步骤来帮助模型思考和推导最终结果，按照逻辑规范生成想要的结果。

```
System Prompt:
你是一名句法歧义分析专家。任务是基于提供的句子、歧义类型和句法树，识别导致句法歧义的最小触发片段。不要假设句法树中不存在的结构。
输入：句子：{sentence}。歧义类型：{ambiguity_type}。句法树：{parse_trees}。
推理步骤：
步骤1：解析每棵树，列出关键短语和依附关系。
步骤2：比较树结构，识别与歧义类型对应的结构差异点。
步骤3：对每个差异点，确定最小触发片段（3-10个词），并通过引用树的差异解释为什么存在歧义。
步骤4：严格按指定的JSON格式输出结果。
输出格式：
{
  "minimal_trigger_segment": "片段",
  "possible_parses": [
  {
    "attachment": "描述",
    "meaning": "解释",
    "tree_reference": "TreeX"
  },
 ],
 "confidence": 0.0,
 "explanation": "原因"
}
示例：
句子："I saw the man with the telescope."
句法树：
Tree1: (S (NP I) (VP saw (NP the man) (PP with (NP the telescope))))
Tree2: (S (NP I) (VP saw (NP the man) (PP with (VP the telescope))))
步骤1：两棵树共享主语NP(I)、动词"saw"和核心宾语NP(the man)。唯一的结构差异在于PP(with the telescope)的依附位置。
步骤2：在Tree1中，PP依附于VP(saw)；在Tree2中，PP依附于NP(the man)。这种依附差异是歧义的结构来源。
步骤3：最小触发片段是"with the telescope"—移除它即可消除两棵树之间的所有结构差异。
{
  "minimal_trigger_segment": "with the telescope",
  "possible_parses": [
  {
    "attachment": "依附于VP(saw)",
    "meaning": "我用望远镜看到了那个男人。",
    "tree_reference": "Tree1"
  },
  {
    "attachment": "依附于NP(the man)",
    "meaning": "我看到了那个有望远镜的男人。",
    "tree_reference": "Tree2"
  }
 ],
 "confidence": 0.95,
 "explanation": "PP依附歧义：介词短语可以修饰动词或名词，产生两种不同的解释。"
}
```

图 5.3 提示词示例

Fig. 5.3 Prompt example

中国知网　https://www.cnki.net

为了提高模型推理可解释性，确保结果可追溯。如图 5.3 所示，使用句法歧义提示词示例，采取 COT 提示方式，让模型在得出最终结论之前，明确地写出其推导过程，比如候选片段在句子中对应的句法树推理路径等。这样可以增加模型输出内容的可解释性并且有利于之后对模型置信度进行校正提供参考。对于一个候选片段，模型可能会有多个候选解释，说明这个片段有多个不同的句法歧义路径。所有的候选解释被收集之后进入到下一阶段知识校准。

5.3 基于领域知识集成的歧义修复建议生成

5.3.1 领域语料库构建

通过爬取维基百科来构建输入需求文档所蕴含的领域知识。第一步基于 Arora 等人[78]提出的自动化需求术语表提取方法，提取关键词。从 SRS 中提取术语词典列表，随后从该列表中选择出现频率最高的前 K 个关键词，使用工具的默认值 K 为 50[77]。

第二步查询维基百科，使用已有的查询引擎识别与所得关键词相关的维基百科文章。这些文章构成了领域特定语料库的基础。为每个关键词检索匹配的维基百科文章，当关键词包含在文章标题中时，则认为该文章为匹配项。如果上述条件不满足，则不会检索到相应的维基百科文章。

然后通过参考维基百科[79]层次化的类别关系增强从语料库中获得的领域信息，在维基百科的层次结构中，每个类别中均包含本类相关文章及其子类文章，在匹配的文章的基础上，对于这个类别找到所有在这个类别下的文章以及所有子类别的文章。如图 5.4 所示，“satellite navigation”的一篇相关文章处于一个同名的维基百科类别下（https://en.wikipedia.org/wiki/Category:Satellite_navigation）。检索该类别及其所有子类别中的所有文章。这样可以保证主题一致性[80]，即语料库中的文章都具有相关性。

为了使领域专用语料库能够被用于该领域内的不同需求文档，增加语料库的范围，在维基百科分类图中找到与匹配的文章所属于类别的相邻类别，如图 5.4 中的“navigation”直接连接到“satellite navigation”。因此，在其以及其所有子类下的文章均被包含。

中国知网 https://www.cnki.net

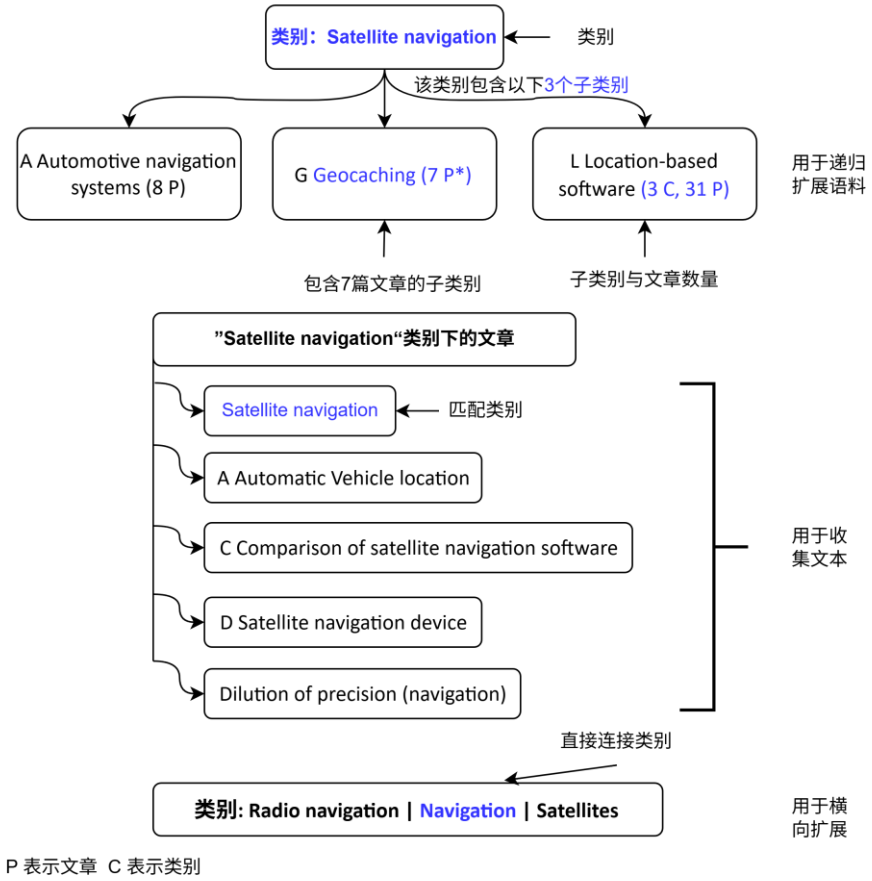


图 5.4 维基百科类别结构示例图

Fig. 5.4 Example of category structure in Wikipedia

5.3.2　歧义修复算法

基于 LLM 结合模式匹配进行判断容易出现幻觉，因此本文提出基于专家路由的多智能体歧义修复机制，通过歧义类型驱动路由，分配给对应歧义定位专家进行分析，各阶段独立决策，最终输出歧义定位片段及对应的原因分析。每个专家内部有一套固定的流程，先用模式匹配获取初步结果，再由大语言模型判断出可能的歧义解释及其置信度，之后参考外部的信息或者术语库等进行修正，最后对各个部分的结果进行加权求和得到最终的歧义片段及原因。基于领域知识库中的内容结合具体歧义片段及其原因给出相应的解决方案并返回所对应的歧义片段的具体位置。

中国知网　https://www.cnki.net

表 5.2 歧义修复算法

Table 5.2 Ambiguity repair algorithm

算法 3.需求歧义修复

输入:需求歧义例子 R,已知的歧义类型列表 T,领域知识库 K;

输出:歧义定位结果 D,修复建议 S.

1. $Preprocessed_Text \leftarrow RUN_NLP_PREPROCESS(R)$;//Step 1:NLP 预处理

2. $M \leftarrow \{\text{content}: R, \text{nlp_analysis}: Preprocessed\ Text\}$;

3. $D \leftarrow \varnothing, S \leftarrow \varnothing$;

4.for each $type \in T$ do//Step 2:类型驱动的专家路由定位与修复

5. $E \leftarrow SELECT_EXPERT(type)$;

6. if $E \neq \text{null}$ then

7. $candidates \leftarrow \varnothing$;

8. $rule_candidates \leftarrow RULE_BASED_MATCH(M, type)$;

9. $candidates \leftarrow candidates \cup rule_candidates$;

10. $llm_candidates \leftarrow LLM_GENERATE_CANDIDATES(M, type, rule_candidates)$;

11. $candidates \leftarrow candidates \cup llm_candidates$;

12. $calibrated_candidates \leftarrow DOMAIN_KNOWLEDGE_INJECT(M, candidates, type)$;

13. $final_result \leftarrow AGGREGATE_CONFIDENCE(calibrated_candidates)$;

14. if $final_result.confidence \geq \theta$ then

15. $D \leftarrow D \cup \{final_result\}$;

16. $ambiguity_segment \leftarrow EXTRACT_AMBIGUITY_SEGMENT(final_result)$;

17. $analysis_reason \leftarrow EXTRACT_REASON_ANALYSIS(final_result)$;

18. $repair_suggestions \leftarrow GENERATE_SUGGESTIONS(ambiguity_segment, analysis_reason, K)$;

19. $S \leftarrow S \cup \{repair_suggestions\}$;

20. end if

21. end if

22.end for

23.return (D, S)

如表 5.2 所示，完整描述 LMArepair 的需求歧义修复过程包括四部分内容。首先是对需求文本进行预处理，然后是基于类型的专家路由定位，接着是候选歧义生成，最后是给出修复建议。其中预处理器是用于对需求文本进行解析并将原始

中国知网 https://www.cnki.net

文本转化为结构化表示形式。专家路由是在六个专家智能体内选择一个与当前歧义类型相对应的专家模块。每个专家模块内具有该种歧义类型所对应模式库、提示模板及有关知识资源等，可用于识别出相应歧义的内容并对它们进行分析。候选歧义生成器是基于规则匹配以及利用大语言模型获得一系列可能存在的歧义候选集合，在发现某种歧义类型之后还会找出具体的歧义部分及其原因。修复建议生成器则接收歧义的部分、原因以及知识库 K 作为输入，进而提出对该部分的修复建议，具体操作为，根据歧义类型从知识库 K 中找到相应的修复模板之后，给出一些关于如何修复的方向性指导，形成可供需求工程师进行审核决策的细节性的修复建议，从而使得需求能够有效地进行重新表述。

5.4　实验分析

本节从不同维度对 LMArepair 进行实验评估。首先针对 LMArepair 存在的挑战与问题，给出关于该歧义修复方法的两个研究问题。随后通过评估歧义修复方法的不同方面来解答这两个研究问题。为评估 LMArepair 的修复效果，本文开展了实验进行评估，最后基于评估结果分析了 LMArepair 的优势与局限性。

5.4.1　研究问题

为了评估 LMArepair 方法的有效性，本节提出以下 2 个研究问题。

问题 1：LMArepair 在歧义定位上是否优于现有方法？旨在对比 LMArepair 与基线方法在不同类型歧义定位任务上的性能。

问题 2：LMArepair 生成的修复建议是否有效？从正确性、语义保留度、负面影响及整体质量提升四个维度，通过专家评估验证修复建议的质量。

5.4.2　评价指标及基准方法

在本文中，将采用 3 个经典的指标来评估 LMArepair 的性能，包括召回率、精确率、$F1$ 分数。

本文对提出的 LMArepair 与 Ezzini 等人[32,33]以及 Talha 等人[36]的工作进行对比，使用相同数据集与评估指标开展对比实验。LMArepair 的修复结果包含歧义定位结果与修复建议两个部分，分别采用不同的评估方式：针对歧义定位结果，使用客观指标衡量定位的有效性；针对修复建议，由于缺乏统一的客观真值标准，本文采用专家评分方式进行主观评估，以弥补自动化指标在语义层面评估能力的不足。

中国知网　https://www.cnki.net

5.4.3 实验方法

本章实验使用与第三章相同的正例样本数据集，在第 3.1.1 小节中对其来源及具体情况进行介绍的基础上，又增加 49 条需求指代歧义[33]的例子，共有 921 条需求数据。

本文用这 921 条需求歧义的例子当作需求歧义修复的实验数据集。在配有英特尔酷睿 i9 处理器和 16GB 内存的 Windows11 的电脑上进行实验，使用 deepseek-v3-0324 作为本实验的大语言模型，设置 0.5 温度参数，实验参数设置已在第 4.5.3 节中进行了详细说明。

5.4.4 实验结果与分析

问题 1：LMArepair 在歧义定位上是否优于现有方法？

为了验证这个问题的结果，本文将 LMArepair 与基于句法模式匹配的 Ezzini 等人[32]的工作、基于微调模型的方法[33]和基于语言规则结合 NLP 分析的半自动方法[36]进行了对比实验，并将单使用大语言模型在数据集上对需求进行歧义定位，计算了对应定位歧义片段的召回率、精确率、*F*1 分数。对比实验的结果如表 5.3 至表 5.6 所示。

表 5.3 LMArepair 与句法模式匹配方法性能比较（句法歧义）

Table 5.3 Performance comparison of LMArepair and syntactic pattern matching method(syntactic ambiguity)

工具/方法	精确率	召回率	*F*1 分数
LLM	0.6761	0.6575	0.6667
LMArepair	0.8472	0.8356	0.8414
句法模式匹配	0.7612	0.8500	0.8031

由表 5.3 可见，在句法歧义定位方面 LMArepair 在三种方法中取得最佳结果，*F*1 为 0.8414，与 LLM 结果相比，在精确率以及召回率方面分别提升 0.1711、0.1781，*F*1 上升约 17 个百分点，上述结果说明在 LLM 上结合句法分析树进行思考及多个 Agent 合作的方法有利于提高 LLM 对句法结构识别效果。而相比于传统的基于句法模式匹配的方法，LMArepair 的 *F*1 分数高出约 4%并且在精确率方面有明显的优势。

中国知网 https://www.cnki.net

表 5.4 LMArepair 与现有方法性能比较（语用歧义）

Table 5.4 Performance comparison of LMArepair with existing methods(pragmatic ambiguity)

工具/方法	精确率	召回率	*F*1 分数
LLM	0.6951	0.6129	0.6514
LMArepair	0.7391	0.8500	0.7907
SpanBERT_RE 模型	0.5278	0.6333	0.5758
语言规则结合 NLP	0.7561	0.7126	0.7337

表 5.4 展示了语用歧义定位对比结果，LMArepair 的 *F*1 是 0.7907，相比语言规则结合 NLP 方法提升约 6 个百分点，与只使用 LLM 相比提升 0.1393。SpanBERT_RE 在该任务上效果较差，但是语言规则结合 NLP 方法效果较为理想，*F*1 为 0.7337，而 LMArepair 通过指代词标注以及 LLM 对上下文进行推断，在满足规则的同时兼顾语义上的灵活性，因此其在召回率及精确率上都表现出色并且对语用歧义定位有很好的鲁棒性。

从表 5.5 可以看出，相较于同类别方法，LMArepair 在词汇歧义、语义歧义的定位上表现最优。对于词汇歧义而言，LMArepair 的 *F*1 值为 0.9191，相比 LLM 基线提高 2 个百分点，说明词汇歧义具有明显特点，而 LLM 自身就已具备较强识别能力，LMArepair 利用领域术语库使得其在召回方面略有增加，保证所有歧义词都被涵盖。而在语义歧义上，LMArepair 的 *F*1 值为 0.8347，相比于 LLM 基线仅高出 1.52 个百分点。这是因为 LMArepair 使用逻辑语义规则库进行修正以防止出现对多个否定嵌套判断错误的情况，故 *F*1 值提升相对不显著。

如表 5.6 所示，LMArepair 的 *F*1 分数为 0.6585、0.7108，在两种任务中都高于 LLM 基线。从语法歧义角度，LMArepair 精确率及召回率分别高出 19.05%、20%。这表示语法上的定位对于通用 LLM 而言有较大难度，但是用规则库结合特定语法歧义定位处理的智能体在歧义片段的定位结果上能起到一定的效果。而在语言错误歧义方面，LMArepair 相对于 LLM 基线只提高了大约 2%，其召回率从之前的 0.7176 提高到 0.7529。使用一个语法错误检测工具以及标点拼写规则库可以起到一定作用，但是还有很大的进步空间。

综上，LMArepair 对于对应的歧义片段定位的效果比传统方法以及基线模型更好。LMArepair 融合模式匹配规则以及大语言模型的优点，在需求歧义定位上效果显著，在与其他的方法相比也具有优势，在面对大语言模型情况下仍然有竞争力，

中国知网　https://www.cnki.net

说明其对于需求歧义定位的有效性和鲁棒性。

表 5.5 词汇歧义和语义歧义定位方面性能比较

Table 5.5 Performance comparison of lexical ambiguity and semantic ambiguity in positioning

工具/方法	词汇歧义			语义歧义		
	精确率	召回率	*F*1 分数	精确率	召回率	*F*1 分数
LLM	0.9091	0.8889	0.8989	0.7937	0.8468	0.8195
LMArepair	0.9124	0.9259	0.9191	0.8005	0.8719	0.8347

表 5.6 语法歧义和语言错误歧义定位方面性能比较

Table 5.6 Performance comparison of syntax ambiguity and language error ambiguity localization

工具/方法	语法歧义			语言错误歧义		
	精确率	召回率	*F*1 分数	精确率	召回率	*F*1 分数
LLM	0.4524	0.4750	0.4634	0.6630	0.7176	0.6893
LMArepair	0.6429	0.6750	0.6585	0.6737	0.7529	0.7108

问题 2：LMArepair 生成的修复建议是否有效？

在验证歧义定位效果之后，本文还对 LMArepair 提出的修复建议进行评价。由于修复建议是关于语义上的正确性和合适程度的问题，无法用一种自动的方式对其进行衡量，所以本研究采用专家打分的方式，在多个方面对修复结果是否合理进行评估。

为了回答该问题，本文请五位有丰富的需求工程师经验的领域专家对每一个修复案例进行打分，每个专家使用一个 5 级李克特量表从四个方面进行评价。正确性是指修复是否有效地解决原始歧义问题（1=未纠正，5=已全部纠正）；语义保留度是修复是否保留原有的意思（1=改变了意义，5=完全保持原意）；负面影响是修复是否产生新的歧义（1=造成很大麻烦，5=没有任何问题）；总体的质量提升是修复是否提高可读性和总体质量（1=降低，5=极大提高）。

为了保证评估的完整性与覆盖度，本研究对实验数据集中的全部修复结果进行评估，涵盖词汇歧义、句法歧义、语义歧义、语用歧义、语法歧义、语言错误歧义六种类型。五位专家在不了解彼此打分的情况下各自对所有样本进行评分，

中国知网 https://www.cnki.net

表 5.7 所呈现的均值、标准差及 Fleiss' Kappa 均基于五位专家的独立评分计算得出。对于任意两位专家评分差异超过 2 分的样本，组织全体专家讨论以核查评分标准的理解是否存在偏差，讨论结论仅作为定性参考，不纳入表 5.7 的统计计算。

结果表明，在这四个维度中 LMArepair 都取得了高分。平均正确率为 4.12，即大多数生成的修复方案确实消除了最初的歧义。较小的标准差为 0.68，意味着不同的修复方案的效果一致。LMArepair 在语义保留方面得分最高，得分为 4.35，即所生成的修复方案基本保持原意。负反馈得分为 4.08，即大多数修复方案不会引入新的歧义，这也表明给出的意见是有价值的。最后总体质量得分 4.21 说明除了消除歧义外，LMArepair 会使需求更易于理解。

表 5.7 专家评估结果

Table 5.7 Expert evaluation results

评估维度	均值	标准差	Fleiss' Kappa
正确性	4.12	0.68	0.61
语义保留度	4.35	0.54	0.67
负面影响	4.08	0.72	0.53
整体质量改善	4.21	0.61	0.58

为了保证评估结果的有效性，在此采用 Fleiss' Kappa 系数来反映五个评价者的评分一致性情况，每个方面总体上的 Kappa 值介于 0.53 至 0.67 之间，按照 Landis 等人[81]的分级标准，其中“正确性”与“整体质量提升”两个维度达到“显著一致”水平，其余两个维度达到“中等一致”水平，表明专家评估结果具有可接受的一致性，评估过程具备可靠性。

如上所述，实验结果表明，LMArepair 利用 LLM 融合领域信息后，在语义层面有较大改进，在给出具体可行建议的同时，可以提出有意义的修复方案，有利于帮助需求工程师做出更好选择，因此可以解决歧义问题。专家评估结果表明，LMArepair 生成的修复建议在正确性、语义保留度、负面影响控制及整体质量提升四个维度上均获得较高评分，评分一致性达到可接受水平，说明该方法能够生成质量较高的修复建议，具备一定的实用价值。

中国知网　https://www.cnki.net

5.4.5 讨论与局限性

本文根据实验结论回答上述两个问题，在对这些问题的回答进行思考之后得出。LMArepair 可以给需求中的歧义提出合理解决方案，这对于需求分析人员处理歧义具有积极意义，可以降低后续开发中的时间成本以及风险成本。尽管 LMArepair 对于解决歧义具有积极作用，但是对于提出的解决方案与原本意图之间在某些情况下仍然存在微小差异，在特定场景下可能存在细微的语义区别，因此未来的研究工作可以考虑增加形式化验证或基于约束验证的方法来保证语义的一致性，提高最终的结果质量。本研究未逐一剥离各模块进行传统消融实验。作为替代，实验中的“单 LLM”基线相当于同时移除所有附加模块的消融设置，结果表明 LMArepair 相较于单 LLM 在各歧义类型上均有显著提升，证明了多模块协同的整体有效性。此外，由于模式匹配、知识库等模块之间存在非线性耦合，且部分歧义类型的样本量有限，独立消融难以公平评估单一模块贡献，故本研究以“有无完整框架”作为主要对比粒度。未来工作可采用模块输出贡献分解、反事实评估或逐步冻结参数等方法进行更细粒度的分析，以进一步揭示各模块的独立作用机制。

对于 LMArepair 的研究仍然有一些缺陷。第一点人工评估存在主观性，在有效性的评估上采用的是专家的意见进行打分，使用李克特量表进行评分。虽然评分者的一致性表明这个方法是有一定的可靠性的，但是人工评估本身就带有主观的因素。第二点数据量较小，目前的需求歧义修复大多是由研究人员创建的数据集，而这并不能很好地反映实际情况，也无法很好的体现出大规模工业级的 SRS 情况，还需要更多的测试。最后出现过度规范的风险，在一些情形下，模型会增加需求中原本没有提到的一些限制条件，造成过度规范的问题。虽然这样做可以增加清晰度，但是也会减少设计的灵活性。

5.5 本章小结

本文提出一种基于 LLM 协调多个 Agent 解决需求歧义问题的方法 LMArepair。此方法利用模式匹配规则以及 LLM，结合专业知识，对 SRS 中出现的需求歧义进行歧义片段识别并提出相应的解决方案。在已有的一些需求歧义及它们所对应类型的具体示例上应用 NLP 技术和模式匹配找出每个例子中的歧义部分进而得到可能的候选歧义片段，再通过 LLM 配合领域知识提供更具针对性的修复建议。

中国知网 https://www.cnki.net

第 6 章　结论及展望

SRS 中的歧义是自然语言需求中常见的质量问题，这类问题可能引发误解进而导致项目失败。为应对传统歧义检测与修复方法低效且覆盖面不足的问题，本文提出了一种基于大语言模型的新思路，即利用这种智能自动化的手段来进行需求歧义检测并进行相应的修复处理，降低人工干预程度的同时节约时间成本并提高需求质量。本文的主要贡献如下。

1.构建面向需求歧义检测与修复的大语言模型经验研究体系，填补了该领域系统性实证研究的空白。针对大语言模型应用于需求歧义处理这一尚待探索的领域，围绕模型检测性能评估、提示词模板与流程规范设计、与当前最先进方法的对比验证三个递进式问题开展实证研究，系统明确了大语言模型在需求歧义检测任务上的能力边界与局限所在。实验结果表明，所设计的提示词模板与流程规范在歧义检测准确率上相较当前最先进方法提升了 4 个百分点，验证了其有效性。

2.提出了一种基于大语言模型与规则结合的多智能体协同的检测方法 LMAdetect，通过大语言模型提取需求文档的词汇、句法和语义特征，构建多维度语言表示，相比传统工具，该方法能够有效识别复杂的句法和语义歧义。本文也设计了一种基于优先级排序机制的歧义分类机制，根据需求语句的上下文特征，精准区分词汇歧义、句法歧义、语法歧义等多种歧义类型，并通过注意力权重排序潜在歧义语句的优先级。实验结果表明，LMAdetect 在已有的需求数据中成功检测出传统方法检测不到的歧义，且在可检测到的歧义类型中召回率平均提升 35.6%， *F*1 分数达到 0.906。

3.提出了一种基于大语言模型与领域知识集成的需求歧义修复方法 LMArepair。该方法提出了结构化歧义修复生成模式，通过分阶段解释与模板化输出设计，增强了模型生成结果的规范性与可控性，为自动化需求修订提供了可实施方案。实验结果表明，LMArepair 相比于传统方法， *F*1 分数平均提升 0.1034，相比于 LLM， *F*1 分数平均提升约 9 个百分点。

尽管本研究在基于大语言模型的需求歧义检测和修复方面已经取得良好的效果，但研究内容仍有深入的空间，未来将朝着以下三个方向努力。

1.收集包含上下文依赖关系的数据集，如用户故事级需求集合或跨句关联的需求片段，以进一步研究篇章级语义一致性下的歧义检测问题。将上下文感知能力从局部扩展到篇章级，贴近真实软件开发场景。同时，将针对不同领域（如医疗、

中国知网　https://www.cnki.net

金融、自动驾驶等）收集领域特定需求文档，开展跨领域泛化能力研究，验证方法在不同领域间的迁移效果。此外，建立公开的误差案例库，对检测与修复失败的案例进行系统分类与根因分析（如标注偏差、规则覆盖不足、LLM 幻觉等），以提升方法的可复现性与可解释性。

2.探索更多的指导机制，利用本文提出的关键结构分析方法，扩展到其他需求质量问题的检测，如不完整条件或不精确术语，以进一步提升需求工程的自动化水平。同时，进一步纳入更多最新的基线方法进行对比，并考察不同规模 LLM 对检测与修复效果的影响，明确模型规模与性能之间的量化关系。

3.在统一的多 Agent 框架下，系统构建覆盖“检测-修复”全流程的端到端需求文本质量提升方案，并在真实需求工程场景中开展实证研究。具体包括：与软件企业合作，将所提方法集成到实际需求评审流程中，评估方法的实际效用、响应延迟及资源开销；同时，增强修复结果的可解释性，如输出中间推理链、可视化歧义定位依据、提供替代方案对比等，以提升需求工程师对自动化修复建议的信任度与采纳率。

中国知网 https://www.cnki.net

参 考 文 献

[1] AMBREEN T, IKRAM N, USMAN M, et al. Empirical research in requirements engineering: trends and opportunities[J]. Requirements Engineering, 2018, 23(1): 63-95.

[2] 曹步展. 面向领域的需求模板符合性及缺陷检测方法研究[D]. 南京: 南京航空航天大学, 2022.

[3] BERRY D M, KAMSTIES E, KRIEGER M M. From contract drafting to software specification: Linguistic sources of ambiguity[M]. Waterloo: University of Waterloo, 2003.

[4] KAMSTIES E, PAECH B. Taming ambiguity in natural language requirements [C] //Proc of the Thirteenth Int Conf on Software and Systems Engineering and Applications. Paris, France: Center for Mastering Systems & Software (CMSL) of CNAM, 2000.

[5] DOE J. Recommended practice for software requirements specifications (IEEE) [S]. New York, USA: Midori, 2011-12-29.

[6] JACKSON M. Software requirements & specifications: a lexicon of practice, principles and prejudices[M]. New York: ACM Press/Addison-Wesley, 1995.

[7] BEER A, JUNKER M, FEMMER H, et al. Initial investigations on the influence of requirement smells on test-case design[C]//2017 IEEE 25th International Requirements Engineering Conference Workshops (REW). Lisbon: IEEE, 2017: 323-326.

[8] SHANG Y R, JIN S. On the ambiguity caused by the language structure in the legal case[C]//Proceedings of the 2018 3rd International Conference on Education, E-learning and Management Technology (ICEEMT 2018). Paris: Atlantis Press, 2018: 499-504.

[9] 王春晖, 金芝, 赵海燕, 等. 一种用户故事需求质量提升方法[J]. 计算机研究与发展, 2021, 58(04): 731-748.

[10] RUPP C, GOETZ R. Linguistic methods of requirements engineering (NLP)[C]//Proceedings of the European Software Process Improvement Conference (EuroSPI 2000). Copenhagen: ELRA, 2000: 68-80.

[11] GAUSE D C, WEINBERG G M. Exploring requirements: quality before design[M]. New York: Dorset House, 1989.

[12] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies,

中国知网 https://www.cnki.net

Volume 1 (Long and Short Papers). Minneapolis: Association for Computational Linguistics, 2019: 4171-4186.

[13] 陈贝, 杜贺, 何远杭, 等. 基于多智能体协作的自动化漏洞修复[J/OL]. 西安电子科技大学学报, 1-14[2026-03-27]. https://doi.org/10.19665/j.issn1001-2400.20260111.

[14] KAMSTIES E, BERRY D M, PAECH B. Detecting ambiguities in requirements documents using inspections[C]//Proceedings of the First Workshop on Inspection in Software Engineering (WISE'01). Hamilton, Canada: Software Quality Research Lab, McMaster University, 2001: 68-80.

[15] FABBRINI F, FUSANI M, GNESI S, et al. An automatic quality evaluation for natural language requirements[C]//Proceedings of the Seventh International Workshop on Requirements Engineering: Foundation for Software Quality (REFSQ'01). Interlaken, Switzerland: REFSQ Workshop, 2001: 4-5.

[16] BERRY D M, KAMSTIES E. Ambiguity in requirements specification[C]//Perspectives on software requirements. Boston, MA: Springer, 2004: 7-44.

[17] NIGAM A, ARYA N, NIGAM B, et al. Tool for automatic discovery of ambiguity in requirements[J]. International Journal of Computer Science Issues, 2012, 9(5): 350-356.

[18] TJONG S F. Avoiding ambiguity in requirements specifications[D]. Nottingham: University of Nottingham, 2008.

[19] ROSADINI B, FERRARI A, GORI G, et al. Using NLP to detect requirements defects: An industrial experience in the railway domain[C]//Requirements Engineering: Foundation for Software Quality. Cham: Springer, 2017: 344-360.

[20] GLEICH B, CREIGHTON O, KOF L. Ambiguity detection: Towards a tool explaining ambiguity sources[C]//Requirements Engineering: Foundation for Software Quality. Berlin, Heidelberg: Springer, 2010: 218-232.

[21] SABRIYE A O J A, ZAINON W M N W. An approach for detecting syntax and syntactic ambiguity in software requirement specification[J]. Journal of Theoretical and Applied Information Technology, 2018, 96(8): 2264-2273.

[22] FERRARI A, ESULI A. An NLP approach for cross-domain ambiguity detection in requirements engineering[J]. Automated Software Engineering, 2019, 26(3): 559-598.

中国知网 https://www.cnki.net

[23] CODEN A, GENTILE A L, GRUHL D, et al. Identifying ambiguity in semantic resources[C]//Proceedings of the 10th International Conference on Knowledge Capture. New York: ACM, 2019: 5-12.

[24] ŠENKÝŘ D, KROHA P. Patterns of ambiguity in textual requirements specification[C]//New knowledge in information systems and technologies. Cham: Springer, 2019: 886-895.

[25] LIU Y, MEDLAR A, GLOWACKA D. Lexical ambiguity detection in professional discourse[J]. Information Processing & Management, 2022, 59(5): 103000.

[26] VEIZAGA A, SHIN S Y, BRIAND L C. Automated smell detection and recommendation in natural language requirements[J]. IEEE Transactions on Software Engineering, 2024, 50(4): 695-720.

[27] LEVY R, ANDREW G. Tregex and tsurgeon: Tools for querying and manipulating tree data structures[C]//Proc of the 5th Int Conf on Language Resources and Evaluation. 2006: 2231-2234.

[28] BANG Y, CAHYAWIJAYA S, LEE N, et al. A multitask, multilingual, multimodal evaluation of chatgpt on reasoning, hallucination, and interactivity[C]//Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics (Volume 1: Long Papers). Nusa Dua, Bali: Association for Computational Linguistics, 2023: 675-718.

[29] LIANG P, BOMMASANI R, LEE T, et al. Holistic evaluation of language models[J]. Transactions on Machine Learning Research, 2023.

[30] OSAMA M, ZAKI-ISMAIL A, ABDELRAZEK M, et al. Score-based automatic detection and resolution of syntactic ambiguity in natural language requirements[C]//2020 IEEE International Conference on Software Maintenance and Evolution (ICSME). Adelaide, SA: IEEE, 2020: 651-661.

[31] ASHFAQ F, BAJWA I S. Natural language ambiguity resolution by intelligent semantic annotation of software requirements[J]. Automated Software Engineering, 2021, 28(2): 13.

[32] EZZINI S, ABUALHAIJA S, ARORA C, et al. Using domain-specific corpora for improved handling of ambiguity in requirements[C]//2021 IEEE/ACM 43rd International Conference on Software Engineering (ICSE). Madrid, ES: IEEE, 2021: 1485-1497.

中国知网 https://www.cnki.net

[33] EZZINI S, ABUALHAIJA S, ARORA C, et al. Automated handling of anaphoric ambiguity in requirements: a multi-solution study[C]//Proceedings of the 44th International Conference on Software Engineering. Pittsburgh Pennsylvania: ACM, 2022: 187-199.

[34] IZHAR R, BHATTI S N, ALHARTHI S A. Bridging precision and complexity: A novel machine learning approach for ambiguity detection in software requirements[J]. IEEE Access, 2025, 13: 12014-12031.

[35] RAJ A. Leveraging large language model for ambiguity detection and resolution in software requirements[D]. Long Beach, CA: California State University, Long Beach, 2024.

[36] TALHA F, TAHIR T, NADEEM T. A semiautomated approach for detecting ambiguities in software requirements using SpanBERT and named entity recognition[J]. Journal of Software: Evolution and Process, 2025, 37(8): e70041.

[37] SCARLINI B, PASINI T, NAVIGLI R. With more contexts comes better performance: contextualized sense embeddings for all-round word sense disambiguation[C]//Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). Online: Association for Computational Linguistics, 2020: 3528-3539.

[38] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems, 2020: 1877-1901.

[39] CHANG Y, WANG X, WANG J, et al. A survey on evaluation of large language models[J]. ACM Transactions on Intelligent Systems and Technology, 2024, 15(3): 1-45.

[40] 王昀, 胡珉, 塔娜, 等. 大语言模型及其在政务领域的应用[J]. 清华大学学报（自然科学版）, 2024, 64(4): 649-658.

[41] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30: 5998-6008.

[42] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[J], 2018.

[43] SUN Y, WANG S, LI Y, et al. Ernie: Enhanced representation through knowledge integration[J], arXiv preprint arXiv:1904.09223, 2019.

[44] ZENG W, REN X, SU T, et al. Pangu-α: Large-scale autoregressive pretrained chinese language models with auto-parallel computation[J], arXiv preprint arXiv:2104.12369, 2021.

[45] SHIN T, RAZEGHI Y, LOGAN IV R L, et al. Autoprompt: Eliciting knowledge from language models with automatically generated prompts[C]//Proceedings of the 2020 Conference on

中国知网 https://www.cnki.net

Empirical Methods in Natural Language Processing (EMNLP). Online: Association for Computational Linguistics, 2020: 4222-4235.

[46] ACHIAM J, ADLER S, AGARWAL S, et al. Gpt-4 technical report[J]. arXiv preprint arXiv:2303.08774, 2023.

[47] LEONG I T, BARBOSA R. Translating natural language requirements to formal specifications: A study on gpt and symbolic nlp[C]//2023 53rd Annual IEEE/IFIP International Conference on Dependable Systems and Networks Workshops (DSN-W). Porto: IEEE, 2023: 259-266.

[48] ALSHAZLY A A, ELFATATRY A M, ABOUGABAL M S. Detecting defects in software requirements specification[J]. Alexandria Engineering Journal, 2014, 53(3): 513-527.

[49] BRIAND L, FALESSI D, NEJATI S, et al. Traceability and SysML design slices to support safety inspections: A controlled experiment[J]. ACM Transactions on Software Engineering and Methodology, 2014, 23(1): 1-43.

[50] GRANDA M F, CONDORI-FERNANDEZ N, VOS T E J, et al. What do we know about the defect types detected in conceptual models?[C]//2015 IEEE 9th International Conference on Research Challenges in Information Science (RCIS). Athens, Greece: IEEE, 2015: 88-99.

[51] ALENAZI M, NIU N, SAVOLAINEN J. SysML modeling mistakes and their impacts on requirements[C]//2019 IEEE 27th International Requirements Engineering Conference Workshops (REW). Jeju Island, Korea (South): IEEE, 2019: 14-23.

[52] BANO M. Addressing the challenges of requirements ambiguity: A review of empirical literature[C]//2015 IEEE Fifth International Workshop on Empirical Requirements Engineering (EmpiRE). Ottawa, ON, Canada: IEEE, 2015: 21-24.

[53] MANNING C D, SCHÜTZE H. Foundations of statistical natural language processing[M]. Cambridge, MA: MIT Press, 1999.

[54] 徐子懋, 姜艳杰, 张宇霞, 等. 基于大语言模型的长方法分解[J]. 软件学报, 2025, 36(06): 2501-2514.

[55] 许炜卓, 赵宇翔, 周阳, 等. 人智交互中大语言模型思维链对大学生提示词策略的影响研究[J]. 情报理论与实践, 2026, 49(03): 121-131.

[56] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[EB/OL]. (2023-12-03)[2026-03-02]. https://arxiv.org/abs/2305.10601.

中国知网 https://www.cnki.net

[57] KHOT T, TRIVEDI H, FINLAYSON M, et al. Decomposed prompting: A modular approach for solving complex tasks[EB/OL]. (2022-10-05)[2026-03-03]. https://arxiv.org/abs/2210.02406.

[58] LI M, ZHAO Y, YU B, et al. Api-bank: A comprehensive benchmark for tool-augmented llms[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 3102-3116.

[59] WANG L, MA C, FENG X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.

[60] SUMERS T R, YAO S, NARASIMHAN K, et al. Cognitive architectures for language agents[EB/OL]. (2023-09-05)[2026-03-03]. https://arxiv.org/abs/2309.02427.

[61] ABUALHAIJA S, FUCCI D, DALPIAZ F, et al. Preface: 3rd workshop on natural language processing for requirements engineering (NLP4RE'20)[C]//Joint Proc of REFSQ-2020 Workshops, Doctoral Symp, Live Studies Track, and Poster Track. Pisa, Italy: CEUR-WS.org, 2020.

[62] FANTECHI A, GNESI S, SEMINI L. Rule-based NLP vs ChatGPT in ambiguity detection, a preliminary study[C]//In Proc. REFSQ Workshops, 2023: 1-10.

[63] FAZELNIA M, KOSCINSKI V, HERZOG S, et al. Lessons from the use of natural language inference (NLI) in requirements engineering tasks[C]//2024 IEEE 32nd Int Requirements Engineering Conf (RE). IEEE, 2024: 103-115.

[64] SALEEM S, ASIM M N, DENGEL A. PassionNet: An innovative framework for duplicate and conflicting requirements identification[J]. Expert Systems with Applications, 2025, 293: 128684.

[65] WASOW T, PERFORS A, BEAVER D. The puzzle of ambiguity[J]. Morphology and the web of grammar: Essays in memory of Steven G. Lapointe. Stanford, CA: CSLI Publications, 2005: 265-282.

[66] ZHANG Y, LI Y, CUI L, et al. Siren's song in the AI ocean: A survey on hallucination in large language models[J]. Computational Linguistics, 2025, 51(4): 1373-1418.

[67] WANG BOXIN, CHEN WEIXIN, PEI HENGZHI, et al. Decodingtrust: A comprehensive assessment of trustworthiness in GPT models[C]//Proc of the 37th Annual Conf on Neural Information Processing Systems. New Orleans, LA, USA, 2023.

中国知网 https://www.cnki.net

[68] GUO B, ZHANG X, WANG Z, et al. How close is chatgpt to human experts? comparison corpus, evaluation, and detection[J]. arXiv preprint arXiv:2301.07597, 2023.

[69] ZAKERI-NASRABADI M, PARSA S. Natural language requirements testability measurement based on requirement smells[J/OL]. Neural Computing and Applications, 2024, 36: 13051-13085[2026-03-03]. https://doi.org/10.1007/s00521-024-09730-x.

[70] HABIB M K, WAGNER S, GRAZIOTIN D. Detecting requirements smells with deep learning: Experiences, challenges and future work[C]//2021 IEEE 29th International Requirements Engineering Conference Workshops (REW). 2021: 153-156.

[71] 陈炫婷, 叶俊杰, 祖璨, 等. GPT 系列大语言模型在自然语言处理任务中的鲁棒性[J]. 计算机研究与发展, 2024, 61(05): 1128-1142.

[72] LIU C, BAO X, ZHANG H, et al. Improving chatgpt prompt for code generation[EB/OL]. (2023-05-14)[2026-03-03]. https://arxiv.org/abs/2305.08360.

[73] TOY J, MACADAM J, TABOR P. Metacognition is all you need? using introspection in generative agents to improve goal-directed behavior[J]. arXiv preprint arXiv:2401.10910, 2024.

[74] JIANG X, LI F, ZHAO H, et al. Long term memory: The foundation of ai self-evolution[EB/OL]. (2024-10-21)[2026-03-03]. https://arxiv.org/abs/2410.15665.

[75] QIAN C, LIU W, LIU H, et al. Chatdev: Communicative agents for software development[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok, Thailand: Association for Computational Linguistics, 2024: 15174-15186.

[76] POMIAN D, BELLUR A, DILHARA M, et al. Together we go further: Llms and ide static analysis for extract method refactoring[J]. arXiv preprint arXiv:2401.15298, 2024.

[77] EZZINI S. Artificial intelligence-enabled automation for ambiguity handling and question answering in natural-language requirements[D]. Lancaster: Lancaster University, 2022.

[78] ARORA C, SABETZADEH M, BRIAND L, et al. Automated extraction and clustering of requirements glossary terms[J]. IEEE Transactions on Software Engineering, 2017, 43(10): 918-945.

[79] STRUBE M, PONZETTO S P. WikiRelate! Computing semantic relatedness using Wikipedia[C]//Proceedings of the 21st national conference on Artificial intelligence: AAAI-06. Menlo Park, Calif.: AAAI Press, 2006: 1419-1424.

中国知网 https://www.cnki.net

[80] NEWMAN D, LAU J H, GRIESER K, et al. Automatic evaluation of topic coherence[C]//Human language technologies: The 2010 annual conference of the north american chapter of the association for computational linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2010: 100-108.

[81] LANDIS J R, KOCH G G. The measurement of observer agreement for categorical data[J]. biometrics, 1977: 159-174.

中国知网 https://www.cnki.net